MINISTERE DE
L'ENSEIGNEMENT SUPERIEUR,
DE LA RECHERCHE ET DE
L'INNOVATION
****
UNIVERSITÉ NAZI BONI
****
UNITE DE FORMATION ET DE
RECHERCHE EN SCIENCES
EXACTES ET APPLIQUÉES

BURKINA FASO
****
La Patrie ou La Mort, Nous Vaincrons

MÉMOIRE DE FIN D'ÉTUDES

Sur le thème :

Étude des meilleures distributions *a priori* des paramètres pour la modélisation des maladies infectieuses

Pour l'obtention du diplôme de

Master en Statistiques Appliquées et Aide à la Décision (SAAD)

présenté et soutenu le 07/02/2026 **par**

OUEDRAOGO Rachidatou

Sous la Direction de : **Dr Sobom M. SOMÉ** Maître de conférences à l'Université Thomas Sankara

Sous la Co-Direction de : **Dr Serge M. A. SOMDA** Maître Assistant à l'Université Nazi BONI

Composition du jury

Monsieur Boureima SANGARÉ	*Professeur Titulaire*	Président
Monsieur Sobom Matthieu SOMÉ	*Maître de Conférences*	Directeur de Mémoire
Monsieur Moussa BARRO	*Maître de Conférences*	Examinateur
Monsieur Serge M. A. SOMDA	*Maître Assistant*	Co-Directeur de Mémoire

Année académique : 2022 - 2023

TABLE DES MATIÈRES

DÉDICACE **I**

REMERCIEMENTS **II**

RÉSUMÉ **III**

ABSTRACT **IV**

LISTE DES SIGLES ET DES ABRÉVIATIONS **V**

I INTRODUCTION GÉNÉRALE **1**

I.1 Contexte et justification 1

I.2 Problématique et revue de la littérature 2

I.3 Objectifs de l'étude 3

I.4 Hypothèse de l'étude 3

II ESTIMATION STATISTIQUE BAYÉSIENNE **4**

II.1 Principe de l'estimation bayésienne 4

II.1.1 Rappel de la théorie 4

II.1.2 Estimation bayésienne 5

II.2 Mise en œuvre de l'estimation bayésienne 6

II.2.1 Les chaînes de Markov et les méthodes de Monte Carlo 6

II.2.2 Les algorithmes MCMC 7

II.2.3 Les solutions logicielles 13

II.3 Détermination de la loi *a priori* 13

II.3.1 Lois *a priori* informatives 13

II.3.2 Ellicitation Subjective 13

II.3.3 Lois conjuguées 14

II.3.4 Lois non informative 16

III LOIS *A PRIORI* POUR LA MODÉLISATION DES MALADIES INFECTIEUSES **21**

III.1 Présentation des modèles 21

III.2 Étude des distributions *a priori* 23

III.2.1 Modélisation Bayésienne 23

III.2.2 Distributions *a priori* 25

IV COMPARAISON DES LOIS *A PRIORI* **33**

IV.1 Approche Méthodologique 33

IV.1.1 Simulation Numérique 33

IV.1.2 Détermination des meilleures distributions 34

IV.2 Résultats 35

IV.2.1 Résultats de l'évaluation de la performance des priors sur le taux de transmission 35

IV.2.2 Résultats de l'évaluation de la performance des priors sur le taux des rétirés . . 36

V DISCUSSION ET CONCLUSION **38**

V.1 Résultats globaux 38

V.2 Discussion 38

V.1.1 Vérification des hypothèses 38

V.1.2 Convergence et performance des estimations 39

V.1.3 Comparaison des performances entre distributions a priori 40

V.1.4 Limites et forces de l'étude 41

V.1.5 Recommandations pratiques et perspectives 41

V.2 Conclusion 42

ANNEXE **47**

Annexe I : Éléments complémentaires sur les chaînes de Markov **49**

Annexe II : Demonstration **52**

Annexe III : Code R **55**

DÉDICACE

A mes aimables parents Madi OUEDRAOGO et Haoua BANDAOGO, merci pour tout.

A mes frères et soeurs, vous êtes adorables merci pour vôtre soutien.

REMERCIEMENTS

Au terme de ce travail, animé d'un profond sentiment de satisfaction, je tiens à exprimer ma sincère gratitude à toutes les personnes qui, de près ou de loin, ont contribué à la réalisation de ce mémoire.

- ✓ Je voudrais tout d'abord adresser mes remerciements à mon Directeur de mémoire, Dr Sobom Matthieu SOMÉ, enseignant-chercheur à l'Université Thomas Sankara, pour avoir accepté de diriger ce travail. Sa disponibilité, son écoute attentive et la pertinence de ses conseils ont fortement contribué à l'aboutissement de cette étude.
- ✓ Je tiens également à exprimer ma profonde reconnaissance à mon Co-directeur de mémoire, Dr Serge M.A. SOMDA, enseignant-chercheur à l'Université Nazi BONI, biostatisticien et responsable du Centre de Calcul au Centre MURAZ. Je lui suis particulièrement reconnaissant pour son accueil chaleureux, le temps qu'il m'a consacré, ainsi que pour le partage généreux de son expertise et ses conseils inestimables.
- ✓ J'adresse mes respectueux remerciements à Pr Boureima SANGARÉ, pour l'honneur qu'il me fait en acceptant de présider ce jury de soutenance.
- ✓ Je remercie également Dr Moussa BARRO, pour avoir accepté d'examiner ce travail avec attention et pour ses observations constructives qui contribueront à son amélioration.
- ✓ J'exprime ma gratitude au Coordonnateur de la filière Master Statistique Appliquée et Aide à la Décision Dr Serge M.A. SOMDA, pour ses efforts constants dans l'organisation de la formation et pour la qualité des enseignements reçus.
- ✓ Mes remerciements vont aussi à toute l'équipe du Centre de Méthodologie et de Gestion des Données, en particulier M. Ibrahima DIALLO, M. Éric DABONÉ et Mme Florence KANGOYE, pour leur accueil, leur disponibilité et leurs conseils avisés.
- ✓ Je tiens également à remercier chaleureusement mes camarades de promotion, pour l'entraide, les échanges scientifiques enrichissants et l'esprit de solidarité qui ont accompagné tout ce parcours.
- ✓ Enfin, je remercie toutes les personnes qui m'ont soutenu, conseillé et encouragé durant la réalisation de ce mémoire, notamment Tatiana BAYALA, Djamal TOÉ, Diane TOÉ, Issouf TRAORÉ, Aïcha OUATTARA, Emmanuel SERMÉ et M. Augustin ZOUNGRANA, ainsi que mes ami(e)s et tous ceux qui ont contribué, de près ou de loin, à l'aboutissement de ce travail.

RÉSUMÉ

Avec pour objectif de chercher les meilleures distributions a priori pour l'estimation des paramètres du modèle dans le cadre des maladies infectieuses, nous avons adopté une approche de simulation Monte-Carlo pour évaluer six distributions *a priori* candidates pour le taux de transmission et pour le taux de retrait à savoir : Gamma (conjuguée), Log-normale (informative), Uniforme (Laplace), Beta de Jeffreys (non informative), Beta (subjective) et Gamma inverse. À partir de 1 000 jeux de données synthétiques générés selon un modèle SIR avec $\beta = 0{,}3$ et $\gamma = 0{,}1$, nous avons estimé les paramètres d'intérêt via l'algorithme MCMC de Gibbs implémenté dans le package rjags. Pour chaque simulation, la performance a été évaluée selon les critères suivants : la convergence des chaînes, la précision prédictive (RMSE, biais), et la couverture des intervalles de crédibilité à 95%.

Toutes les distributions testées ont démontré d'excellentes propriétés de convergence pour le taux de transmission (taux de succès $> 98{,}9\%$, R $< 1{,}1$), confirmant l'exploration satisfaisante de l'espace paramétrique. En termes de précision prédictive, la distribution non informative de Laplace (Uniforme(0,1 ; 0,5)) s'est distinguée avec le RMSE le plus faible (0,1049). Pour le paramètre du taux de retrait, le prior de Laplace qui est la loi Uniforme (0,07 ; 0,14) a affiché la meilleure performance prédictive (RMSE = 0,0141) avec une couverture de 89,6%, tandis que le prior Gamma (30,86 ; 308,64) a excellé en termes de convergence 92% avec un RMSE de 0,0178.

Cette étude établit qu'il n'existe pas de prior universellement optimal. Le choix doit être contextualisé selon la nature du paramètre, le cadre épidémiologique et les objectifs de l'analyse. Pour les modèles SIR, les distributions Uniforme et Gamma conjuguée offrent le meilleur compromis entre précision, stabilité et flexibilité. Ces résultats ouvrent des perspectives pour l'amélioration méthodologique, l'extension à des modèles plus complexes et la validation sur données réelles.

Mots-clés : Distributions a priori, épidémiologie, MCMC, modèle SIR, Modélisation bayésienne

ABSTRACT

Aiming to identify the best prior distributions for parameter estimation in the context of infectious diseases, we adopted a Monte Carlo simulation approach to evaluate six candidate prior distributions for the transmission rate and for the removal rate, namely : Gamma (conjugate), Log-normal (informative), Uniform (Laplace), Jeffreys Beta (non-informative), Beta (subjective), and Inverse Gamma. From 1,000 synthetic datasets generated according to an SIR model with $\beta = 0.3$ and $\gamma = 0.1$, we estimated the parameters of interest using the Gibbs MCMC algorithm implemented in the rjags package. For each simulation, performance was assessed according to four criteria : chain convergence, predictive accuracy (RMSE, bias), and coverage of the 95% credibility intervals.

All tested distributions demonstrated excellent convergence properties for the transmission rate (success rate $> 98.9\%$, R < 1.014), confirming satisfactory exploration of the parameter space. In terms of predictive accuracy, the non-informative Laplace distribution (Uniform(0.1, 0.5)) stood out with the lowest RMSE (0.1049). For the removal rate parameter, the Laplace prior, which is the Uniform(0.07, 0.14) distribution, showed the best predictive performance (RMSE = 0.0141) with a coverage of 89.6%, while the Gamma(30.86, 308.64) prior excelled in terms of convergence (92%) with an RMSE of 0.0178.

This study establishes that there is no universally optimal prior. The choice must be contextualized according to the nature of the parameter, the epidemiological framework, and the objectives of the analysis. For SIR models, the Uniform and conjugate Gamma distributions offer the best compromise between accuracy, stability, and flexibility. These results open perspectives for methodological improvement, extension to more complex models, and validation using real data.

Keywords : Bayesian modeling, epidemiology, MCMC, prior distributions, SIR model

LISTE DES SIGLES ET DES ABRÉVIATIONS

HMC	:	Hamiltonian Monte Carlo
MCMC	:	Monte Carlo par Chaîne de Markov
NUTS	:	No-U-Turn Sampler
RMSE	:	Racine de l'Erreur Quadratique Moyenne
SDE	:	Équation Différentielle Stochastique
SEIR	:	Susceptible-Exposé-Infecté-Rétabli
SIR	:	Susceptible-Infecté-Rétabli
SIRS	:	Susceptible-Infecté-Rétabli-Susceptible

LISTE DES TABLEAUX

1 Lois *a priori* conjuguées naturelles pour quelques familles exponentielles usuelles. . . . 16

1 Tableau récapitulatif des distributions *a priori* et *a posteriori* 32

1 Performance des modèles β 36

2 Performance des modèles γ 36

1 Lois *a priori* pour β 53

2 Lois *a priori* pour γ 54

I.1 Contexte et justification

Les maladies infectieuses demeurent l'une des principales causes de morbidité et de mortalité à l'échelle mondiale, représentant un défi majeur pour les systèmes de santé publique [1, 2]. Leur émergence est favorisée par une combinaison de facteurs interconnectés incluant la croissance démographique rapide, l'urbanisation non planifiée, l'intensification de la mobilité humaine, les modifications environnementales et climatiques, ainsi que les disparités dans les infrastructures sanitaires [3]. Selon l'Organisation Mondiale de la Santé, en 2021 [4], le taux de mortalité attribuable aux maladies infectieuses s'élevait à 184,6 décès pour 100 000 habitants au niveau mondial, avec des disparités régionales marquées : 608,7 pour 100 000 en Afrique et 682,9 pour 100 000 au Burkina Faso. Une analyse épidémiologique exhaustive menée par Liu et collaborateurs [5] a recensé 3 013 événements épidémiques entre 1996 et 2023, répartis comme suit : 1 305 infections respiratoires, 436 infections à transmission vectorielle, 469 épidémies d'origine hydrique ou alimentaire, 484 infections par contact direct et 319 autres types d'épidémies.

Face à l'émergence de ces maladies infectieuses et à l' ambition de relever les défis liés à la variation spatio-temporelle du nombre de cas de maladies infectieuses, la modélisation mathématique s'impose comme un outil essentiel pour la prise de décision en santé publique. En effet, les modèles mathématiques intègrent et structurent les données concernant : la dynamique de transmission épidémique, la sévérité différentielle selon les groupes démographiques, le statut immunitaire des populations, l'impact des mesures barrières et la protection vaccinale [6]. Parmi les modèles mathématiques couramment utilisés pour la modélisation des maladies infectieuses, les modèles compartimentaux jouent un rôle central. Toutefois, afin de mieux capturer l'incertitude, la variabilité individuelle, ou l'hétérogénéité de la population, il devient pertinent de recourir à des approches bayésiennes intégrant ces compartiments dans un cadre probabiliste.

L'approche bayésienne offre des perspectives prometteuses pour modéliser les épidémies en intégrant les connaissances préalables disponibles sur les paramètres épidémiologiques. Elle repose sur l'utilisation de lois *a priori*, qui expriment les croyances initiales ou les hypothèses sur les valeurs possibles des paramètres avant l'observation des données. Ces lois reflètent les connaissances préexistantes ou les suppositions que l'expérimentateur considère comme plausibles pour un paramètre donné [7]. Le choix de la distribution *a priori* constitue une étape méthodologique cruciale dont dépendent la validité et la robustesse des inférences. Selon Gelman et al. [8], ce choix doit être guidé par plusieurs considérations : la nature et la quantité d'informations disponibles, la taille de l'échantillon observé, la structure du modèle statistique, les propriétés computationnelles souhaitées et l'interprétabilité des résultats.

Toutefois, le choix de la distribution *a priori* la plus appropriée demeure un enjeu méthodologique majeur, notamment en épidémiologie, où les résultats peuvent être sensibles à cette spécification. D'où

l'intérêt de s'interroger sur la détermination des meilleures distributions *a priori* pour la modélisation des maladies infectieuses.

Dans ce travail, le chapitre 2 présentera les principes de l'estimation bayésienne, en exposant les fondements théoriques de l'inférence bayésienne ainsi que les outils nécessaires à l'estimation des paramètres dans les modèles épidémiologiques. Le chapitre 3 sera consacré aux différentes lois a priori utilisées dans la modélisation des maladies infectieuses, en mettant en évidence leur rôle dans l'intégration des connaissances préalables et leur importance dans la construction du modèle. Le chapitre 4 proposera une analyse comparative de ces lois a priori afin d'évaluer leur influence sur les estimations et d'identifier les choix les plus adaptés au contexte étudié. Enfin, le chapitre 5 présentera une discussion des résultats obtenus, suivie d'une conclusion générale exposant les principaux enseignements du travail, ses limites et les perspectives de recherche.

I.2 Problématique et revue de la littérature

Le choix de la distribution *a priori* en modélisation bayésienne est un élément essentiel, car il influence directement la stabilité et la fiabilité des inférences. Depuis l'essor de la statistique bayésienne, la question de savoir quel a priori est le plus adapté pour modéliser les maladies infectieuses reste largement débattue. En effet, plusieurs auteurs ont tenté d'apporter des lignes directrices claires pour orienter ce choix.

Les travaux de Gelman et al. [9] montrent que des *a priori* faiblement informatifs mais bien structurés permettent d'éviter des postérieures instables ou trop sensibles aux hypothèses. De leur côté, Hannestad et al. [10] déconseillent l'usage systématique d'*a priori* uniformes pour des paramètres contraints, car ces derniers peuvent fausser les estimations et donner une fausse impression de neutralité.

Plus récemment, Darges et al. [11] ont mis en évidence l'intérêt des distributions Gamma pour les paramètres strictement positifs : elles génèrent des postérieures plus cohérentes et introduisent moins de distorsion que d'autres formes d'a priori. Par ailleurs, Walter et Coolen [12] rappellent qu'en présence d'une forte incertitude sur l'*a priori*, il est plus prudent de considérer plusieurs possibilités plutôt qu'un choix unique, afin de renforcer la crédibilité des conclusions.

Ces travaux montrent qu'il existe aujourd'hui un débat méthodologique réel autour du choix des distributions *a priori*. Chaque auteur apporte un point de vue particulier et insiste sur des aspects différents de la modélisation bayésienne. Cette diversité souligne que le choix de l'*a priori* n'est pas anodin et qu'il peut influencer de manière significative la qualité des inférences.

Dans ce contexte, il devient essentiel de mettre en place un cadre méthodologique capable de comparer plusieurs spécifications *a priori*, non seulement selon des critères théoriques, mais aussi à travers leurs effets concrets sur l'estimation des paramètres épidémiologiques. La question centrale

qui guide cette étude est donc : Comment construire une démarche méthodologique permettant de comparer et de sélectionner les distributions *a priori* les mieux adaptées à la modélisation bayésienne des maladies infectieuses ?

I.3 Objectifs de l'étude

Pour répondre a cette question, nous nous sommes fixés comme objectif d'étudier les meilleures distributions *a priori* des paramètres pour la modélisation des maladies infectieuses.
De façon plus spécifique, il s'agira de :

1. Effectuer une revue des distributions *a priori* couramment utilisées pour les paramètres clés des modèles compartimentaux de maladies infectieuses ;
2. Développer un cadre méthodologique pour l'évaluation comparative des distributions *a priori*, intégrant des critères statistiques ;
3. Identifier les distributions *a priori* optimales pour chaque paramètre du modèle SIR par simulation Monte-Carlo et inférence bayésienne MCMC.

I.4 Hypothèse de l'étude

Les hypothèses de l'étude sont :
H1 : Les distributions *a priori* informatives correctement spécifiées présentent de meilleures performances d'estimation dans l'estimation des paramètres épidémiologiques ;
H2 : Les distributions *a priori* non informatives présentent des performances relativement équivalentes entre elles.

II.1 Principe de l'estimation bayésienne

II.1.1 Rappel de la théorie

L'approche fréquentiste, suppose que les données $(x_1, \ldots, x_n)$ sont des réalisations d'un vecteur de variables aléatoires $X = (X_1, \ldots, X_n)$, où chaque X_i est une variable aléatoire à valeurs dans $\mathbb{R}^d$. Ces variables sont supposées **indépendantes et identiquement distribuées** (i.i.d.), et leur loi dépend d'un paramètre θ appartenant à un espace de paramètres $\Theta \subset \mathbb{R}^p$ [13].

Dans l'approche fréquentiste, on suppose que la loi de X appartient au modèle, c'est-à-dire qu'il existe $\theta \in \Theta$ tel que X est de loi P_θ. L'inférence statistique consiste à chercher à estimer θ à partir d'une réalisation de la variable aléatoire X. Souvent, X consiste en un n-uplet $X = (X_1, \ldots, X_n)$. Dans ce cas, l'espace $(E, \mathcal{E})$ et le modèle $\mathcal{P}$ dépendent de n.

Les grandes questions dans le cadre fréquentiste sont :

1. **Estimation.** Il s'agit de construire un estimateur $\hat{\theta}(X)$ qui soit proche de la vraie valeur θ du paramètre θ. Typiquement, on souhaite souvent qu'un estimateur soit :
   - **convergent** : Un estimateur $\hat{\theta}_n$ de θ est dit convergent si
   $$\hat{\theta}_n \xrightarrow[n\to\infty]{\mathbb{P}} \theta;$$
   - **Sans Biais** : si
   $$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n\to\infty]{\mathcal{L}} \mathcal{N}(0, \Sigma);$$
   - **et que son risque quadratique tendant vers zéro** :
   $$\mathbb{E}_\theta\left[(\hat{\theta}_n - \theta)^2\right] = \mathcal{O}\left(\frac{1}{n}\right).$$
2. **Intervalles/régions de confiance.** On cherche à construire un sous-ensemble aléatoire $R(X)$ de Θ tel que $\theta_0 \in R(X)$ avec grande probabilité (sous P_θ).
3. **Tests.** On veut répondre par « vrai » ou « faux » à une propriété donnée de θ en construisant un test $\phi(X)$ à valeurs dans $\{0, 1\}$.

Lorsqu'on souhaite estimer une quantité d'intérêt $\hat{\theta_n}$ à partir de données observées $(x_1, \ldots, x_n)$, on utilise un modèle statistique qui formalise le lien entre les observations et le paramètre inconnu θ. Ce modèle repose sur l'hypothèse que les variables aléatoires $X = (X_1, \ldots, X_n)$ sont indépendantes et identiquement distribuées (i.i.d.) et que leur loi dépend d'un paramètre $\theta \in \Theta \subset \mathbb{R}^p$.

Sous certaines conditions, le meilleur estimateur est celui qui maximise la fonction de vraisemblance.

Soit un n-échantillon d'une variable aléatoire X. La fonction $f(x_1, x_2, \ldots, x_n; \theta)$ désigne la densité conjointe de $(X_1, X_2, \ldots, X_n)$.

On définit la fonction de vraisemblance par

$$L(x, \theta) = L(x_1, x_2, \ldots, x_n; \theta) = f(x_1, x_2, \ldots, x_n; \theta) \tag{II.1}$$

considérée comme une fonction de θ seul.

La fonction $L(x, \theta)$ est appelée *vraisemblance* de θ.

Si $(X_k)_{k \leq n}$ sont des variables continues i.i.d. dont la densité est f_θ, alors la fonction de vraisemblance est définie par :

$$L(\theta; x_1, \ldots, x_n) = \prod_{k=1}^{n} f_\theta(x_k) \tag{II.2}$$

Dans ce cadre, la valeur de L pour un ensemble donné d'observations $(x_1, \ldots, x_n)$ exprime la plausibilité de ces données sous le modèle paramétrique pour une valeur spécifique de θ. Cette fonction constitue la base de nombreuses méthodes d'estimation, comme l'estimation du maximum de vraisemblance, qui consiste à rechercher la valeur de θ qui maximise L.

II.1.2 Estimation bayésienne

L'analyse bayésienne repose sur l'idée que le paramètre inconnu θ est traité comme une variable aléatoire. L'espace des paramètres Θ est muni d'une loi de probabilité π, appelée *loi a priori*, qui reflète les connaissances initiales ou les incertitudes sur θ avant toute observation. On note alors $\theta \sim \pi$.

Dans ce cadre, les notions traditionnelles de probabilités ou densités paramétrées par θ, utilisées en approche fréquentiste, perdent leur pertinence. Elles sont remplacées par des probabilités conditionnelles, des indépendances et des densités conditionnelles à θ. Ainsi, la loi *a priori* π joue un rôle central en formalisant les informations disponibles avant l'observation des données. Lorsqu'on adopte strictement une perspective bayésienne.

Un *modèle bayésien* est défini, pour une variable aléatoire ou une suite de variables aléatoires, par :

— une loi conditionnelle $X \sim f(X \mid \theta)$,

— une loi a priori $\theta \sim \pi$.

Loi *a priori*

Soit $(f_\theta)_{\theta \in \Theta}$ une famille de densités de probabilité à paramètre dans Θ. Une *loi a priori* π est une loi de probabilité (ou densité de probabilité) définie sur Θ.

Fonction de densité

La loi jointe des observations $X = (X_1, \ldots, X_n)$ est exprimée conditionnellement au paramètre θ. Cette loi est représentée par $f(x \mid \theta) = f(x_1, \ldots, x_n \mid \theta)$.

Pour simplifier les notations, on peut utiliser $f(X \mid \theta)$ pour désigner la densité jointe de la variable aléatoire X dans le cas continu.

Loi *a posteriori*

L'objectif de l'inférence bayésienne est d'actualiser notre connaissance sur le paramètre θ en tenant compte des observations disponibles. Cette actualisation s'effectue par le passage de la loi *a priori* $\pi(\theta)$, qui représente notre connaissance initiale avant toute observation, à la loi *a posteriori* $\pi(\theta \mid X)$, qui représente notre connaissance mise à jour après avoir observé les données X.

La loi *a posteriori* combine ainsi l'information *a priori* sur le paramètre et l'information apportée par les données observées. Elle constitue le pilier central de l'analyse bayésienne, puisque toutes les inférences sur θ en découlent[7].

Le théorème de Bayes fournit le mécanisme formel de cette actualisation. Il établit que la loi *a posteriori* est proportionnelle au produit de la vraisemblance et de la loi a priori :

$$\pi(\theta \mid X) \propto L(X \mid \theta)\, \pi(\theta) \tag{II.3}$$

Formule de Bayes

Dans le contexte d'un modèle bayésien, où θ représente un paramètre inconnu et X les données observées, la formule devient :

$$\pi(\theta \mid X) = \frac{f(X \mid \theta)\pi(\theta)}{\int_\Theta f(X \mid u)\pi(u)\, du} \tag{II.4}$$

Où :

- $f(X \mid \theta)$ est la **vraisemblance**, représentant la probabilité ou densité des données conditionnellement au paramètre θ.
- $\pi(\theta)$ est la **loi *a priori***, qui décrit les connaissances initiales sur θ.
- $\pi(\theta \mid X)$ est la **loi *a posteriori***, qui incorpore les observations X pour actualiser la connaissance sur θ.
- $\int_\Theta f(X \mid u)\pi(u)\, du$ est un facteur de normalisation pour assurer que la densité $\pi(\theta \mid X)$ s'intègre à 1.

II.2 Mise en œuvre de l'estimation bayésienne

II.2.1 Les chaînes de Markov et les méthodes de Monte Carlo

Les chaînes de Markov

Une chaîne de Markov est une suite d'événements ou de situations (appelées *états*), notée $\{X_n\}_{n\geq 0}$, où ce qui se passe ensuite dépend uniquement de l'état actuel X_n, et pas de ce qui s'est passé avant $(X_{n-1}, X_{n-2}, \ldots, X_0)$ [14].

Cela signifie que :

$$P(X_n = j \,|\, X_{n-1} = i, X_{n-2}, \ldots, X_0) = P(X_n = j \,|\, X_{n-1} = i). \tag{II.5}$$

Si les règles pour passer d'un état i à un état j restent toujours les mêmes (indépendantes de n), la chaîne de Markov est dite **homogène**. Cela se traduit par :

$$P(X_n = j \mid X_{n-1} = i) = P(X_1 = j \mid X_0 = i) = p_{ij}. \tag{II.6}$$

Si on veut savoir la probabilité de passer d'un état i à un état j en k étapes, on utilise les **probabilités de transition en k étapes**, notées $p_{ij}^{(k)}$:

$$p_{ij}^{(k)} = P(X_k = j \mid X_0 = i). \tag{II.7}$$

Ces probabilités sont obtenues en multipliant la matrice de transition P par elle-même k fois :

$$P^{(k)} = P \times P \times \cdots \times P \quad \text{(k fois)}.$$

La méthode de Monte Carlo

Les méthodes de Monte-Carlo sont des techniques numériques basées sur l'échantillonnage aléatoire pour estimer des intégrales complexes. Le problème classique peut être formulé comme suit :

— Soit $h(x)$, une fonction définie sur $\mathbb{R}^m$, et $f(x)$, une densité de probabilité avec un support $X \subset \mathbb{R}^m$.

— L'objectif est de calculer l'espérance suivante :

$$I = \mathbb{E}_f[h(x)] = \int_{x \in X} h(x) f(x)\, dx. \tag{II.8}$$

Pour approcher cette valeur, on procède comme suit :

1. Générer n (n doit être très grand) variables aléatoires X_i ($i = 1, \ldots, n$) indépendantes et identiquement distribuées (i.i.d.) suivant la densité $f(x)$.
2. Estimer I à l'aide de la moyenne empirique :

$$\hat{h}_n = \frac{1}{n} \sum_{j=1}^{n} h(x_j). \tag{II.9}$$

Cette méthode permet d'estimer efficacement I, même lorsque l'intégrale ne peut pas être calculée analytiquement.

II.2.2 Les algorithmes MCMC

L'algorithme de Metropolis-Hastings

Les méthodes de Monte Carlo classiques, bien que puissantes, présentent certaines limitations pratiques, notamment lorsqu'il s'agit de simuler des distributions complexes. L'algorithme de Metropolis-Hastings est une méthode d'échantillonnage utilisée pour générer des échantillons à partir d'une distribution cible complexe, notamment dans le cadre de la statistique bayésienne ou des simulations Monte

Carlo [15].

Il a une particularité d'avoir une structure de mémoire markovienne car dans de nombreux problèmes pratiques, la distribution cible π est de grande dimension et n'a pas de forme analytique simple. Par exemple, dans le cadre bayésien, π est souvent une loi *a posteriori* obtenue via la formule de Bayes, qui n'est connue qu'à une constante près. Les méthodes classiques de simulation, comme l'inversion de la fonction de répartition, deviennent alors inapplicables [1].

Aussi, l'algorithme utilise une probabilité d'acceptation ρ pour décider si un nouvel état proposé doit être accepté ou rejeté. Contrairement à une approche binaire (tout ou rien), cette règle permet de conserver parfois l'état précédent, ce qui réduit les rejets inutiles et améliore le rendement de l'algorithme. Pour finir, sous certaines conditions d'irréductibilité et apériodicité, la chaîne de Markov construite par l'algorithme converge vers la distribution cible π. Cette propriété d'ergodicité garantit que, après un nombre suffisant d'itérations, les échantillons générés suivent bien la distribution souhaitée.

L'algorithme de Metropolis-Hastings repose sur trois idées clés :

1. **Distribution de proposition** : À chaque itération, un nouvel état t est proposé à partir d'une distribution de proposition $g(t \mid \theta_{r-1})$, qui dépend de l'état courant θ_{r-1}. Le choix de g est crucial pour l'efficacité de l'algorithme : une distribution bien adaptée permet d'explorer rapidement l'espace des états tout en minimisant les rejets.

2. **Probabilité d'acceptation** : La probabilité d'acceptation $\rho(\theta_{r-1}, t)$ est définie comme :

$$\rho(\theta_{r-1}, t) = \min\left(1, \frac{\pi(t) \cdot g(\theta_{r-1} \mid t)}{\pi(\theta_{r-1}) \cdot g(t \mid \theta_{r-1})}\right). \tag{II.10}$$

   Cette formule garantit que la chaîne de Markov converge vers la distribution cible π.

3. **Réversibilité et ergodicité** : Pour assurer la convergence, le noyau de transition de la chaîne doit être réversible par rapport à π. Cela signifie que la probabilité de passer de θ à θ' est égale à celle de passer de θ' à θ, pondérée par les densités $\pi(\theta)$ et $\pi(\theta')$. Sous des conditions d'irréductibilité et d'apériodicité, la chaîne devient ergodique, et la distribution des états converge vers π.

1. Voir ANNEXE I

Algorithme 1 Algorithme de Metropolis–Hastings

Choisir un point initial $\theta^{(0)}$
pour $r = 1$ à N **faire**
    Proposer un candidat $t \sim g(t \mid \theta^{(r-1)})$
    Calculer la probabilité d'acceptation :

$$\rho = \min\left(1, \frac{\pi(t)\, g(\theta^{(r-1)} \mid t)}{\pi(\theta^{(r-1)})\, g(t \mid \theta^{(r-1)})}\right)$$

    Tirer $u \sim \text{Uniform}(0, 1)$
    si $u < \rho$ **alors**
        Accepter la proposition : $\theta^{(r)} = t$
    sinon
        Rejeter la proposition : $\theta^{(r)} = \theta^{(r-1)}$
    fin si
fin pour

Cet algorithme génère une chaîne de Markov dont la distribution stationnaire est la distribution cible $\pi(\theta)$, permettant ainsi d'obtenir des échantillons asymptotiquement distribués selon cette loi même lorsqu'elle n'est pas normalisée.

L'échantillonnage de Gibbs

L'échantillonnage de Gibbs [7] est utilisé lorsque la variable à simuler, notée θ, est un vecteur de dimension finie. Contrairement à Metropolis-Hastings, cette méthode est plus restrictive, mais elle s'applique à la plupart des modèles statistiques pratiques. Pour fonctionner, elle nécessite de connaître les distributions conditionnelles de chaque composante de θ par rapport aux autres. Par exemple, si θ a deux composantes, il faut connaître $[\theta_1 \mid \theta_2]$ et $[\theta_2 \mid \theta_1]$.

Algorithme 2 Échantillonnage de Gibbs

Entrée : distributions conditionnelles $[\theta_1 \mid \theta_{-1}], \ldots, [\theta_d \mid \theta_{-d}]$, nombre d'itérations N
Sortie : échantillons $\{\theta^{(r)} = (\theta_1^{(r)}, \ldots, \theta_d^{(r)})\}_{r=1}^{N}$
Initialiser $\theta^{(0)} = (\theta_1^{(0)}, \ldots, \theta_d^{(0)})$ avec des valeurs arbitraires
pour $r = 0 \ldots N-1$ **faire**
    pour $i = 1 \ldots d$ **faire**
        Simuler $\theta_i^{(r+1)} \sim [\theta_i \mid \theta_1^{(r+1)}, \ldots, \theta_{i-1}^{(r+1)}, \theta_{i+1}^{(r)}, \ldots, \theta_d^{(r)}]$
    fin pour
fin pour

La séquence des couples (θ_1, θ_2) ainsi générés forme une chaîne de Markov, qui converge vers la

distribution cible.

Algorithme Hamiltonian Monte Carlo (HMC)

Le *Hamiltonian Monte Carlo* (HMC) [16] alterne des mises à jour simples pour les variables de momentum avec des mises à jour de type Metropolis dans lesquelles un nouvel état est proposé en calculant une trajectoire selon la dynamique hamiltonienne, implémentée avec la méthode du saute-mouton (*leapfrog*). L'algorithme HMC commence à un ensemble initial de paramètres θ spécifié, puis pour un nombre donné d'itérations, un nouveau vecteur de momentum est échantillonné et la valeur actuelle du paramètre θ est mise à jour en utilisant l'intégrateur leapfrog avec un temps de discrétisation ε et un nombre de pas L selon la dynamique hamiltonienne, suivi d'une étape d'acceptation de Metropolis.

HMC utilise la dynamique hamiltonienne pour produire des propositions distantes pour l'algorithme de Metropolis, évitant ainsi l'exploration lente de l'espace d'état qui résulte du comportement diffusif des propositions simples de marche aléatoire. La méthode repose sur l'introduction de variables de « momentum » fictives qui, combinées avec les paramètres d'intérêt (les variables de « position »), définissent un hamiltonien $H(\theta, \rho) = T(\rho) + V(\theta)$, où T représente l'énergie cinétique et V l'énergie potentielle (égale au logarithme négatif de la densité a posteriori).

Algorithme 3 Hamiltonian Monte Carlo (HMC)

Nécessite État initial $\theta^{(0)}$, nombre d'itérations N, pas ε, nombre de pas leapfrog L, distribution cible $\pi(\theta)$, matrice de masse M (souvent $M = I$)

Assurer Échantillons $\{\theta^{(t)}\}_{t=1}^{N}$

pour $t = 1$ **to** N **faire**
  Échantillonner le momentum : $\rho^{(t)} \sim \mathcal{N}(0, M)$
  Initialiser : $\tilde{\theta} \leftarrow \theta^{(t-1)}, \quad \tilde{\rho} \leftarrow \rho^{(t)}$
  Intégration leapfrog :
  pour $i = 1$ **to** L **faire**
    Demi-pas pour le momentum : $\tilde{\rho} \leftarrow \tilde{\rho} + \frac{\varepsilon}{2}\nabla_\theta \log \pi(\tilde{\theta})$
    Pas complet pour la position : $\tilde{\theta} \leftarrow \tilde{\theta} + \varepsilon M^{-1}\tilde{\rho}$
    Demi-pas pour le momentum : $\tilde{\rho} \leftarrow \tilde{\rho} + \frac{\varepsilon}{2}\nabla_\theta \log \pi(\tilde{\theta})$
  fin pour
  Inverser le momentum : $\tilde{\rho} \leftarrow -\tilde{\rho}$
  Calculer l'Hamiltonien :

$$H_{\text{actuel}} = -\log \pi(\theta^{(t-1)}) + \frac{1}{2}(\rho^{(t)})^\top M^{-1}\rho^{(t)}$$

$$H_{\text{proposé}} = -\log \pi(\tilde{\theta}) + \frac{1}{2}\tilde{\rho}^\top M^{-1}\tilde{\rho}$$

  Étape d'acceptation Metropolis-Hastings :

$$\alpha = \min\left(1, \exp(H_{\text{actuel}} - H_{\text{proposé}})\right)$$

  Échantillonner $u \sim \text{Uniforme}(0, 1)$
  si $u < \alpha$ **alors**
    $\theta^{(t)} \leftarrow \tilde{\theta}$ ▷ accepter
  sinon
    $\theta^{(t)} \leftarrow \theta^{(t-1)}$ ▷ rejeter
  fin si
fin pour

Algorithme No-U-Turn Sampler (NUTS)

Le *No-U-Turn Sampler* (NUTS) est une extension de HMC qui élimine le besoin de spécifier un nombre de pas L [17]. NUTS utilise un algorithme récursif pour construire un ensemble de points candidats probables qui couvre une large étendue de la distribution cible, s'arrêtant automatiquement lorsqu'il commence à faire demi-tour et retracer ses pas. L'algorithme stoppe automatiquement lorsqu'il observe un demi-tour du chemin revenant sur lui-même.

Si L est trop petit, l'algorithme HMC standard présente un comportement de marche aléatoire indésirable, tandis que si L est trop grand, l'algorithme gaspille du temps de calcul. NUTS résout ce problème en adaptant automatiquement la longueur de trajectoire. NUTS dérive également une méthode pour adapter le paramètre de taille de pas ε à la volée basée sur une moyenne primale-duale, permettant ainsi d'utiliser NUTS sans aucun réglage manuel.

Pour garantir la réversibilité, le chemin est étendu à la fois vers l'avant et vers l'arrière dans le temps virtuel. De plus, au lieu d'un seul choix accepter/rejeter, l'algorithme échantillonne le point suivant parmi l'ensemble des candidats générés le long du chemin.

Algorithme 4 No-U-Turn Sampler (NUTS)

Nécessite état initial $\theta^{(0)}$, nombre d'itérations N, pas ϵ, matrice de masse M

Assurer échantillons $\{\theta^{(t)}\}_{t=1}^{N}$

pour $t = 1$ to N **faire**
  Échantillonner le momentum : $\rho^{(0)} \sim \mathcal{N}(0, M)$
  Initialiser : $u \sim \text{Uniform}(0, \exp(-H(\theta^{(t-1)}, \rho^{(0)})))$
  $\theta_- \leftarrow \theta_+ \leftarrow \theta^{(t-1)}$
  $\rho_- \leftarrow \rho_+ \leftarrow \rho^{(0)}$
  $j \leftarrow 0$, $n \leftarrow 1$, $s \leftarrow 1$
  tant que $s = 1$ **faire**
    Échantillonner direction : $v \sim \text{Uniform}(\{-1, +1\})$
    si $v = -1$ **alors**
      $(\theta_-, \rho_-, \cdot, \cdot, \theta', n', s') \leftarrow \text{BuildTree}(\theta_-, \rho_-, u, v, j, \epsilon)$
    sinon
      $(\cdot, \cdot, \theta_+, \rho_+, \theta', n', s') \leftarrow \text{BuildTree}(\theta_+, \rho_+, u, v, j, \epsilon)$
    fin si
    si $s' = 1$ **alors**
      Avec probabilité $\min(1, n'/n)$, définir $\theta^{(t)} \leftarrow \theta'$
    fin si
    $n \leftarrow n + n'$
    $s \leftarrow s' \cdot \mathbb{1}[(\theta_+ - \theta_-) \cdot \rho_- \geq 0] \cdot \mathbb{1}[(\theta_+ - \theta_-) \cdot \rho_+ \geq 0]$
    $j \leftarrow j + 1$
  fin tant que
  Mettre à jour $\epsilon^{(t+1)}$ selon la méthode d'adaptation duale (warm-up)
fin pour

II.2.3 Les solutions logicielles

L'inférence bayésienne nécessite des outils spécialisés pour implémenter des modèles complexes et effectuer des simulations. Plusieurs logiciels et bibliothèques ont été développés pour faciliter ce processus. Dans cette section, nous présentons quelques solutions logiciels :

1. L'interface **WinBUGS** permet aux utilisateurs de définir leur modèle statistique dans un langage appelé langage BUGS [18], puis exécutent des algorithmes MCMC en boîte. WinBUGS utilise essentiellement des algorithmes de type Gibbs sampling et Metropolis–Hastings. noire.
2. **JAGS** est un logiciel pour l'analyse bayésienne basé sur l'échantillonnage de Gibbs [18]. Il est similaire à BUGS, mais plus léger et multiplateforme. Il est souvent utilisé via l'interface R (`rjags`) et utilise essentiellement des algorithmes de type Gibbs sampling et Metropolis–Hastings.
3. **Stan** est un logiciel puissant pour l'inférence bayésienne, utilisant un langage de modélisation probabiliste. Il est compatible avec R, Python, Julia et d'autres langages [19]. Stan utilise l'agorithme Hamiltonian Monte Carlo et le No-U-Turn Sampler.
4. **TensorFlow Probability et PyMC3** sont des bibliothèques Python pour l'inférence probabiliste et l'apprentissage bayésien. Ils sont idéal pour les modèles hiérarchiques et les données complexes. Ils utilisent l'agorithme Hamiltonian Monte Carlo et le No-U-Turn Sampler.

II.3 Détermination de la loi *a priori*

La distribution *a priori* joue un rôle essentiel dans l'inférence bayésienne. Elle incarne les connaissances ou les croyances initiales concernant un paramètre inconnu Θ. Ces informations *a priori* sont ensuite fusionnées avec les données observées, via leur distribution de probabilité, pour former la distribution *a posteriori* [8].

II.3.1 Lois *a priori* informatives

Les lois *a priori* informatives intègrent explicitement des connaissances préalables sur le paramètre θ, issues de la littérature, d'études antérieures ou de l'expertise du domaine. Contrairement aux lois subjectives basées principalement sur des jugements individuels, les lois informatives reposent sur des informations quantitatives déjà établies. Elles permettent ainsi de concentrer la masse de probabilité autour d'une valeur jugée plausible et de contrôler l'incertitude au moyen d'hyperparamètres soigneusement choisis.

II.3.2 Ellicitation Subjective

Les lois *à priori* subjectives sont déterminées dans plusieurs scenarios. La détermination subjective des probabilités des valeurs de θ peut être basée sur les expériences antérieures, des intuitions

des statisticiens. Cependant, lorsque l'espace des paramètres Θ n'est pas dénombrable, une première approche pour déterminer π est le partitionnement de Θ en des ensembles et la probabilité de chaque ensemble $\pi(\theta)$ est approchée par un histogramme. Une autre approche est d'évaluer les vraisemblances des éléments significatifs de Θ tout en construisant une courbe de vraisemblance proportionnelle a π. [20] Dans les 2 cas, lorsque omega n'est pas bornée il y'a nécessité de construire des queues de distribution ce qui rend la détermination subjective difficile.
Lorsque nous ne disposons d'aucune information directe sur θ, une alternative est de recourir à la distribution marginale de x,

$$m(x) = \int_{\Theta} f(x \mid \theta)\pi(\theta)\, d\theta \tag{II.11}$$

II.3.3 Lois conjuguées

Lorsque l'information *a priori* est floue, peu fiable, ou absente, il est difficile de construire une loi *a priori* subjective. Dans ces situations, il est préférable d'utiliser des lois *a priori* dites « objectives », construites à partir du modèle d'échantillonnage $f(x \mid \theta)$.

Définition 1 : Une famille $\mathcal{F}$ de distributions de probabilité sur Θ est dite conjuguée (ou fermée par échantillonnage) pour une fonction de vraisemblance $f(x \mid \theta)$ si, pour tout $\pi \in \mathcal{F}$, la distribution a posteriori $\pi(\cdot \mid x)$ appartient également à $\mathcal{F}$ [20].

L'idée des lois *a priori* conjuguées repose sur un principe d'invariance. Lorsqu'on observe des données x issues de $f(x \mid \theta)$, ces données n'apportent qu'une quantité limitée d'information sur θ. Plutôt que de transformer radicalement la distribution *a priori* $\pi(\theta)$, cette information devrait simplement ajuster ses paramètres pour obtenir la distribution *a posteriori* $\pi(\theta \mid x)$.

Dans cette section nous présentons les lois *a priori* conjuguées des familles exponentielles.

Définition 2 : Soient μ une mesure σ-finie sur $\mathcal{X}$, Θ l'espace des paramètres, C et h des fonctions respectivement de $\mathcal{X}$ et Θ dans $\mathbb{R}_+$, et R et T des fonctions de Θ et $\mathcal{X}$ dans $\mathbb{R}^k$ [20]. La famille des distributions de densité (par rapport à μ)

$$f(x \mid \theta) = C(\theta)h(x)\exp\{R(\theta)\cdot T(x)\} \tag{II.12}$$

$f(x \mid \theta) = C(\theta)h(x)\exp\{R(\theta)\cdot T(x)\}$ alors $\pi(\theta) = c(\theta)\exp\{k\cdot R(\theta)\}$ est dite *famille exponentielle de dimension* k.

Dans le cas particulier où $\Theta \subset \mathbb{R}^k$, $\mathcal{X} \subset \mathbb{R}^k$ et

$$f(x \mid \theta) = C(\theta)h(x)\exp\{\theta\cdot x\} \tag{II.13}$$

la famille est dite *naturelle*.

Proposition 1 : Une famille conjuguée pour $f(x \mid \theta)$ est donnée par

$$\pi(\theta \mid \mu, \lambda) = K(\mu, \lambda)\, e^{\theta \cdot \mu - \lambda \psi(\theta)} \tag{II.14}$$

où $K(\mu, \lambda)$ est la constante de normalisation de la densité. La loi a posteriori correspondante est $\pi(\theta \mid \mu + x, \lambda + 1)$.

Exemple 1 :

Soit une variable aléatoire X suivant une loi de Bernoulli de paramètre inconnu θ :

$$X \mid \theta \sim \text{Bernoulli}(\theta), \quad \theta \in [0, 1].$$

On dispose d'une connaissance *à priori* sur θ sous la forme d'une loi Beta :

$$\theta \sim \text{Beta}(\alpha, \beta), \quad \alpha, \beta > 0.$$

1. Déterminer la loi *a posteriori* de θ après l'observation d'un seul tirage $X = x$.
2. Vérifier que la loi *a posteriori* appartient à la même famille que la loi *a priori* (Beta).

Remarque : Cet exemple illustre le principe des lois *a priori* conjuguées et montre comment l'information apportée par les données ajuste simplement les paramètres de la loi *a priori*.

La vraisemblance du modèle est :

$$f(x \mid \theta) = \theta^x (1 - \theta)^{1-x}.$$

La loi *a priori* est :

$$\pi(\theta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha - 1} (1 - \theta)^{\beta - 1},$$

où $B(\alpha, \beta)$ est la fonction Beta.

D'après le théorème de Bayes, la loi *a posteriori* est proportionnelle au produit de la vraisemblance et de la loi *a priori* :

$$\pi(\theta \mid x) \propto f(x \mid \theta)\pi(\theta) = \theta^x (1 - \theta)^{1-x} \cdot \theta^{\alpha - 1} (1 - \theta)^{\beta - 1} = \theta^{\alpha + x - 1} (1 - \theta)^{\beta + 1 - x - 1}.$$

On reconnaît la forme d'une loi Beta, donc :

$$\theta \mid x \sim \text{Beta}(\alpha + x, \beta + 1 - x).$$

Illustration numérique :

- *A priori* : $\alpha = 2, \beta = 3$ - Observation : $x = 1$

Alors :

$$\theta \mid x = 1 \sim \text{Beta}(3; 3).$$

La loi *a posteriori* appartient bien à la même famille que la loi *a priori*, ce qui illustre la conjugaison.

TABLE 1 – Lois *a priori* conjuguées naturelles pour quelques familles exponentielles usuelles.

Famille $f(x \mid \theta)$	Paramètre	**Loi a priori** $\pi(\theta)$	**Loi a posteriori** $\pi(\theta \mid x)$
Normale $\mathcal{N}(\theta, \sigma^2)$	θ	Normale $\mathcal{N}(\mu, \tau^2)$	$\mathcal{N}\left(\frac{\sigma^2\mu+\tau^2 x}{\sigma^2+\tau^2}, \frac{\sigma^2\tau^2}{\sigma^2+\tau^2}\right)$
Poisson $\mathcal{P}(\theta)$	θ	Gamma $\mathcal{G}(\alpha, \beta)$	Gamma $\mathcal{G}(\alpha + x, \beta + 1)$
Gamma $\mathcal{G}(\nu, \theta)$	θ	Gamma $\mathcal{G}(\alpha, \beta)$	Gamma $\mathcal{G}(\alpha + \nu, \beta + x)$
Binomiale $\mathcal{B}(n, \theta)$	θ	Bêta Be(α, β)	Bêta Be$(\alpha + x, \beta + n - x)$
Binomiale Négative $\mathcal{NB}(m, \theta)$	θ	Bêta Be(α, β)	Bêta Be$(\alpha + m, \beta + x)$
Multinomiale $\mathcal{M}_k(\theta_1, \ldots, \theta_k)$	$\theta = (\theta_1, ..., \theta_k)$	Dirichlet $\mathcal{D}(\alpha_1, \ldots, \alpha_k)$	Dirichlet $\mathcal{D}(\alpha_1 + x_1, \ldots, \alpha_k + x_k)$
Normale $\mathcal{N}(\mu, 1/\theta)$	$\theta = 1/\sigma^2$	Gamma $\mathcal{G}(\alpha, \beta)$	Gamma $\mathcal{G}\left(\alpha + 0.5, \beta + \frac{(\mu-x)^2}{2}\right)$

II.3.4 Lois non informative

Quand aucune connaissance préalable n'est disponible, ces lois servent de point de départ neutre. Elles se construisent uniquement à partir de la structure des données, évitant de biaiser les résultats par des hypothèses subjectives.
Nous aborderons les lois de laplace, de jeffrey et les lois de references tout en sachant bien qu'il ya les lois coïncidantes qui visent à trouver une loi *a priori* telle que les intervalles de crédibilité bayésiens aient une couverture fréquentiste approximativement égale au niveau de confiance nominal.

Lois *a priori* de Laplace

Laplace fut le premier à utiliser des lois *non informatives* dans des problèmes comme l'estimation de boules blanches dans une urne et le calcul de la proportion de naissances masculines. il munit ces paramètres d'une loi *a priori* qui prend en compte son ignorance en donnant la même vraisemblance à chaque valeur du paramètre, soit donc en utilisant une loi uniforme

Sa méthode, le **principe de raison insuffisante**, postule :

$$\pi(\theta) = \text{constante} \quad \forall \theta \in \Theta \tag{II.15}$$

Fondé sur l'**équiprobabilité** des événements élémentaires.
Les principales critiques étaient :

1. **Impropreté des lois** : Les lois uniformes peuvent être non intégrables sur des espaces infinis, rendant leur utilisation problématique en pratique.
2. **Incohérence de partitionnement** : Le choix d'une loi uniforme dépend de la manière dont l'espace des paramètres est partitionné, ce qui peut conduire à des résultats contradictoires selon

la partition choisie.

3. **Non-invariance reparamétrique** : Une loi uniforme sur un paramètre ne reste pas uniforme après une transformation non linéaire, ce qui rend le choix du paramétrage crucial et arbitraire.

Exemple 2 : Prior de Laplace avec vraisemblance Poisson

Problème : estimation d'un taux d'événement On cherche à estimer le taux moyen d'incidents par unité de temps, noté θ (par exemple, le nombre de maladies par semaine). Le paramètre est défini sur $\Theta = [0, \infty[$.

1. Spécification du prior de Laplace En absence d'information préalable, on adopte le principe de raison insuffisante de Laplace, supposant que toutes les valeurs de θ sont équiprobables. On choisit donc un prior uniforme impropre sur $[0, \infty[$:

$$\pi(\theta) \propto 1, \quad \theta \geq 0.$$

2. Modèle de vraisemblance Supposons qu'on observe x événements au cours de la période considérée. La vraisemblance suit une loi de Poisson :

$$f(x|\theta) = \frac{\theta^x e^{-\theta}}{x!}.$$

3. Loi *a posteriori* via Bayes La loi *a posteriori* est donnée par :

$$\pi(\theta|x) \propto f(x|\theta)\pi(\theta).$$

Avec le prior uniforme, cela devient :

$$\pi(\theta|x) \propto \theta^x e^{-\theta}.$$

4. Identification de la loi *a posteriori* On reconnaît une loi Gamma :

$$\theta|x \sim \text{Gamma}(\text{shape} = x + 1, \text{rate} = 1),$$

dont la densité est

$$\pi(\theta|x) = \frac{1}{\Gamma(x+1)} \theta^x e^{-\theta}, \quad \theta > 0.$$

5. Exemple numérique Si l'on observe $x = 4$ incidents :

$$\theta|x \sim \text{Gamma}(5; 1),$$

avec moyenne a posteriori $E[\theta|x] = 5$ et variance $\text{Var}[\theta|x] = 5$.

Le prior uniforme (Laplace) reflète l'ignorance initiale.

La vraisemblance Poisson incorpore les données observées.

La loi *a posteriori* est Gamma, dont les paramètres dépendent directement de l'observation x.

Lois *a priori* de Jeffrey

Jeffreys propose une approche intrinsèque qui évite effectivement le besoin de prendre en compte une structure d'invariance potentielle, tout en étant souvent compatible lorsque cette structure existe.

Les lois *a priori* non informatives de Jeffreys sont fondées sur l'*information de Fisher*, donnée par :

$$I(\theta) = \mathbb{E}_\theta \left[\left(\frac{\partial \log f(X|\theta)}{\partial \theta} \right)^2 \right] \tag{II.16}$$

Sous certaines conditions de régularité, cette information est aussi égale à :

$$I(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2 \log f(X|\theta)}{\partial \theta^2} \right] \tag{II.17}$$

La loi *a priori* de Jeffreys s'écrit :

$$\pi^*(\theta) \propto I^{1/2}(\theta) \tag{II.18}$$

Propriétés clés :

— **Invariance reparamétrique** : Pour une transformation bijective $h(\theta)$:

$$I(\theta) = I(h(\theta))(h'(\theta))^2 \tag{II.19}$$

Le Jacobien $h'(\theta)$ assure que la loi reste cohérente après changement de variable.

Lois de Référence

Les lois de référence, introduites par Bernardo (1979) et développées par Berger et Bernardo, sont une généralisation des lois de Jeffreys pour les modèles à paramètres multiples, distinguant paramètres d'intérêt θ_1 et paramètres de nuisance θ_2. L'objectif est de construire une loi *a priori* non informative qui respecte la structure du modèle, gère les paramètres de nuisance de manière cohérente et invariante sous reparamétrisation. Les limites de cette loi sont la complexité calculatoire (intégration), la dépendance au choix de θ_1 et la difficulté pour les modèles non réguliers.

Construction des lois de référence

Étape 1 : Prior conditionnel pour le paramètre de nuisance ($\theta_2|\theta_1$)

Pour θ_1 fixé, calculer la loi de Jeffreys pour θ_2 :

$$\pi(\theta_2|\theta_1) \propto \sqrt{I_{22}(\theta_1, \theta_2)}, \tag{II.20}$$

où I_{22} est le bloc de la matrice d'information de Fisher associé à θ_2.

Étape 2 : Prior marginal pour le paramètre d'intérêt (θ_1)

Marginaliser θ_2 pour obtenir une vraisemblance intégrée :

$$\tilde{f}(x|\theta_1) = \int f(x|\theta_1, \theta_2)\pi(\theta_2|\theta_1)\, d\theta_2. \tag{II.21}$$

Appliquer la loi de Jeffreys sur cette vraisemblance marginale :

$$\pi(\theta_1) \propto \sqrt{I_{\tilde{f}}(\theta_1)}, \tag{II.22}$$

où $I_{\tilde{f}}(\theta_1)$ est l'information de Fisher de $\tilde{f}(x|\theta_1)$.

Prior joint de référence

$$\pi_{\text{ref}}(\theta_1, \theta_2) = \pi(\theta_1) \cdot \pi(\theta_2|\theta_1). \tag{II.23}$$

Exemple 3 : Loi de référence pour un modèle Poisson avec paramètre de nuisance

Problème : Supposons qu'on observe des événements $x = (x_1, x_2, \ldots, x_n)$ provenant d'une loi Poisson de moyenne $\lambda\theta$, où :

— $\theta > 0$ est le paramètre d'intérêt (taux d'événement standardisé),

— $\lambda > 0$ est un paramètre de nuisance connu ou estimé.

1. Prior conditionnel pour le paramètre de nuisance Si λ était inconnu, pour un θ fixé, on calculerait la loi de Jeffreys pour λ :

$$\pi(\lambda|\theta) \propto \sqrt{I_{\lambda\lambda}(\theta, \lambda)},$$

où $I_{\lambda\lambda}$ est le bloc correspondant de la matrice d'information de Fisher pour λ.

2. Prior marginal pour le paramètre d'intérêt On marginalise λ dans la vraisemblance :

$$\tilde{f}(x|\theta) = \int f(x|\theta, \lambda)\pi(\lambda|\theta)d\lambda.$$

Puis on applique la loi de Jeffreys sur la vraisemblance marginale :

$$\pi(\theta) \propto \sqrt{I_{\tilde{f}}(\theta)},$$

où $I_{\tilde{f}}(\theta)$ est l'information de Fisher de la vraisemblance intégrée.

3. Prior joint de référence La loi de référence conjointe est donnée par :

$$\pi_{\text{ref}}(\theta, \lambda) = \pi(\theta) \cdot \pi(\lambda|\theta).$$

4. Interprétation Cette construction garantit :

— que le prior est non-informatif pour le paramètre d'intérêt θ,

— que le paramètre de nuisance λ est traité de manière cohérente avec la structure du modèle,

— et que la loi est invariante par reparamétrisation.

Remarque : Pour un modèle simple Poisson à paramètre unique (λ connu), la loi de référence coïncide avec la loi de Jeffreys classique :

$$\pi(\theta) \propto \theta^{-1/2}.$$

III.1 Présentation des modèles

La distribution *a priori* est un élément essentiel de l'approche bayésienne. Elle reflète les connaissances ou hypothèses initiales sur un paramètre incertain. Ces informations sont ensuite combinées avec les données nouvellement disponibles pour obtenir la distribution *a posteriori*, qui est utilisée pour tirer des conclusions et prendre des décisions futures [8].

Somda et al. [21] proposent une modélisation bayésienne de l'épidémie de COVID-19 au Burkina Faso en utilisant un modèle SIR (*Susceptible-Infectieux-Retiré*) pour estimer et prédire la propagation du virus. Ils intègrent un modificateur de transmission pour tenir compte des mesures de santé publique mises en place. Les lois *a priori* utilisées sont faiblement informatives et incluent des distributions Beta pour les proportions initiales d'infectés ($\theta_0^I \sim \text{Beta}(1; (Y_1^I)^{-1})$) et de susceptibles ($\theta_0^S \sim \text{Beta}(1; (Y_2^S)^{-1})$), ainsi que des distributions Gamma pour les paramètres de variance ($\lambda^I \sim \text{Gamma}(2; 0,0001)$, $\lambda^R \sim \text{Gamma}(2; 0,0001)$) et d'échelle ($k \sim \text{Gamma}(2; 0,0001)$).

Bettencourt et al. [22] proposent une modélisation bayésienne en temps réel pour évaluer le potentiel épidémique des maladies émergentes, comme la grippe aviaire H5N1, à l'aide d'un modèle SIR modifié. Ce modèle intègre les transmissions humaines et les infections provenant d'un réservoir animal. Une distribution uniforme $[0; 3]$ est utilisée comme loi *a priori* pour R, mise à jour itérativement avec les données observées.

Weidemann et al. [23] développent une approche bayésienne pour l'inférence des paramètres d'un modèle de transmission du rotavirus en Allemagne, basé sur un modèle compartimental de type SIS (Susceptible-Infectieux-Susceptible) avec équations différentielles ordinaires. Afin d'estimer les paramètres clés du modèle, ils utilisent des distributions *à priori* adaptées, notamment des *Skewed Normal* (SN) pour permettre une meilleure prise en compte de l'asymétrie des paramètres biologiques et épidémiologiques . Les paramètres contraints à des valeurs strictement positives sont transformés via une log-transformation, tandis que ceux devant rester dans l'intervalle $[0; 1]$ (ex. taux de détection, infectiosité relative) sont modélisés avec une transformation logit. Certains paramètres sont associés à des lois *a priori* faiblement informatives, notamment l'infectiosité relative des symptomatiques $p \sim SN(0; 1,12; 0)$, les taux de contact $c_i \sim SN(0; 0,82; 0)$, l'amplitude saisonnière $a_1, a_2 \sim SN(0; 1,02; 0)$, la phase saisonnière $b_1, b_2 \sim SN(0; 1,87; 0)$, l'augmentation relative du taux de détection $q^{(e)}, q^{(w)} \sim SN(0; 0,36; 0)$ et le paramètre de dispersion des observations $d \sim SN(-0,01; 0,82; 0)$.

Gelman et al. [24] proposent une distribution *a priori* faiblement informative pour la régression logistique et d'autres modèles de régression généralisée, visant à améliorer la stabilité des estimations, notamment en cas de séparation complète. Ils recommandent l'utilisation d'une distribution Student-t

avec $\nu = 1$, équivalente à une Cauchy$(0; 2, 5)$ pour les coefficients des variables explicatives et une Cauchy$(0; 10)$ pour l'intercept. Cette distribution permet de limiter les valeurs extrêmes tout en assurant une certaine flexibilité. Contrairement à l'*a priori* normal souvent utilisé, la Cauchy permet de modéliser des effets plus importants sans imposer une pénalisation excessive.

Didelot et al. [25] proposent une approche bayésienne pour inférer les événements de transmission des maladies infectieuses à partir des données de séquençage du génome complet, en intégrant un modèle épidémiologique et un modèle de diversification génétique. L'épidémie est modélisée comme un processus *SIR* en temps continu, où le taux d'infection β et le taux de retrait γ suivent des lois exponentielles $\beta \sim \text{Exp}(1)$ et $\gamma \sim \text{Exp}(1)$, garantissant une faible informativité tout en limitant les valeurs extrêmes. La diversité intra-hôte est capturée via un modèle coalescent neutre avec une taille de population effective $N_e \sim \text{Exp}(1)$, permettant une modélisation flexible des relations phylogénétiques entre les souches. Le temps de divergence T entre lignées suit une loi uniforme $T \sim \text{Unif}(0; t_{\max})$, où $t_{\max}$ est fixé en fonction de la durée totale de l'épidémie observée, évitant ainsi d'imposer une contrainte temporelle forte sur les événements de transmission. Le taux de mutation μ du pathogène est modélisé par une loi log-normale $\mu \sim \text{LogNormal}(\mu_0; \sigma^2)$, reflétant la variabilité biologique et évolutive des séquences génétiques.

McKinley et al. [26] proposent une approche bayésienne basée sur des méthodes pseudo-marginales et de Monte Carlo par chaînes de Markov (MCMC) pour l'inférence des modèles épidémiologiques à partir de données incomplètes. L'épidémie est modélisée par un processus stochastique en temps continu de type SIR ou SEIR, où les taux de transmission β et de récupération γ peuvent suivre différentes distributions a priori selon le niveau d'informativité souhaité. Dans le cadre d'une approche non informative, β et γ sont modélisés par des lois uniformes $\beta \sim \mathcal{U}(0; \infty)$ et $\gamma \sim \mathcal{U}(0; \infty)$, permettant une exploration sans contrainte des valeurs possibles. Alternativement, une loi Gamma avec une grande variance $\beta, \gamma \sim G(\epsilon; \epsilon^{-1})$, où $\epsilon \approx 10^{-4}$, est utilisée pour garantir une faible informativité tout en maintenant une distribution définie. Le temps entre la première infection et le premier retrait suit une loi exponentielle $\theta \sim Exp(\lambda)$ avec un paramètre λ très faible, autorisant une large gamme de valeurs initiales.

Li et al. [27] proposent une approche bayésienne efficace pour l'inférence des modèles épidémiologiques stochastiques en temps continu, en utilisant une approximation basée sur le théorème central limite fonctionnel pour accélérer le calcul des vraisemblances. L'épidémie est modélisée par un processus markovien compartimental de type SEIR étendu, incluant plusieurs stades infectieux (E, A, I_1, I_2, I_3) et une stratification en 16 classes d'âge. Les taux de transmission β_i suivent une loi log-normale $\beta_i \sim \log N(\mu = 0,2, \sigma = 0,1)$, permettant de capturer une incertitude asymétrique tout en assurant des valeurs strictement positives. Les taux de transition entre compartiments $\gamma_E, \gamma_A, \gamma_1, \gamma_2, \gamma_3$ sont modélisés par une loi normale tronquée $N(\mu; \sigma^2)$, avec des valeurs moyennes comprises entre $(3 \text{ jours})^{-1}$ et $(7.25 \text{ jours})^{-1}$ et un écart-type fixé à 10 % de la moyenne pour éviter les valeurs extrêmes. Les valeurs

initiales des compartiments S_0, E_0, I_0 suivent une loi normale large avec un écart-type égal à $1/3$ de la moyenne estimée, tandis que les paramètres liés aux mesures de contrôle (ex. confinement) t_{lock}, W_{lock} sont modélisés par une loi normale $N(\mu = 17 \text{ jours}, \sigma = 1 \text{ jour})$ et $N(\mu = 12 \text{ jours}, \sigma = 1 \text{ jour})$. L'infectiosité tardive ν_L suit une loi log-normale avec $\mu = 0,1$ et $\sigma = 0,05$, permettant de refléter les incertitudes sur la transmission des cas sévères.

Golightly et al. [28] proposent une approche bayésienne basée sur l'approximation du bruit linéaire (LNA) et des méthodes pseudo-marginales pour l'inférence des modèles épidémiologiques stochastiques à partir de données d'incidence. L'épidémie est modélisée par un processus SIR ou SIRS avec un taux d'infection β pouvant varier dans le temps selon un processus stochastique. Les distributions *a priori* des paramètres sont choisies selon leur niveau d'informativité : une approche non informative est adoptée pour certains paramètres, comme le taux de report $\lambda \sim U(0;1)$ et le paramètre de retour à l'état sensible $\log \kappa \sim N(0;1)$, permettant une exploration sans contrainte des valeurs possibles. Une faible informativité est également garantie pour le taux de récupération $\gamma \sim \log N(0;0,5^2)$ et l'écart-type du bruit brownien $\sigma_\beta \sim \log N(1;1)$, offrant une flexibilité dans la dynamique d'infection. L'observation suit une loi binomiale ou binomiale négative, avec un paramètre de dispersion $\phi \sim \log N(0;1)$, assurant une prise en compte de la sous-détection et de la surdispersion.

Cassidy et al. [29] développent une approche bayésienne pour l'inférence et l'évaluation de modèles de transmission des pathogènes nosocomiaux en intégrant des données de séquençage génomique complet. L'épidémie est modélisée par un processus SIR stochastique, où la dynamique de transmission est influencée par la structure hospitalière et les distances génétiques entre isolats. L'inférence est réalisée via une approche de Monte Carlo par Chaînes de Markov (MCMC) avec augmentation de données pour estimer les paramètres épidémiologiques et génétiques. Les distributions *a priori* sont choisies de manière flexible : une loi Bêta est utilisée pour la probabilité d'être colonisé à l'admission $p \sim \text{Beta}(\alpha;\beta)$ et la sensibilité des tests $z \sim \text{Beta}(\alpha';\beta')$, tandis que le taux de transmission β et le paramètre de dépendance génétique γ suivent des lois uniformes impropres $\beta, \gamma \sim U(0;\infty)$. Les paramètres de distance génétique $\theta, \theta_I, \theta_G$ sont modélisés par des lois Gamma $\theta \sim \text{Gamma}(a;b)$, capturant la variabilité des mutations entre souches.

III.2 Étude des distributions *a priori*

III.2.1 Modélisation Bayésienne

Cherchons à modéliser la meilleure distribution *a priori* pour les paramètres du modèle SIR afin d'obtenir des estimations fiables et cohérentes avec les données épidémiologiques. Dans cette étude, nous utilisons une approche stochastique basée sur un processus de Poisson pour modéliser la dynamique de transmission. Cette approche permet de représenter le nombre de nouvelles infections comme une variable aléatoire suivant une loi de Poisson, où le taux d'infection dépend du nombre d'individus

susceptibles et infectés. Elle offre une meilleure flexibilité pour capturer l'incertitude et la variabilité des transmissions dans un cadre bayésien [30].

Soit le modèle compartimental répresenté comme suit[31] :

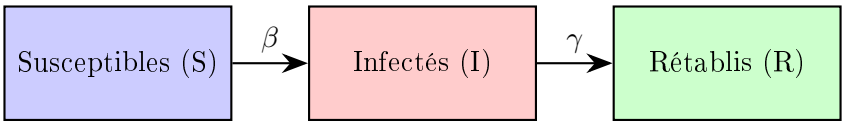

Équations Stochastiques Correspondantes

Dans notre approche, nous utilisons un processus de Poisson pour modéliser la dynamique de transmission :

- Capturer la nature discrète des événements d'infection
- Intégrer naturellement l'incertitude dans un cadre bayésien
- Respecter la contrainte $I_t \in \mathbb{N}$

Modèle Stochastique Poissonnien

Soit $X_t = (S_t, I_t, R_t)$ le vecteur d'état. Les transitions sont modélisées par :

$$\begin{cases} S_t \to S_t - 1 \quad \text{à taux} \quad \beta \frac{S_t I_t}{N} \quad \text{(nouvelle infection)} \\ I_t \to I_t - 1 \quad \text{à taux} \quad \gamma I_t \quad \text{(retirés)} \end{cases} \tag{III.1}$$

Toutefois, bien que les équations stochastiques permettent de représenter la variabilité des taux de transition via un bruit multiplicatif, elles reposent sur des approximations continues. Nous préférons ici une modélisation par processus de Poisson, plus adaptée à la nature discrète des événements d'infection et de guérison, surtout dans un cadre bayésien.

Dans un cadre stochastique, on considère que le nombre réel de nouvelles infections à un instant t est une variable aléatoire et suit une loi de Poisson. Pour chaque intervalle de temps discret t, on modélise :

$$\begin{gathered} \text{Nombre de nouvelles infections } Y_t \sim \text{Poisson}\left(\beta \frac{S_t I_t}{N}\right) \\ \text{Nombre de retirés } Z_t \sim \text{Poisson}(\gamma I_t) \end{gathered} \tag{III.2}$$

où S_t représente le nombre d'individus susceptibles, I_t le nombre d'individus infectés, et β le taux de transmission.

Les états sont ensuite mis à jour selon :

$$\begin{cases} S_{t+1} = S_t - Y_t \\ I_{t+1} = I_t + Y_t - Z_t \\ R_{t+1} = R_t + Z_t \end{cases} \tag{III.3}$$

III.2.2 Distributions *a priori*

Loi Conjuguée : Loi Gamma

La loi Gamma est utilisée par [32] Set Flaxman et ses co-auteurs pour modéliser les délais entre infection et décès, ce qui illustre son aptitude à représenter des temps positifs. Elle est également bien adaptée pour exprimer une incertitude sur des paramètres positifs comme β ou γ, notamment en raison de sa conjugaison avec la loi de Poisson. Elle est donc retenue dans ce travail comme *a priori* réaliste pour ces paramètres.

Soit la loi de poisson suivante :

$$\mathbb{P}(X = x \mid \lambda) = \frac{e^{-\lambda}\,\lambda^x}{x!} \tag{III.4}$$

La loi Gamma est la loi conjuguée pour la loi de Poisson. Sa densité de probabilité est :

$$\mathbb{P}(\lambda) = \frac{b^a\,\lambda^{a-1}\,e^{-b\lambda}}{\Gamma(a)} \tag{III.5}$$

La distribution *a posteriori* de λ sachant les données $\mathbf{X}$ est proportionnelle au produit de la vraisemblance et de la distribution *a priori*. Cela découle du théorème de Bayes :

$$\mathbb{P}(\lambda \mid \mathbf{X}) \propto P(\mathbf{X} \mid \lambda) \cdot \mathbb{P}(\lambda) \tag{III.6}$$

- **Étape 1 : Vraisemblance**

Si on a n observations indépendantes $\mathbf{X} = (X_1, X_2, \ldots, X_n)$, la vraisemblance est le produit des probabilités individuelles :

$$\mathbb{P}(\mathbf{X} \mid \lambda) = \prod_{i=1}^{n} P(X_i \mid \lambda) = \prod_{i=1}^{n} \frac{e^{-\lambda}\,\lambda^{X_i}}{X_i!} \tag{III.7}$$

$$\mathbb{P}(\mathbf{X} \mid \lambda) = \left(\prod_{i=1}^{n} e^{-\lambda}\right) \cdot \left(\prod_{i=1}^{n} \lambda^{X_i}\right) \cdot \left(\prod_{i=1}^{n} \frac{1}{X_i!}\right) \tag{III.8}$$

Chaque terme peut être simplifié séparément :

- **Terme exponentiel** :

$$\prod_{i=1}^{n} e^{-\lambda} = e^{-\lambda n}$$

- **Terme en λ** :

$$\prod_{i=1}^{n} \lambda^{X_i} = \lambda^{n\overline{x}_n}$$

- **Terme factoriel** :

$$\prod_{i=1}^{n} \frac{1}{X_i!} = \frac{1}{\prod_{i=1}^{n} X_i!}$$

$$\mathbb{P}(\mathbf{X} \mid \lambda) = e^{-\lambda n} \cdot \lambda^{n\overline{x}_n} \cdot \frac{1}{\prod_{i=1}^{n} X_i!}$$

$$\mathbb{P}(\mathbf{X} \mid \lambda) = \frac{e^{-\lambda n}\, \lambda^{n\overline{x}_n}}{\prod_{i=1}^{n} X_i!}$$

- **Étape 2 : Distribution *a priori***

La distribution *a priori* de λ est une loi Gamma de paramètres a et b :

$$\mathbb{P}(\lambda) = \frac{b^a\, \lambda^{a-1}\, e^{-b\lambda}}{\Gamma(a)} \tag{III.9}$$

- **Étape 3 : Distribution *a posteriori***

La distribution *a posteriori* de λ sachant les données $\mathbf{X}$ est proportionnelle au produit de la vraisemblance et de la distribution *a priori* :

$$\mathbb{P}(\lambda \mid \mathbf{X}) \propto \mathbb{P}(\mathbf{X} \mid \lambda) \cdot \mathbb{P}(\lambda) \tag{III.10}$$

Substituons les expressions de la vraisemblance et de la distribution *a priori* :

$$\mathbb{P}(\lambda \mid \mathbf{X}) \propto \left(\frac{e^{-\lambda n}\, \lambda^{n\overline{x}_n}}{\prod_{i=1}^{n} X_i!} \right) \cdot \left(\frac{b^a\, \lambda^{a-1}\, e^{-b\lambda}}{\Gamma(a)} \right) \tag{III.11}$$

En regroupant les termes, on obtient :

$$\mathbb{P}(X \mid \lambda) \cdot \mathbb{P}(\lambda) = \left(\prod_{i=1}^{n} \frac{1}{X_i!} \right) \cdot \frac{b^a}{\Gamma(a)} \cdot \lambda^{n\overline{x}_n + a - 1} \cdot e^{-\lambda(n+b)} \tag{III.12}$$

Simplifions cette expression en regroupant les termes en λ et $e^{-\lambda}$, et en ignorant les termes constants (indépendants de λ) :

$$\mathbb{P}(\lambda \mid \mathbf{X}) \propto \left(e^{-\lambda n}\, \lambda^{n\overline{x}_n} \right) \cdot \left(\lambda^{a-1}\, e^{-b\lambda} \right) \tag{III.13}$$

Regroupons les termes :

— **Termes en λ** :

$$\lambda^{n\overline{x}_n} \cdot \lambda^{a-1} = \lambda^{n\overline{x}_n + a - 1}$$

— **Termes en $e^{-\lambda}$** :

$$e^{-\lambda n} \cdot e^{-b\lambda} = e^{-\lambda(n+b)}$$

$$\mathbb{P}(\lambda \mid \mathbf{X}) \propto \lambda^{n\overline{x}_n + a - 1}\, e^{-\lambda(n+b)} \tag{III.14}$$

La distribution *a posteriori* est une loi Gamma de paramètres mis à jour a' et b' :

$$\mathbb{P}(\lambda \mid X) = \frac{(b')^{a'} \lambda^{a'-1} e^{-b'\lambda}}{\Gamma(a')} \tag{III.15}$$

où : - $a' = n\overline{x}_n + a$ (paramètre de forme mis à jour), - $b' = n + b$ (paramètre de taux mis à jour).
La constante de normalisation $P(X)$ est absorbée dans les termes $\frac{(b')^{a'}}{\Gamma(a')}$.

Loi Informatif : Loi log-normale

La loi Log-normale est appropriée pour modéliser des paramètres positifs avec une forte asymétrie ou variabilité. Elle est utilisée dans des contextes bayésiens récents comme la prédiction génomique ou les données économiques, notamment dans [33**?**]. Elle est souvent utilisée dans les modèles épidémiologiques pour des paramètres comme le taux de reproduction ou la durée infectieuse.
La distribution log-normale a été utilisée comme distribution *a priori* dans l'étude intitulé Inférence bayésienne des taux de propagation du COVID-19 en Afrique du Sud [34].
La loi log-normale est définie pour $\lambda_t > 0$. Si on pose $\theta = \ln \lambda_t$, alors θ suit une loi Normale de moyenne μ et de variance σ^2. La densité de probabilité de λ_t est :

$$\mathbb{P}(\lambda_t) = \frac{1}{\lambda_t \sigma \sqrt{2\pi}} \exp\left(-\frac{(\ln \lambda_t - \mu)^2}{2\sigma^2}\right). \tag{III.16}$$

- **Vraisemblance**

La vraisemblance des données $N_{t_1}, N_{t_2}, \ldots, N_{t_n}$ sous une loi de Poisson de paramètre λ_t est :

$$\mathbb{P}(N_{t_1}, N_{t_2}, \ldots, N_{t_n} \mid \lambda_t) = \prod_{i=1}^{n} \frac{e^{-\lambda_t} \lambda_t^{N_{t_i}}}{N_{t_i}!}. \tag{III.17}$$

En simplifiant, on obtient :

$$contenu...\mathbb{P}(N_{t_1}, N_{t_2}, \ldots, N_{t_n} \mid \lambda_t) = e^{-n\lambda_t} \lambda_t^{\sum_{i=1}^{n} N_{t_i}} \cdot \left(\prod_{i=1}^{n} \frac{1}{N_{t_i}!}\right). \tag{III.18}$$

- **Distribution *a posteriori***

La distribution *a posteriori* est proportionnelle au produit de la vraisemblance et de la distribution *a priori* :

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) \propto \mathbb{P}(N_{t_1}, N_{t_2}, \ldots, N_{t_n} \mid \lambda_t) \cdot \mathbb{P}(\lambda_t). \tag{III.19}$$

En substituant, on obtient :

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) \propto \left(\prod_{i=1}^{n} \frac{e^{-\lambda_t} \lambda_t^{N_{t_i}}}{N_{t_i}!}\right) \cdot \frac{1}{\lambda_t \sigma \sqrt{2\pi}} \exp\left(-\frac{(\ln \lambda_t - \mu)^2}{2\sigma^2}\right). \tag{III.20}$$

Simplifions cette expression :

1. Les termes constants (indépendants de λ_t) peuvent être ignorés dans la proportionnalité.
2. On regroupe les termes en λ_t et $e^{-\lambda_t}$:

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) \propto \lambda_t^{\left(\sum_{i=1}^{n} N_{t_i} - 1\right)} e^{-n\lambda_t} \exp\left(-\frac{(\ln \lambda_t - \mu)^2}{2\sigma^2}\right). \tag{III.21}$$

Loi non informatif : Prior de Jeffreys

La loi de Jeffreys est une loi *a priori* non informative, souvent utilisée pour garantir l'invariance par changement de paramètre. Elle est utilisée récemment dans des applications variées (voir [35, 36]) pour les paramètres d'échelle dans les modèles bayésiens. Elle est particulièrement recommandée pour les paramètres d'échelle, tels que les taux β et γ, lorsque l'on souhaite éviter d'introduire une information arbitraire.

- **Dérivation de l'information de Fisher et de la loi *a priori* de Jeffreys pour la loi de Poisson**

Information de Fisher pour une observation

Pour une loi de Poisson de paramètre λ, la densité de probabilité est :

$$\mathbb{P}(X \mid \lambda) = \frac{e^{-\lambda}\lambda^X}{X!} \tag{III.22}$$

Le logarithme de la vraisemblance est :

$$\log \mathbb{P}(X \mid \lambda) = -\lambda + X \log \lambda - \log(X!) \tag{III.23}$$

La dérivée première par rapport à λ est :

$$\frac{\partial \log \mathbb{P}(X \mid \lambda)}{\partial \lambda} = -1 + \frac{X}{\lambda} \tag{III.24}$$

La dérivée seconde par rapport à λ est :

$$\frac{\partial^2 \log \mathbb{P}(X \mid \lambda)}{\partial \lambda^2} = -\frac{X}{\lambda^2} \tag{III.25}$$

L'information de Fisher est l'opposée de l'espérance de la dérivée seconde. Pour une loi de Poisson, $\mathbb{E}[X] = \lambda$, donc :

$$I(\lambda) = -\mathbb{E}\left[-\frac{X}{\lambda^2}\right] = \frac{\mathbb{E}[X]}{\lambda^2} = \frac{\lambda}{\lambda^2} = \frac{1}{\lambda} \tag{III.26}$$

- **Information de Fisher pour n observations**

Pour n observations indépendantes $X_1, X_2, \ldots, X_n$, la vraisemblance totale est :

$$\mathbb{P}(X_1, X_2, \ldots, X_n \mid \lambda) = \prod_{i=1}^{n} \frac{e^{-\lambda}\lambda^{X_i}}{X_i!} \tag{III.27}$$

Le logarithme de la vraisemblance totale est :

$$\log \mathbb{P}(X_1, X_2, \ldots, X_n \mid \lambda) = -n\lambda + \left(\sum_{i=1}^{n} X_i\right) \log \lambda - \sum_{i=1}^{n} \log(X_i!) \tag{III.28}$$

La dérivée seconde par rapport à λ est :

$$\frac{\partial^2 \log P(X_1, X_2, \ldots, X_n \mid \lambda)}{\partial \lambda^2} = -\frac{\sum_{i=1}^{n} X_i}{\lambda^2} \tag{III.29}$$

L'information de Fisher pour n observations est donc :

$$I(\lambda) = -\mathbb{E}\left[-\frac{\sum_{i=1}^{n} X_i}{\lambda^2}\right] = \frac{n\mathbb{E}[X]}{\lambda^2} = \frac{n\lambda}{\lambda^2} = \frac{n}{\lambda} \tag{III.30}$$

La loi *a priori* de Jeffreys est une loi non informative qui dépend de l'information de Fisher. Pour une loi de Poisson de paramètre λ_t, nous avons déjà vu que :

$$\mathbb{P}(\lambda_t) \propto \frac{1}{\sqrt{\lambda_t}} \tag{III.31}$$

- **Distribution *a posteriori* pour λ_t**

Supposons que nous observons des données $N_{t_1}, N_{t_2}, \ldots, N_{t_n}$ à des instants $t_1, t_2, \ldots, t_n$. La vraisemblance des données est :

$$\mathbb{P}(N_{t_1}, N_{t_2}, \ldots, N_{t_n} \mid \lambda_t) = \prod_{i=1}^{n} \frac{e^{-\lambda_{t_i}}\lambda_{t_i}^{N_{t_i}}}{N_{t_i}!} \tag{III.32}$$

En combinant cette vraisemblance avec la loi *a priori* de Jeffreys, la distribution a posteriori pour λ_t est :

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) \propto P(N_{t_1}, N_{t_2}, \ldots, N_{t_n} \mid \lambda_t) \cdot P(\lambda_t) \tag{III.33}$$

En substituant les expressions, on obtient :

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) \propto \left(\prod_{i=1}^{n} \frac{e^{-\lambda_{t_i}}\lambda_{t_i}^{N_{t_i}}}{N_{t_i}!}\right) \cdot \frac{1}{\sqrt{\lambda_t}} \tag{III.34}$$

En regroupant les termes dépendants de λ_t, on obtient :

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) \propto \lambda_t^{\left(\sum_{i=1}^{n} N_{t_i} - \frac{1}{2}\right)} \cdot e^{-\sum_{i=1}^{n} \lambda_{t_i}} \tag{III.35}$$

Loi non informatif de Laplace : Loi uniforme

La loi uniforme a été choisit par Golightly et al. pour modéliser le taux de report λ dans leurs étude sur l'approximation du bruit linéaire et des méthodes pseudo-marginales pour l'inférence des modèles épidémiologiques stochastiques à partir de données d'incidence [28].
La loi uniforme est utilisée comme *a priori* peu non informatif lorsqu'aucune information précise n'est disponible. Elle est notamment employée dans l'article de Flaxman et collaborateurs[37] pour certains effets d'intervention. La loi uniforme sur l'intervalle $[a, b]$ est définie par :

$$\mathbb{P}(\lambda_t) = \begin{cases} \frac{1}{b-a} & \text{si } a \leq \lambda_t \leq b, \\ 0 & \text{sinon.} \end{cases} \tag{III.36}$$

La vraisemblance des données $N_{t_1}, N_{t_2}, \ldots, N_{t_n}$ est :

$$\mathbb{P}(N_{t_1}, N_{t_2}, \ldots, N_{t_n} \mid \lambda_t) = e^{-n\lambda_t} \lambda_t^{\sum_{i=1}^n N_{t_i}} \cdot \left(\prod_{i=1}^n \frac{1}{N_{t_i}!} \right). \tag{III.37}$$

La distribution *a posteriori* est proportionnelle au produit de la vraisemblance et de la distribution *a priori* :

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) \propto \begin{cases} e^{-n\lambda_t} \lambda_t^{\sum_{i=1}^n N_{t_i}} & \text{si } a \leq \lambda_t \leq b, \\ 0 & \text{sinon.} \end{cases} \tag{III.38}$$

En normalisant, on obtient une loi Gamma tronquée sur $[a, b]$:

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) = \begin{cases} \frac{e^{-n\lambda_t} \lambda_t^{\sum_{i=1}^n N_{t_i}}}{\int_a^b e^{-n\lambda_t} \lambda_t^{\sum_{i=1}^n N_{t_i}} \, d\lambda_t} & \text{si } a \leq \lambda_t \leq b, \\ 0 & \text{sinon.} \end{cases} \tag{III.39}$$

Loi *a priori* subjective : Loi Beta

La loi Bêta est définie sur l'intervalle $[0; 1]$, ce qui en fait une distribution naturelle pour modéliser des proportions comme le taux de détection ρ. Elle est recommandée dans la littérature bayésienne moderne pour représenter des probabilités, comme le montrent [38**?**].
La loi Beta est définie pour un paramètre $\lambda_t \in [0; 1]$. Sa densité de probabilité est :

$$\mathbb{P}(\lambda_t) = \frac{\lambda_t^{\alpha-1}(1-\lambda_t)^{\beta-1}}{B(\alpha, \beta)}, \tag{III.40}$$

où $B(\alpha, \beta)$ est la fonction Beta.

- **Vraisemblance**

La vraisemblance des données $N_{t_1}, N_{t_2}, \ldots, N_{t_n}$ sous une loi de Poisson de paramètre λ_t est :

$$\mathbb{P}(N_{t_1}, N_{t_2}, \ldots, N_{t_n} \mid \lambda_t) = \prod_{i=1}^{n} \frac{e^{-\lambda_t} \lambda_t^{N_{t_i}}}{N_{t_i}!}. \tag{III.41}$$

- **Distribution *a posteriori***

La distribution *a posteriori* est proportionnelle au produit de la vraisemblance et de la distribution *a priori* :

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) \propto P(N_{t_1}, N_{t_2}, \ldots, N_{t_n} \mid \lambda_t) \cdot P(\lambda_t) \tag{III.42}$$

En substituant, on obtient :

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) \propto \left(\prod_{i=1}^{n} \frac{e^{-\lambda_t} \lambda_t^{N_{t_i}}}{N_{t_i}!} \right) \cdot \frac{\lambda_t^{\alpha-1}(1-\lambda_t)^{\beta-1}}{B(\alpha, \beta)} \tag{III.43}$$

Simplifions cette expression :

1. Les termes constants (indépendants de λ_t) peuvent être ignorés dans la proportionnalité.
2. On regroupe les termes en λ_t et $(1-\lambda_t)$:

$$\mathbb{P}(\lambda_t \mid N_{t_1}, N_{t_2}, \ldots, N_{t_n}) \propto \lambda_t^{\sum_{i=1}^{n} N_{t_i} + \alpha - 1} (1-\lambda_t)^{\beta-1} e^{-n\lambda_t} \tag{III.44}$$

Loi Gamma Inverse

La loi Inverse-Gamma est souvent utilisée comme *a priori* sur des paramètres de variance ou de durée. Elle est notamment utilisée dans les modèles hiérarchiques bayésiens, comme dans [39], pour représenter une incertitude sur les échelles ou variances latentes.

La loi Gamma Inverse est définie pour un paramètre $\lambda \in (0; +\infty)$. Sa densité de probabilité est :

$$\mathbb{P}(\lambda) = \frac{b^a}{\Gamma(a)} \lambda^{-(a+1)} e^{-b/\lambda} \tag{III.45}$$

où :

- $a > 0$ est le paramètre de forme,
- $b > 0$ est le paramètre d'échelle.

- **Vraisemblance**

Soit un échantillon $X_1, X_2, \ldots, X_n$ tel que $X_i \sim \text{Poisson}(\lambda)$ conditionnellement à λ. La vraisemblance est :

$$\mathbb{P}(X_1, \ldots, X_n \mid \lambda) = \prod_{i=1}^{n} \frac{\lambda^{X_i} e^{-\lambda}}{X_i!} = \lambda^{n\overline{x}_n} e^{-n\lambda} \cdot \left(\prod_{i=1}^{n} \frac{1}{X_i!} \right) \tag{III.46}$$

On en déduit (à une constante près) :

$$\mathbb{P}(X \mid \lambda) \propto \lambda^{n\overline{x}_n} e^{-n\lambda} \tag{III.47}$$

- **Distribution *a posteriori***

La distribution *a posteriori* est proportionnelle au produit de la vraisemblance et de la loi *a priori* :

$$\mathbb{P}(\lambda \mid X) \propto \mathbb{P}(X \mid \lambda) \cdot \mathbb{P}(\lambda) \tag{III.48}$$

En substituant les expressions :

$$\mathbb{P}(\lambda \mid X) \propto \lambda^{n\overline{x}_n} e^{-n\lambda} \cdot \lambda^{-(a+1)} e^{-b/\lambda} \tag{III.49}$$

Par Simplification :

$$\mathbb{P}(\lambda \mid X) \propto \lambda^{n\overline{x}_n - a - 1} \cdot e^{-n\lambda - b/\lambda} \tag{III.50}$$

TABLE 1 – Tableau récapitulatif des distributions *a priori* et *a posteriori*

Distribution	**Fonction de densité**	**A posteriori**
Loi conjuguée (Gamma)	$\mathbb{P}(\lambda_t) = \frac{b^a \lambda_t^{a-1} e^{-b\lambda_t}}{\Gamma(a)}$	Gamma$(a + \sum_{i=1}^{n} N_{t_i},\, b + n)$
Loi Informatif (log-normale)	$\mathbb{P}(\lambda_t) = \frac{1}{\lambda_t \sigma \sqrt{2\pi}} \exp\left(-\frac{(\ln \lambda_t - \mu)^2}{2\sigma^2}\right)$	$\lambda_t^{\left(\sum_{i=1}^{n} N_{t_i} - 1\right)} e^{-n\lambda_t} \exp\left(-\frac{(\ln \lambda_t - \mu)^2}{2\sigma^2}\right)$
Loi de Laplace (uniforme)	$\mathbb{P}(\lambda_t) = \frac{1}{b-a}$ (pour $\lambda_t \in [a, b]$)	Tronquée sur $[a, b]$: $\lambda_t^{\sum_{i=1}^{n} N_{t_i}} e^{-n\lambda_t}$
Loi Non Informative (Loi de Jeffreys)	$\mathbb{P}(\lambda_t) \propto \frac{1}{\sqrt{\lambda_t}}$	$\lambda_t^{\left(\sum_{i=1}^{n} N_{t_i} - \frac{1}{2}\right)} e^{-n\lambda_t}$
Loi Subjective (Beta)	$\mathbb{P}(\lambda_t) = \frac{\lambda_t^{\alpha-1}(1-\lambda_t)^{\beta-1}}{B(\alpha,\beta)}$	$\lambda_t^{\sum_{i=1}^{n} N_{t_i} + \alpha - 1} (1 - \lambda_t)^{\beta-1} e^{-n\lambda_t}$
Loi Gamma Inverse	$\mathbb{P}(\theta) = \dfrac{b^a}{\Gamma(a)} \lambda^{-(a+1)} e^{-b/\lambda}$	$\lambda^{\sum X_i - a - 1} \cdot e^{-n\lambda - b/\lambda}$

Dans ce chapitre, nous débutons par une simulation numérique afin de générer des données réalistes, puis nous estimons les paramètres du modèle en testant différentes distributions *a priori*. Une fonction spécifique est définie pour chaque loi *a priori*, permettant de calculer le postérieur en fonction de l'ensemble des valeurs possibles de ses hyperparamètres. Cette approche nous permet d'identifier la distribution *a priori* la plus adaptée pour chaque paramètre avant de comparer l'ensemble des distributions candidates afin d'optimiser la modélisation.

IV.1 Approche Méthodologique

IV.1.1 Simulation Numérique

Pour analyser la dynamique d'une épidémie émergente, nous utilisons un modèle SIR stochastique dans une population fermée de taille N, composée initialement de $S_0 = N - 1$ individus susceptibles, $I_0 = 1$ individu infecté, et $R_0 = 0$ individu rétabli. Le modèle repose sur l'hypothèse d'un mélange homogène, c'est-à-dire que chaque individu a la même probabilité d'entrer en contact avec n'importe quel autre, et considère que la durée de l'infection suit une loi exponentielle de moyenne $1/\gamma$. Aucune immunité préalable ni intervention extérieure (comme la vaccination ou l'isolement) n'est introduite pendant la période de simulation. Cette approche permet de prendre en compte l'incertitude inhérente à la transmission et s'appuie sur les fondements théoriques proposés par Andersson et Britton en 2000 pour modéliser les épidémies dans des populations fermées [40]. La paramétrisation du modèle repose sur l'identification des paramètres épidémiologiques fondamentaux : le taux de transmission β et le taux de guérison γ. Afin de simuler des données réalistes, une approche stochastique est adoptée, où la dynamique de l'épidémie est représentée par un modèle SIR discret en temps. À chaque pas de temps, deux types d'événements sont considérés : les infections nouvelles, modélisées par une variable aléatoire suivant une loi de Poisson de paramètre $\lambda_{\text{infect}} = \beta \cdot S(t) \cdot I(t)/N$, et les guérisons, modélisées également par une Poisson de paramètre $\lambda_{\text{recov}} = \gamma \cdot I(t)$. Ces choix permettent de refléter la variabilité naturelle du processus de transmission, tout en respectant les contraintes épidémiologiques (le nombre de personnes infectées ou guéries ne peut excéder les effectifs disponibles). La simulation s'étend sur une période de 150 jours, à partir d'un état initial avec 1 individus infectés. Ce cadre permet de générer une base de données synthétique, servant de support à l'évaluation comparative des lois a priori et de leurs hyperparamètres dans une approche bayésienne.

Afin d'évaluer la performance des différentes distributions *a priori* considérées, nous avons adopté une approche par simulation de type Monte-Carlo. Plus précisément, nous avons généré $1,000$ jeux de données synthétiques à partir du modèle SIR, en fixant la valeur vraie du paramètre β à 0.3 et γ à 0.1. Pour chaque jeu de données simulé, nous avons estimé le paramètre d'intérêt à l'aide de la

méthode bayésienne via l'algorithme MCMC de Gibbs implémenté dans le package `rjags`. Deux chaînes indépendantes ont été exécutées, chacune avec $20,000$ itérations, dont $2,000$ dédiées à l'adaptation et *burn-in*. L'évaluation rigoureuse des différentes distributions *a priori* proposées constitue l'étape cruciale pour valider leur pertinence.

IV.1.2 Détermination des meilleures distributions

Pour déterminer les meilleures distributions *a priori*, nous avons adopté plusieurs afin d'obtenir une perspective complète et nuancée. Les performances ont d'abord été jugées sur la convergence des chaînes, le $\hat{R}$ moyen servant d'indicateur principal : une valeur inférieure à 1.1 confirme l'atteinte d'un équilibre stable. Ensuite, la performance prédictive a été quantifiée à l'aide de trois métriques clés : le taux de couverture des intervalles de crédibilité à 95% qui évalue la fiabilité de l'incertitude , la RMSE pour mesurer la précision globale des estimations, et le biais essentiel pour identifier toute erreur systématique. Il est à noter que notre critère principal de validation est la RMSE.

1. Erreur quadratique moyenne (RMSE)

Le RMSE est interprété comme l'erreur moyenne de prédiction, qui détermine la précision de prédiction du modèle.

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{\beta}_i - \beta_{\text{true}})^2} \tag{IV.1}$$

où $\hat{\beta}_i$ est l'estimation du paramètre β à l'itération i, β_{true} est la valeur réelle du paramètre, et n est le nombre d'échantillons MCMC. le RMSE mesure l'écart moyen entre les estimations du modèle et la valeur vraie. Plus lea RMSE est petit, plus l'estimation est précise.

2. Biais

Dans notre contexte de simulation Monte–Carlo, le biais est calculé comme la différence moyenne entre l'estimation a posteriori du paramètre et la valeur réelle fixée :

$$\text{Biais}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta_{\text{vraie}} \tag{IV.2}$$

où :

— θ_{vraie} est la valeur réelle du paramètre dans la simulation ;

— $\mathbb{E}[\hat{\theta}]$ désigne la moyenne empirique des valeurs estimées sur les N répétitions.

3. Taux de couverture

Le taux de couverture est la proportion des intervalles de confiance construits à partir de simulations qui contiennent la vraie valeur du paramètre.

$$\text{Couverture} = \mathbf{1}\{\beta_{\text{true}} \in [\hat{\beta}_{0.025}, \hat{\beta}_{0.975}]\} \tag{IV.3}$$

où β_{true} est la vraie valeur du paramètre β, $\hat{\beta}_{0.025}$ et $\hat{\beta}_{0.975}$ sont les quantiles 2.5% et 97.5% des échantillons, et $\mathbf{1}\{\cdot\}$ est la fonction indicatrice valant 1 si la condition est vraie, 0 sinon.

4. Taux de convergence : Test de Gelman et Rubin (R-hat)

Le diagnostic de convergence vise à vérifier si les chaînes MCMC ont suffisamment exploré l'espace des paramètres et atteignent bien la distribution stationnaire cible. La convergence est évaluée par le facteur de réduction potentielle de Gelman-Rubin, noté $\hat{R}$.

$$\hat{R} = \sqrt{\frac{\hat{V}}{W}} \tag{IV.4}$$

où :

- ✓ W est la variance intra-chaîne, obtenue en moyennant les variances de chaque chaîne MCMC,
- ✓ B est la variance inter-chaînes, c'est-à-dire la variance des moyennes des différentes chaînes,
- ✓ $\hat{V} = \frac{n-1}{n}W + \frac{1}{n}B$ est une estimation combinée de la variance,
- ✓ n est le nombre d'itérations par chaîne.

Le critère de convergence est atteint lorsque $\hat{R} \approx 1.1$, indiquant que toutes les chaînes MCMC explorent la même distribution cible.

IV.2 Résultats

IV.2.1 Résultats de l'évaluation de la performance des priors sur le taux de transmission

Toutes les distributions *a priori* testées présentent d'excellentes propriétés de convergence, avec des taux de réussite supérieurs à 98,9% et des valeurs de R comprises entre 1,010 et 1,014, largement inférieures au seuil critique de 1,1. Ces résultats indiquent que l'espace paramétrique a été exploré de manière satisfaisante et que les chaînes ont atteint leur distribution stationnaire. En termes de RMSE, la distribution Uniforme(0,1 ; 0,5) se distingue nettement avec la valeur la plus faible (0,1049), suivie de près par Gamma(11 ; 3) (0,1072). Ces deux distributions offrent donc la meilleure précision globale pour l'estimation de β. À l'inverse, les distributions Beta(0,5 ; 0,5) (RMSE = 0,1598) et Log-normale (RMSE = 0,1523) présentent les erreurs quadratiques moyennes les plus élevées, suggérant une moindre performance prédictive.

Toutes les distributions *a priori* induisent un biais négatif, indiquant une estimation moyenne inférieure à la valeur vraie du taux de transmission.

Sur la base des critères de convergence, de RMSE et de biais, les distributions Uniforme(0,1 ; 0,5) et Gamma(11 ; 3) émergent comme les spécifications *a priori* les plus performantes pour le paramètre β dans notre contexte de simulation.

TABLE 1 – Performance des modèles β

Modèle	**Convergence**	**Beta_Moyen**	**Couverture**	**Biais**	**RMSE**	**Rhat**
Gamma(9,30)	98.90	0.23	65.90	-0.07	0.12	1.01
lnorm(-1.2, 0.41)	99.20	0.21	67.20	-0.08	0.15	1.01
beta(1.5, 1.5)	99.00	0.22	67.70	-0.08	0.15	1.01
Inv-Gamma(11, 3)	99.30	0.25	65.70	-0.05	0.11	1.01
unif(0.1, 0.5)	99.50	0.24	66.70	-0.05	0.10	1.01
beta(0.5, 0.5)	99.20	0.21	65.30	-0.08	0.15	1.01

IV.2.2 Résultats de l'évaluation de la performance des priors sur le taux des rétirés

TABLE 2 – Performance des modèles γ

Modèle	**Convergence**	**Gamma_Moyen**	**Couverture**	**Biais**	**RMSE**	**Rhat**
Gamma(30.86, 308.64)	92.00	0.09	88.50	-0.009	0.01	1.03
lnorm(-2.3, 0.18)	89.50	0.07	64.90	-0.026	0.04	1.04
beta(1.16,1.54)	85.70	0.09	68.20	-0.002	0.07	1.09
beta(0.5, 0.5)	90	0.07	67.50	-0.026	0.04	1.04
unif(0.07, 0.14)	89.20	0.09	89.60	-0.007	0.01	1.04

Le prior Gamma présente les meilleurs résultats de convergence, avec un taux de succès de 92% et un $\hat{R}$ moyen de $1,034$, proche de la valeur cible $1,0$, indiquant une excellente stabilité des chaînes MCMC. Sa précision prédictive est également satisfaisante, avec un RMSE de $0,0178$ et un biais de $-0,0091$, reflétant une erreur systématique quasi nulle. La couverture des intervalles de crédibilité à 95% atteint $88,5\%$.

Le prior uniforme se distingue par la meilleure performance prédictive avec le RMSE le plus faible $(0,0141)$, indiquant une précision optimale des estimations. Il présente également la plus grande couverture des intervalles de crédibilité $(89,6\%)$. Toutefois, ses indicateurs de convergence sont légèrement inférieurs à ceux du prior Gamma, avec un taux de convergence de $89,2\%$ et un $\hat{R}$ moyen de $1,043$, restant néanmoins acceptables.

À l'inverse, les priors lognormal et beta affichent des performances nettement plus faibles en termes de couverture (toutes inférieures à 69%) et se situent donc derrière les priors Gamma et Uniforme, malgré des valeurs de $\hat{R}$ jugées acceptables (entre $1,04$ et $1,092$).

V.1 Résultats globaux

Les analyses menées sur l'ensemble des distributions *a priori* permettent de dégager plusieurs tendances générales concernant le comportement des estimateurs bayésiens dans notre cadre de simulation.

- **Convergence des chaînes MCMC**

L'ensemble des spécifications *a priori* présente une excellente convergence. Les valeurs du diagnostic de Gelman-Rubin se situent systématiquement dans l'intervalle R= 1,01–1,09, bien en dessous du seuil critique de 1,1. Les taux de convergence sont également élevés, atteignant au moins 85,7% pour le paramètre β, et au moins 89,2% pour γ, ce qui confirme la stabilité des chaînes et la fiabilité des inférences obtenues.

- **Performances différenciées selon le paramètre**

Les performances des distributions *a priori* varient sensiblement d'un paramètre à l'autre :
Pour le taux de transmission β, les lois Uniforme et Gamma inverse se démarquent nettement, affichant les plus faibles valeurs de RMSE et donc la meilleure précision globale.
Pour le taux de retrait γ, ce sont également les priors Uniforme et Gamma qui offrent les résultats les plus satisfaisants, tant en termes de précision que de stabilité.
Ces observations confirment que l'efficacité d'une spécification *a priori* dépend du paramètre considéré.

- **Couverture inférieure au niveau nominal**

Les taux de couverture des intervalles de crédibilité à 95% se situent entre 65,3% et 89,6%, des valeurs systématiquement inférieures au niveau nominal de 95 Cela indique que les modèles ont tendance à sous-estimer l'incertitude réelle entourant les paramètres, malgré une bonne précision moyenne des estimations.

V.2 Discussion

V.1.1 Vérification des hypothèses

L'analyse comparative des performances des différentes distributions *a priori* pour les paramètres β et γ du modèle SIR permet de vérifier systématiquement les hypothèses formulées au début de cette étude. Les distributions évaluées incluent : la loi conjuguée (Gamma), la loi informative (Log-normale), la loi de Laplace (Uniforme), la loi non informative de Jeffreys, la loi subjective (Beta) et la loi Gamma inverse.

- **Hypothèse H1 : Hypothèse Rejetée pour les deux paramètres**

Pour le paramètre β, la loi Gamma inverse(11 ;3) et la loi conjuguée Gamma(9 ;30), toutes deux informatives et bien centrées, présentent de bonnes performances (RMSE = 0,1072 et 0,1172 ; convergence $\geq$ 98,9%, $\hat{R} \approx$ 1,01). En revanche, la loi Log-normale(-1,2 ; 0,41), malgré un centrage correct, conduit à un RMSE plus élevé (0,1523), montrant que la structure de la distribution influence autant que le niveau d'information.

Pour le paramètre γ, la loi conjuguée Gamma (30,86 ; 308,64) affiche d'excellentes performances (RMSE = 0,0178, biais $\approx -0{,}009$, couverture = 88,5%, convergence = 92%, $\hat{R}$ = 1,03). À l'inverse, la loi Log-normale(-2,3 ; 0,18)génère un RMSE élevé (0,4), révélant une instabilité des estimations due à sa structure.

Ces résultats montrent que les performances des lois *a priori* ne dépendent pas uniquement de leur niveau d'information, mais surtout de leur adéquation structurelle avec les paramètres à estimer. la loi Log-normale, malgré un niveau d'information comparable, présente une variance plus élevée, des queues lourdes et une asymétrie plus marquée, ce qui dégrade la stabilité des estimations (RMSE élevé et couverture insuffisante). Cela nous conduit donc à rejeter l'hypothèse H1 qui stipule que les distributions *a priori* informatives correctement spécifiées présentent de meilleures performances d'estimation dans l'estimation des paramètres épidémiologiques .

- **Hypothèse H2 : Hypothèse rejetée les deux paramètres**

L'hypothèse selon laquelle les distributions *a priori* faiblement ou non informatives présenteraient des performances équivalentes est rejetée. Les résultats montrent des différences marquées entre les lois *a priori* :

— **Pour** β : la loi Uniforme $(0,1; 0,5)$ obtient un RMSE de 0,1049 et une convergence de 99,5%, tandis que la loi Beta $(0,5; 0,5)$ (prior de Jeffrey) présente un RMSE plus élevé (0,1598) malgré une convergence comparable.

— **Pour** γ : la loi Uniforme $(0,07; 0,14)$ se distingue par un RMSE de 0,0141 et une couverture de 89,6%, alors que la loi Beta $(0,5; 0,5)$ (prior de Jeffrey) affiche une performance beaucoup plus faibles.

Ces écarts s'expliquent par la structure des distributions car la loi Uniforme possède un support cohérent avec les valeurs plausibles des paramètres, Tandisque les lois Beta, en forme de U et limitées à $[0, 1]$, imposent des contraintes artificielles.

V.1.2 Convergence et performance des estimations

Nos valeurs Rhat sont inférieur à $1,1$, ce qui indique une bonne convergence des chaînes MCMC. Il s'agit d'un résultat positif, qui suggère que nos modèles ont réussi à échantillonner la distribution postérieure pour chaque a priori [41].

Les mesures de biais et RMSE quantifient la précision de nos estimations. Les valeurs RMSE inférieures sont généralement meilleures, nos résultats montre des variations, ce qui indique que certaines distributions aboutissent à des estimations plus précises que d'autres.

Nos valeurs de couverture sont nettement inférieures a 95% valeur nominal ciblés dans l'études. Une approche similaire d'évaluation systématique des priors a été utilisée par des chercheurs qui montre dans leurs article qu'un processus de Poisson néglige à la fois la surdispersion et la taille de la population à l'origine des infections. L'utilisation d'un processus de Poisson implique une hypothèse spécifique concernant la relation variance-moyenne (variance égale moyenne), qui peut être moins flexible que les modèles incorporant une surdispersion. Ce qui as un impact sur la couverture. Cela suggère que nos modèles, malgré une bonne convergence (Rhat), sous-estiment peut-être la véritable incertitude, probablement en raison de l'hypothèse de Poisson [41].

V.1.3 Comparaison des performances entre distributions a priori

Dans le domaine de l'inférence bayésienne, des recherches comparant les priors hiérarchiques et les priors adaptés ont montré que ces deux types affichaient les RMSE les plus faibles pour les estimations de paramètres, tandis que les priors vagues produisaient des erreurs importantes ou des problèmes de convergence [42]. Nos résultats concordent partiellement avec ces observations : les priors Beta(0,5 ; 0,5) (prior de Jeffrey), relativement vagues, ont effectivement montré des RMSE plus élevés pour β confirmant l'idée que des priors insuffisamment informatifs peuvent dégrader la précision de l'estimation.

Les distributions Uniforme(0,07 ; 0,14) (RMSE = 0,01) et Gamma(30,86 ;308,64) (RMSE = 0,010) ont été celles qui ont fourni les estimations les plus précises pour le taux de retrait. Ces résultats montrent clairement que, dans notre contexte, ces deux familles de priors sont particulièrement adaptées. Ces performances sont cohérentes avec la littérature méthodologique sur les priors gamma et uniformes dans les modèles multiniveaux [43]. En effet, les études montrent que le prior uniforme tend à produire un biais et un RMSE plus faibles lorsque la corrélation intra-classe (ICC) est faible, tandis que le prior gamma devient plus performant lorsque l'ICC est plus élevé. nos résultats confirment l'idée plus générale selon laquelle l'efficacité d'un prior dépend fortement du contexte du modèle.

Contrairement à l'intuition selon laquelle un *a priori* fortement informatif devrait améliorer l'estimation, nos résultats montrent qu'une informativité excessive peut devenir contre-productive. Les distributions Gamma(9 ;30), lnorm(-2,3 ;0,18) et lnorm(-1,2 ;0,41), bien que centrées sur les valeurs vraies, n'ont pas systématiquement dominé les *a priori* non informatif comme Uniforme(0,1 ;0,5) et Uniforme(0,07 ;0,14). Ce constat rejoint les conclusions de Gelman et al. [9] sur la nature contextuelle de l'informativité antérieure : l'efficacité d'un *a priori* dépend de son interaction avec la vraisemblance. Lorsque les données contiennent déjà une information substantielle, un prior trop concentré peut introduire une rigidité qui freine l'adaptation du modèle, tandis qu'un *a priori* faiblement informatif assure

une meilleure robustesse et flexibilité de l'inférence.

V.1.4 Limites et forces de l'étude

Cette étude s'inscrit dans un cadre méthodologique comportant à la fois des contraintes et des atouts, ces derniers contribuant à la fiabilité des résultats obtenus.

Limites de l'étude.

- Le temps d'exécution très élevé des modèles stochastiques a limité notre capacité à explorer davantage de facteurs ou à tester des modèles plus complexes.
- La non validation des résultats sur des données réelles, ce qui réduit la possibilité de généraliser pleinement nos conclusions.

Forces de l'étude.

- La méthodologie adoptée est rigoureuse, avec l'utilisation du MCMC, des équations stochastiques et de simulations numériques sur 1000 jeux de données, ce qui renforce la robustesse des résultats.
- L'évaluation multi-critères offre une analyse complète et équilibrée de la performance des différents priors.
- L'étude propose enfin des pistes de recherche claires, ouvrant la voie à des travaux futurs plus approfondis.

V.1.5 Recommandations pratiques et perspectives

Nos simulations Monte–Carlo permettent de dégager plusieurs recommandations utiles pour la mise en œuvre de l'inférence bayésienne dans les modèles épidémiologiques. Elles mettent en évidence des principes généraux ainsi que des choix de distributions *a priori* adaptés à chaque paramètre.

Recommandations spécifiques selon les paramètres Les résultats montrent que le choix de la distribution *a priori* doit tenir compte du paramètre que l'on souhaite estimer.

- **Pour le taux de transmission β et le taux de retrait γ :**
  - Les priors non informatives comme la distribution **uniforme** apparaît comme le choix le plus équilibré, car elle fournit la meilleure précision prédictive tout en garantissant une bonne convergence des chaînes MCMC.
  - En alternative, les distributions **conjuguées**, telles que la Gamma, donnent également de bonnes performances et peuvent être privilégiées pour leur interprétabilité et leur compatibilité avec le modèle de Poisson.

Principes généraux de modélisation : De manière plus générale, nos résultats confirment l'intérêt d'utiliser des priors non informatifs ou faiblement informatifs. Toutefois, aucune distribution n'est optimale dans tous les contextes. Le choix du prior doit reposer sur deux éléments clés :

- **Le paramètre ciblé**, dont la dynamique et l'échelle influencent directement la forme du prior approprié ;
- **Le contexte épidémiologique et structurel de l'étude**, notamment les valeurs physiologiquement plausibles et les connaissances préalables disponibles.

Nos analyses montrent qu'un prior trop concentré peut devenir contre-productif, même lorsqu'il est centré sur une valeur correcte. Par exemple, un prior de type `Gamma(9;30)` peut limiter la flexibilité du modèle lorsque les données sont riches en information. Cette rigidité réduit la capacité d'apprentissage à partir des observations et peut accentuer un biais systématique.

Perspectives

Les résultats obtenus dans cette étude ouvrent plusieurs pistes de recherche susceptibles d'améliorer de manière significative la modélisation bayésienne des maladies infectieuses. Ces perspectives s'organisent autour de trois axes principaux :

- **Amélioration méthodologique** : Il serait intéressant de tester d'autres lois de vraisemblance (par exemple une loi permettant la sur-dispersion) et d'évaluer les performances avec différents algorithmes d'inférence afin de vérifier si les résultats restent stables.
- **Extension à des modèles plus complexes** : L'étude pourrait être élargie à des modèles épidémiologiques plus détaillés, incluant par exemple des effets spatio-temporels ou d'autres sources d'incertitude.
- **Validation sur données réelles** : Enfin, appliquer la méthode à des données épidémiologiques réelles permettrait de confirmer les conclusions obtenues à partir des simulations.

V.2 Conclusion

L'estimation fiable des paramètres épidémiologiques constitue un enjeu majeur pour la surveillance et le contrôle des maladies infectieuses. Dans ce contexte, l'approche bayésienne offre un cadre méthodologique rigoureux permettant d'intégrer l'incertitude et les connaissances *a priori* dans le processus d'inférence. Cependant, le choix des distributions *a priori* demeure une question fondamentale qui influence directement la qualité des estimations et des prédictions épidémiologiques. Cette étude a évalué systématiquement la performance de six distributions a priori (Gamma, Log-normale, Beta, et Uniforme) pour l'estimation des paramètres du modèle SIR classique via une approche de simulation

Monte-Carlo rigoureuse. L'évaluation, incluant la convergence des chaînes MCMC (R), la précision prédictive (RMSE), le biais, et la couverture des intervalles de crédibilité, a permis de dresser un bilan nuancé de la performance de chaque distribution *a priori*. Les résultats révèlent que, pour le taux de transmission β et le taux de retrait γ, les distributions Uniforme et Gamma sont les plus performantes et se distinguent respectivement par leur précision et leur stabilité. Un enseignement majeur se dégage : il n'existe pas de prior idéal valable en toute circonstance. Le choix optimal doit toujours être contextualisé, en tenant compte de la nature du paramètre, du cadre épidémiologique, du volume d'information disponible et des objectifs de l'analyse. Malgré les limites identifiées, nos résultats ouvrent des perspectives pour l'exploration de nouvelles approches méthodologiques.

RÉFÉRENCES BIBLIOGRAPHIQUES

[1] Nathan D Wolfe, Claire Panosian Dunavan, and Jared Diamond. Origins of major human infectious diseases. *Nature*, 447(7142) :279–283, 2007.

[2] Mark EJ Woolhouse and Sonya Gowtage-Sequeria. Host range and emerging and reemerging pathogens. *Emerging infectious diseases*, 11(12) :1842, 2005.

[3] David M Morens and Anthony S Fauci. Emerging infectious diseases : threats to human health and global stability. *PLoS pathogens*, 9(7) :e1003467, 2013.

[4] World Health Organization. *Global Health Estimates 2021 : Deaths by Cause, Age, Sex, by Country and by Region, 2000-2021*. World Health Organization, Geneva, 2021. URL https://ourworldindata.org/grapher/infectious-disease-death-rates.

[5] Qiao Liu, Min Liu, Wannian Liang, Xuanjun Li, Wenzhan Jing, Zhongdan Chen, and Jue Liu. Global distribution and health impact of infectious disease outbreaks, 1996–2023 : a worldwide retrospective analysis of world health organization emergency event reports. *Journal of Global Health*, 15 :04151, 2025.

[6] Agence de la santé publique du Canada. Modélisation mathématique pour la préparation aux pandémies au canada, October 2024. URL https://www.canada.ca/fr/sante-publique/services/rapports-publications/releve-maladies-transmissibles-canada-rmtc/numero-mensuel/2024-50/numero-10-octobre-2024/modelisation-mathematique-preparation-pandemies.html. RMTC. 2024 Oct ;50(10). Last Modified : 2024-10-03.

[7] Eric Parent and Jacques Bernier. *Le raisonnement bayésien : modélisation et inférence*. Springer, 2007.

[8] Andrew Gelman. Prior distribution. In Abdel H. El-Shaarawi and Walter W. Piegorsch, editors, *Encyclopedia of Environmetrics*, volume 3, pages 1634–1637. John Wiley & Sons, Ltd., Chichester, 2002.

[9] Andrew Gelman, Daniel Simpson, and Michael Betancourt. The prior can often only be understood in the context of the likelihood. *Entropy*, 19(10) :555, 2017.

[10] Steen Hannestad and Thomas Tram. Optimal prior for bayesian inference in a constrained parameter space. *arXiv preprint arXiv :1710.08899*, 2017.

[11] John E Darges, Alen Alexanderian, and Pierre A Gremaud. Variance-based sensitivity of bayesian inverse problems to the prior distribution. *International Journal for Uncertainty Quantification*, 15(2), 2025.

[12] Gero Walter and Frank PA Coolen. Sets of priors reflecting prior-data conflict and agreement. In *International Conference on Information Processing and Management of Uncertainty in Knowledge-Based Systems*, pages 153–164. Springer, 2016.

[13] Yannick Traonmilin and Adrien Richou. Introduction aux statistiques bayésiennes, 2018. URL https://www.math.u-bordeaux.fr/~arichou/Bayes/StatBayesiennes.pdf. Notes de cours de Master 1.

[14] J. R. Norris. *Markov Chains*. Cambridge University Press, Cambridge, 1998. ISBN 978-0521633963.

[15] Éric Parent and Jacques Bernier. Construction par metropolis-hastings d'une chaîne de markov pour simulation monte carlo vers une distribution donnée. *Le raisonnement bayésien : Modélisation et inférence*, pages 245–262, 2007.

[16] Radford M Neal et al. Mcmc using hamiltonian dynamics. *Handbook of markov chain monte carlo*, 2(11) :2, 2011.

[17] Matthew D Hoffman, Andrew Gelman, et al. The no-u-turn sampler : adaptively setting path lengths in hamiltonian monte carlo. *J. Mach. Learn. Res.*, 15(1) :1593–1623, 2014.

[18] Martyn Plummer. Modélisation bayésienne avec jags et r. In *1ères Rencontres R*, Bordeaux, France, July 2012. URL https://hal.science/hal-00717521. Communication présentée aux Rencontres R 2012.

[19] Léo Grinsztajn, Elizaveta Semenova, Charles C Margossian, and Julien Riou. Bayesian workflow for disease transmission modeling in stan. *Statistics in medicine*, 40(27) :6209–6234, 2021.

[20] Christian P. Robert. Des informations a priori aux lois a priori. In *Le choix bayésien : Principes et pratique*, pages 113–174. Springer, Paris, 2006.

[21] MAS Somda, EAB Dabone, Moussa Doulougou, Cedric Stéphane Bationo, and TKM Galboni. Early-stage modelling and forecast of covid-19 outbreak in burkina faso using a bayesian sir approach. *African Journal of Mathematics and Statistics Studies*, 4(3) :145–156, 2021.

[22] Luis MA Bettencourt and Ruy M Ribeiro. Real time bayesian estimation of the epidemic potential of emerging infectious diseases. *PloS one*, 3(5) :e2185, 2008.

[23] Felix Weidemann, Manuel Dehnert, Judith Koch, Ole Wichmann, and Michael Höhle. Bayesian parameter inference for dynamic infectious disease modelling : rotavirus in germany. *Statistics in Medicine*, 33(9) :1580–1599, 2014.

[24] Andrew Gelman, Aleks Jakulin, Maria Grazia Pittau, and Yu-Sung Su. A weakly informative default prior distribution for logistic and other regression models. 2008.

[25] Xavier Didelot, Jennifer Gardy, and Caroline Colijn. Bayesian inference of infectious disease transmission from whole-genome sequence data. *Molecular biology and evolution*, 31(7) :1869–1879, 2014.

[26] Trevelyan J McKinley, Joshua V Ross, Rob Deardon, and Alex R Cook. Simulation-based bayesian inference for epidemic models. *Computational Statistics & Data Analysis*, 71 :434–447, 2014.

[27] Yuting I Li, Günther Turk, Paul B Rohrbach, Patrick Pietzonka, Julian Kappler, Rajesh Singh, Jakub Dolezal, Timothy Ekeh, Lukas Kikuchi, Joseph D Peterson, et al. Efficient bayesian inference of fully stochastic epidemiological models with applications to covid-19. *Royal Society Open Science*, 8(8) :211065, 2021.

[28] Andrew Golightly, Laura E Wadkin, Sam A Whitaker, Andrew W Baggaley, Nick G Parker, and Theodore Kypraios. Accelerating bayesian inference for stochastic epidemic models using incidence data. *Statistics and Computing*, 33(6) :134, 2023.

[29] Rosanna Cassidy, Theodore Kypraios, and Philip D O'Neill. Modelling, bayesian inference, and model assessment for nosocomial pathogens using whole-genome-sequence data. *Statistics in Medicine*, 39(12) :1746–1765, 2020.

[30] B. Nguyen-Van-Yen, Pierre Del Moral, and Bernard Cazelles. Inférence et diagnostic de modèles épidémiques stochastiques avec augmentation des données de mesure aléatoire de poisson. *Mathematical Biosciences*, 335 :108583, 2021.

[31] Babacar Mbaye Ndiaye, Lena Tendeng, and Diaraf Seck. Comparative prediction of confirmed cases with covid-19 pandemic by machine learning, deterministic and stochastic sir models. *arXiv preprint arXiv :2004.13489*, 2020.

[32] Seth Flaxman, Swapnil Mishra, Axel Gandy, H Juliette T Unwin, Thomas A Mellan, Helen Coupland, Charles Whittaker, Harrison Zhu, Tresnia Berah, Jeffrey W Eaton, et al. Estimating the effects of non-pharmaceutical interventions on covid-19 in europe. *Nature*, 584(7820) :257–261, 2020.

[33] Abraham A. Montesinos-López, Oscar A. Montesinos-López, and Julio Crossa. Bayesian lognormal regression model for genomic prediction. *Theoretical and Applied Genetics*, 137 :345–359, 2024.

[34] Rendani Mbuvha and Tshilidzi Marwala. Bayesian inference of covid-19 spreading rates in south africa. *PloS one*, 15(8) :e0237126, 2020.

[35] Yibo Shi, Braghadeesh Lakshminarayanan, and Cristian R Rojas. A metropolis-adjusted langevin algorithm for sampling jeffreys prior. *arXiv preprint arXiv :2504.06372*, 2025.

[36] Antoine Van Biesbroeck, Clément Gauchy, Cyril Feau, and Josselin Garnier. Reference prior for bayesian estimation of seismic fragility curves. *Probabilistic Engineering Mechanics*, 76 :103622, 2024.

[37] Seth Flaxman, Swapnil Mishra, Axel Gandy, H Juliette T Unwin, Thomas A Mellan, Helen Coupland, Charles Whittaker, Harrison Zhu, Tresnia Berah, Jeffrey W Eaton, et al. Estimating the effects of non-pharmaceutical interventions on covid-19 in europe. *Nature*, 584(7820) :257–261, 2020.

[38] Linduni M Rodrigo, Robert Kohn, Hadi M Afshar, and Sally Cripps. A beta cauchy-cauchy (becca) shrinkage prior for bayesian variable selection. *arXiv preprint arXiv :2501.07061*, 2025.

[39] Eric T Bradlow, Howard Wainer, and Xiaohui Wang. A bayesian random effects model for testlets. *Psychometrika*, 64(2) :153–168, 1999.

[40] Hakan Andersson and Tom Britton. *Stochastic epidemic models and their statistical analysis*, volume 151. Springer Science & Business Media, 2012.

[41] Michael Li, Jonathan Dushoff, and Benjamin M Bolker. Fitting mechanistic epidemic models to data : A comparison of simple markov chain monte carlo approaches. *Statistical methods in medical research*, 27(7) :1956–1967, 2018.

[42] Praveen Natesan, Rajiv Nandakumar, Thomas Minka, and Jonathan D. Rubright. Bayesian prior choice in irt estimation using mcmc and variational bayes. *Frontiers in Psychology*, 7 :1422, 2016.

[43] Guangming Li and Like An. Comparison of prior setting methods for multilevel model effect estimation based on small sample imbalanced nested data in bayesian framework. *Computational Intelligence and Neuroscience*, 2022(1) :2726602, 2022.

TABLE DES ANNEXES

Annexe I : Éléments complémentaires sur les chaînes de Markov **49**

Annexe II : Demonstration **52**

Annexe III : Code R **55**

Annexe I : Éléments complémentaires sur les chaînes de Markov

1. Limites des méthodes classiques de simulation

Les méthodes de simulation directe reposent généralement sur la transformation de variables aléatoires uniformes. Parmi celles-ci, la méthode la plus répandue est l'inversion de la fonction de répartition.

Principe. Soit X une variable aléatoire de fonction de répartition F. Il est alors possible de simuler X en posant

$$X = F^{-1}(U),$$

où $U \sim \mathcal{U}([0,1])$ et où F^{-1} désigne la fonction quantile, c'est-à-dire l'inverse généralisée de la fonction de répartition F.

Limites pratiques. Cette méthode suppose la connaissance explicite de la fonction F^{-1}, ce qui n'est possible que pour un nombre restreint de distributions usuelles, telles que les lois exponentielle ou de Weibull. De plus, pour les distributions multidimensionnelles, la fonction de répartition jointe devient rapidement très complexe.

Dans le cadre bayésien, la loi a posteriori

$$\pi(\theta \mid x) \propto L(x \mid \theta)\, \pi(\theta)$$

n'est connue qu'à une constante de normalisation près, ce qui rend le calcul explicite de la fonction de répartition, et donc de sa fonction quantile, impraticable. Par ailleurs, lorsque la dimension du paramètre est élevée, les coûts de calcul deviennent rapidement prohibitifs.

D'autres méthodes classiques existent, mais présentent également des limitations importantes. La méthode de rejet nécessite la construction d'une densité instrumentale dominant la densité cible, ce qui est difficile à garantir en grande dimension. La méthode de Box–Muller est limitée à la simulation de lois gaussiennes, tandis que diverses transformations ne s'appliquent qu'à des familles spécifiques de lois.

Ces limitations justifient le recours aux méthodes de Monte Carlo par chaînes de Markov (MCMC), et notamment à l'algorithme de Metropolis–Hastings, qui permettent d'échantillonner des distributions complexes sans connaître leur constante de normalisation.

2. Conditions de convergence : irréductibilité et apériodicité

Pour qu'une chaîne de Markov converge vers une distribution stationnaire unique π, certaines propriétés fondamentales doivent être vérifiées, notamment l'irréductibilité et l'apériodicité.

2.1 Irréductibilité

Définition. Une chaîne de Markov $(X_n)_{n\geq 0}$ définie sur un espace d'états E est dite irréductible par rapport à une mesure π si, pour tout ensemble mesurable $A \subset E$ tel que $\pi(A) > 0$, il existe une probabilité strictement positive d'atteindre A à partir de n'importe quel état initial.
Formellement, pour tout $x \in E$ et tout ensemble $A \subset E$ vérifiant $\pi(A) > 0$, il existe un entier $n \geq 1$ tel que

$$P^n(x, A) = \mathbb{P}(X_n \in A \mid X_0 = x) > 0.$$

Interprétation. Cette propriété signifie que la chaîne est capable d'explorer l'ensemble de l'espace d'états. Aucune région associée à une probabilité non nulle n'est inaccessible depuis un état donné.

Importance pour les méthodes MCMC. Sans irréductibilité, la chaîne peut rester confinée dans une sous-région de l'espace d'états, produisant des échantillons qui ne sont pas représentatifs de la distribution cible.

Exemple. Une chaîne définie sur l'ensemble $\{1, 2, 3, 4\}$ dans laquelle les états $\{1, 2\}$ et $\{3, 4\}$ forment deux classes distinctes sans communication entre elles n'est pas irréductible.

2.2 Apériodicité

Définition. Une chaîne de Markov est dite apériodique si elle ne présente pas de comportement cyclique. Pour un état $x \in E$, la période est définie par

$$d(x) = \gcd\{n \geq 1 : P^n(x, x) > 0\}.$$

La chaîne est apériodique si $d(x) = 1$ pour tout $x \in E$ (ou, dans le cas irréductible, pour tout état appartenant à une même classe de communication).

Interprétation. L'apériodicité signifie que la chaîne peut revenir à un état donné à des instants non réguliers et ne suit pas un schéma cyclique strict.

Importance pour les méthodes MCMC. Cette propriété empêche que certains états ne soient visités qu'à des intervalles fixes, ce qui pourrait compromettre la convergence vers la distribution cible.

Exemple. Une marche aléatoire sur $\mathbb{Z}$ alternant strictement entre nombres pairs et impairs possède une période égale à 2 et n'est donc pas apériodique.

Remarque pratique. Dans l'algorithme de Metropolis–Hastings, l'introduction d'une probabilité positive de rester dans l'état courant (auto-boucle) permet généralement d'assurer l'apériodicité.

3. Théorème ergodique

Lorsque la chaîne de Markov est irréductible, apériodique et admet une distribution stationnaire π, c'est-à-dire vérifiant

$$\pi P = \pi,$$

on a, pour tout $x \in E$,

$$\lim_{n\to\infty} P^n(x, \cdot) = \pi(\cdot).$$

De plus, le théorème ergodique garantit que, pour toute fonction f intégrable par rapport à π,

$$\frac{1}{N}\sum_{n=1}^{N} f(X_n) \xrightarrow[N\to\infty]{\text{p.s.}} \mathbb{E}_\pi[f(X)] = \int f(x)\,\pi(x)\,dx.$$

Cette propriété est fondamentale pour les méthodes MCMC, car elle assure que les moyennes empiriques calculées le long de la chaîne convergent vers les espérances sous la distribution cible, permettant ainsi une inférence statistique fiable.

Les hyperparamètres ont été choisis en se basant sur la littérature et calculés de manière à s'adapter à chaque distribution, ainsi qu'aux valeurs des paramètres utilisées pour la simulation.

Calcul des hyperparamètres pour le taux de transmission

Distribution Gamma

Pour une loi Gamma, les hyperparamètres *shape* et *rate* ont été calculés à partir de la moyenne et de l'écart-type souhaités. En prenant un écart-type cible de 0.1, on obtient :

$$\text{shape} = \frac{\hat{\beta}^2}{\text{sd}^2}, \quad \text{rate} = \frac{\hat{\beta}}{\text{sd}^2}.$$

Distribution Log-Normale

Pour la loi log-normale, les paramètres *meanlog* et *sdlog* ont été définis de manière à ce que la moyenne soit $\hat{\beta}$ et que l'intervalle de crédibilité à 95% corresponde à $[\beta_{\min}, \beta_{\max}]$. Les formules utilisées sont :

$$\text{meanlog} = \log(\hat{\beta}), \quad \text{sdlog} = \frac{\log(\beta_{\max}) - \log(\beta_{\min})}{2z_{0.975}}$$

où $z_{0.975}$ est la valeur critique de la loi normale standard.

Distribution Beta

Pour la loi Beta, les paramètres *shape1* et *shape2* ont été calculés après mise à l'échelle de β dans l'intervalle $[0, 1]$:

$$\text{shape1} = \mu\left(\frac{\mu(1-\mu)}{\sigma^2} - 1\right), \quad \text{shape2} = (1-\mu)\left(\frac{\mu(1-\mu)}{\sigma^2} - 1\right),$$

où μ et σ sont respectivement la moyenne et l'écart-type de la variable mise à l'échelle.

Distribution Inverse-Gamma

Pour l'Inverse-Gamma, les paramètres α (shape) et β (scale) ont été choisis de sorte que la moyenne de la distribution soit proche de 0.3 et que la variance reflète l'incertitude souhaitée.

Distribution Uniforme

Enfin, une loi uniforme a été définie sur l'intervalle plausible :

$$\beta \sim \text{Uniforme}(\beta_{\min}, \beta_{\max}).$$

Résumé

Le tableau ci-dessous résume les hyperparamètres obtenus pour chaque loi a priori considérée pour β :

Table 1 – Lois *a priori* pour β

Distribution	Paramètre 1	Paramètre 2	Prior
Gamma	shape = 9.00	rate = 30.00	Conjuguée
Log-Normale	meanlog = -1.20	sdlog = 0.41	Informatif
Beta	shape1 = 2.10	shape2 = 4.90	Subjectif
Inverse-Gamma	alpha = 11	beta = 3	faiblement Informatif
Uniforme	min = 0.10	max = 0.50	Non Informatif de Laplace
beta	min = 0.5	max = 0.5	Non Informatif de jeffrey

Calcul des hyperparamètres pour le taux de guérison

Distribution Gamma

Pour la loi Gamma, les hyperparamètres *shape* et *rate* ont été déterminés à partir de la moyenne et de l'écart-type souhaités (sd = 0.018) :

$$\text{shape} = \frac{\hat{\gamma}^2}{\text{sd}^2}, \quad \text{rate} = \frac{\hat{\gamma}}{\text{sd}^2}.$$

Distribution Log-Normale

Pour la loi log-normale, les paramètres *meanlog* et *sdlog* ont été choisis de manière à ce que la moyenne corresponde à $\hat{\gamma}$ et que l'intervalle de crédibilité à 95% corresponde à $[\gamma_{\min}, \gamma_{\max}]$:

$$\text{meanlog} = \log(\hat{\gamma}), \quad \text{sdlog} = \frac{\log(\gamma_{\max}) - \log(\gamma_{\min})}{2z_{0.975}}.$$

Distribution Beta

Pour la loi Beta, les hyperparamètres *shape1* et *shape2* ont été calculés après mise à l'échelle de γ dans l'intervalle $[0, 1]$:

$$\text{shape1} = \mu\left(\frac{\mu(1-\mu)}{\sigma^2} - 1\right), \quad \text{shape2} = (1-\mu)\left(\frac{\mu(1-\mu)}{\sigma^2} - 1\right),$$

où μ et σ sont la moyenne et l'écart-type de la variable mise à l'échelle.

Distribution Inverse-Gamma

Pour l'Inverse-Gamma, les paramètres α (shape) et β (scale) ont été choisis de manière à refléter la moyenne $\hat{\gamma}$ et la variance souhaitée pour l'incertitude.

Distribution Uniforme

Pour la loi uniforme, l'intervalle plausible défini est :

$$\gamma \sim \text{Uniforme}(\gamma_{\text{min}}, \gamma_{\text{max}}).$$

Résumé des hyperparamètres

Le tableau ci-dessous présente les hyperparamètres obtenus pour chaque loi a priori considérée pour γ :

TABLE 2 – Lois *a priori* pour γ

Distribution	Paramètre 1	Paramètre 2	Prior
Gamma	shape = 30.86	rate = 308.64	Conjuguée
Log-Normale	meanlog = -2.30	sdlog = 0.21	Informatif
Beta	shape1 = 2.02	shape2 = 16.22	Subjectif
Inverse-Gamma	alpha = 32.89	beta = 3.19	Informatif
Uniforme	min = 0.07	max = 0.14	Non Informatif de Laplace
beta	min = 0.5	max = 0.5	Non Informatif de jeffrey

Code JAGS

```
model {
 # === PRIORS ===
 # __PRIOR_BETA__
 # __PRIOR_GAMMA__

 # Conditions initiales
 S[1] <- N - 1
 I[1] <- 1
 R[1] <- 0

 for (t in 1:(T-1)) {
  # Infections
  lambda_infect[t] <- beta * S[t] * I[t] / N
  Y[t+1] ~ dpois(lambda_infect[t])
  Y_eff[t+1] <- min(Y[t+1], S[t])  # Contrainte

  # Guérisons
  lambda_recov[t] <- gamma * I[t]
  recov[t] ~ dpois(lambda_recov[t])
  recov_eff[t] <- min(recov[t], I[t] + Y_eff[t+1])

  # Mise à jour
  S[t+1] <- S[t] - Y_eff[t+1]
  I[t+1] <- I[t] + Y_eff[t+1] - recov_eff[t]
  R[t+1] <- R[t] + recov_eff[t]
 }
}
```

Code le modèle du taux de transmission et de retrait

```
library(rjags)
library(coda)
library(parallel)
```

```
gc()
options(warn = -1)

# -------------------------
# Fonctions de base
# -------------------------

generer_donnees <- function(beta_true = 0.3, gamma_true = 0.1, N = 1000, jours = 150) {
 S <- numeric(jours)
 I <- numeric(jours)
 Y <- numeric(jours)

 S[1] <- N - 1
 I[1] <- 1

 for (t in 1:(jours-1)) {
  lambda_infect <- beta_true * S[t] * I[t] / N
  nouveaux_cas <- rpois(1, lambda_infect)
  nouveaux_cas <- min(nouveaux_cas, S[t])

  nouvelles_guerisons <- rpois(1, gamma_true * I[t])
  nouvelles_guerisons <- min(nouvelles_guerisons, I[t])

  S[t+1] <- S[t] - nouveaux_cas
  I[t+1] <- I[t] + nouveaux_cas - nouvelles_guerisons
  Y[t+1] <- nouveaux_cas
 }

 return(list(Y = Y[-1], N = N, T = jours - 1, gamma = gamma_true))
}

func_est <- function(modele_path, donnees, beta_true = 0.3, niter = 20000, n_chains = 2) {
 tryCatch({
  model <- jags.model(file = modele_path, data = donnees, n.chains = n_chains,
  n.adapt = 2500, quiet = TRUE)
```

```
  update(model, 2000)

  samples <- coda.samples(model, variable.names = "beta", n.iter = niter, thin = 10, quiet = T

  gelman_stat <- gelman.diag(samples)
  rhat <- gelman_stat$psrf[1]



  beta_samples <- unlist(samples)
  quantiles <- quantile(beta_samples, probs = c(0.025, 0.5, 0.975))

  convergence_originale <- rhat < 1.1

  list(
  convergence = convergence_originale,
  estimation = quantiles[2],
  ic_bas = quantiles[1],
  ic_haut = quantiles[3],
  couverture = (beta_true >= quantiles[1]) & (beta_true <= quantiles[3]),
  precision = quantiles[2] - beta_true,
  rhat = rhat
  )
 }, error = function(e) {
  list(
  convergence = FALSE, convergence_stricte = FALSE,
  estimation = NA, ic_bas = NA, ic_haut = NA,
  couverture = FALSE, precision = NA,
  rhat = NA
  )
 })
}

une_simulation <- function(i, modele_path, beta_true) {
 donnees <- generer_donnees(beta_true = beta_true)
 res <- func_est(modele_path, donnees, beta_true)
```

```
 data.frame(
 simulation = i,
 CONVERGENCE = res$convergence,
 ESTIMATION = res$estimation,
 COUVERTURE = res$couverture,
 PRECISION = res$precision,
 RHAT = res$rhat
 )
}

# -------------------------
# Fonction de réplication parallèle
# -------------------------

func_rep_parallel <- function(modele_file, nom_modele, Nsim = 1000, beta_true = 0.3, n_cores =
 if (is.null(n_cores)) n_cores <- max(1, detectCores() - 1)
 start_total <- Sys.time()
 resultats_list <- list()
 n_batches <- ceiling(Nsim / batch_size)
 modele_file <- normalizePath(modele_file, mustWork = FALSE)
 is_unix <- (.Platform$OS.type == "unix")

 if (!is_unix) {
  cl <- makeCluster(n_cores)
  clusterEvalQ(cl, { library(rjags); library(coda); NULL })
  clusterExport(cl, varlist = c("une_simulation","func_est","generer_donnees","beta_true"), en
 }

 for (batch in 1:n_batches) {
  idx_start <- (batch - 1) * batch_size + 1
  idx_end <- min(batch * batch_size, Nsim)
  batch_indices <- idx_start:idx_end

  if (is_unix) {
   batch_results <- mclapply(batch_indices,
   function(i) une_simulation(i, modele_file, beta_true),
```

```
    mc.cores = n_cores,
    mc.preschedule = TRUE)
   } else {
    safe_call <- function(i) {
     tryCatch({
      une_simulation(i, modele_file, beta_true)
     }, error = function(e) {
      data.frame(simulation=i, CONVERGENCE=FALSE,
      ESTIMATION=NA, COUVERTURE=FALSE, PRECISION=NA,
      RHAT=NA)
     })
    }
    clusterExport(cl, varlist = c("modele_file","beta_true"), envir=environment())
    batch_results <- parLapplyLB(cl, batch_indices, safe_call)
   }

   resultats_list <- c(resultats_list, batch_results)
  }

  if (!is_unix) stopCluster(cl)

  resultats <- do.call(rbind, resultats_list)
  resultats
}

# -------------------------
# Statistiques finales
# -------------------------

calculer_stats_modele <- function(resultats, nom_modele) {
 data.frame(
 Modele = nom_modele,
 Conv_Classique = round(mean(resultats$CONVERGENCE, na.rm = TRUE)*100,2),
 Beta_Moyen = round(mean(resultats$ESTIMATION, na.rm = TRUE),4),
 Couverture = round(mean(resultats$COUVERTURE, na.rm = TRUE)*100,2),
 Precision_Moy = round(mean(resultats$PRECISION, na.rm = TRUE),4),
```

```
  RMSE = round(sqrt(mean(resultats$PRECISION^2, na.rm = TRUE)),4),
  Biais = round(mean(resultats$PRECISION, na.rm = TRUE),4),
  Rhat_Moyen = round(mean(resultats$RHAT, na.rm = TRUE),3)
  )
}
```

Fonction de réplication parallèle

La fonction de réplication parallèle a pour objectif de réaliser plusieurs simulations indépendantes en parallèle, afin d'accélérer le calcul et d'obtenir des résultats statistiques fiables pour l'estimation des paramètres β et γ dans le modèle épidémiologique.