N° d'ordre.....

MINISTERE DE L'ENSEIGNEMENT SUPERIEUR, DE LA RECHERCHE SCIENTIFIQUE ET DE L'INNOVATION

****

UNIVERSITÉ NAZI BONI

****

www.univ.bobo.gov.bf

MINISTÈRE DE LA SANTÉ

****

SECRÉTARIAT GÉNÉRAL

****

INSTITUT NATIONAL DE SANTE PUBLIQUE

www.centre-muraz.bf

RAPPORT DE FIN DE CYCLE

Pour obtenir la

LICENCE PROFESSIONNELLE DE STATISTIQUES ET INFORMATIQUE

Présenté par

OUEDRAOGO Rachidatou

sur le thème:

Approche statistique de correction des données du Système National d'Information Sanitaire (SNIS) du Burkina Faso après la grève de juin à septembre 2019 des agents de santé : cas des données du VIH/SIDA.

Sous la direction de:

Maître de stage : **Dr Serge M. A. SOMDA,** Méthodologie-Biostatisticien au Centre Muraz, Enseignant-Chercheur à l'université Nazi BONI

Directeur de rapport: **Dr Borlli Michel Jonas SOME,** Enseignant-Chercheur à l'université Nazi BONI

Période de stage : 02 Juin - 30 Août 2020

Année universitaire : 2019 - 2020

TABLE DES MATIÈRES

DÉDICACE

A mes aimables parents.

Vous représentez pour moi le symbole de la bonté par excellence, la source de tendresse, l'exemple du dévouement. Je Vous remercie profondément pour les encouragements et le soutien dans mes études.

A mes frères et sœurs, mes ami(e)s et à tous ceux qui ont contribué pour parfaire ce travail.

REMERCIEMENTS

Au terme de ce travail, animé d'une grande joie, je voudrais témoigner ma profonde reconnaissance à tous ceux qui, de près ou de loin, ont contribué à la réalisation de ce rapport.

- ✓ Tout d'abord, j'adresse mes remerciements à mon directeur de rapport, Dr Borlli M.J SOME, enseignant chercheur à l'université Nazi BONI qui a accepté de me guider dans la rédaction de mon rapport de fin de cycle, son écoute et ses conseils m'ont suscité un vif intérêt.
- ✓ Je tiens à remercier vivement mon maitre de stage, Dr Serge M.A SOMDA, enseignant-chercheur en statistique à l'université Nazi BONI, biostatisticien et responsable du Centre de Calcul au Centre MURAZ, pour son accueil, le temps passé ensemble et le partage de son expertise au quotidien. Il fut d'une aide précieuse à travers ses explications et ses conseils inestimables.
- ✓ Je remercie également toute l'équipe du Centre de Calcul pour leur accueil, leur esprit d'équipe et en particulier Mes encadreurs M. Ibrahima DIALLO, M. Éric DABONE et M. Mimbouré YARA gestionnaire de données au Centre MURAZ, Mme Florence KANGOYE, et Mme Philomène OUATTARA pour leurs judicieux conseils,
- ✓ Enfin, je tiens à remercier toutes les personnes qui m'ont conseillé et relu lors de la rédaction de ce rapport de stage : ma famille, mes camarades stagiaires du centre de calcul Armelle stéphanie BADO, André SOME et Sy Lucien TRAORE, mes ami(e)s ainsi que mes camarades de promotion.

RÉSUMÉ

Avoir une information sanitaire de qualité est une priorité de la Direction Générale des Statistiques Sectorielles du Ministère de la santé. Le niveau de qualité des données de routine du système national d'information sanitaire du Burkina Faso reste un défi à relever. En effet, la faible qualité des données est due à la faible complétude des données. L'analyse de l'exhaustivité sur l'année 2019 montre que plus de 70% des rapports mensuels n'ont pas été soumis au niveau intermédiaire par les districts sanitaires au mois de juin, juillet et août. Seulement vingt (20) districts ont atteint un taux de rapportage supérieur à 75% pour le taux de rapportage au niveau des Centres Médicale avec Antenne chirurgicale (CMA). Cette faible complétude a impacté négativement la qualité des données du VIH/SIDA. L'analyse portant sur la tendance des indicateurs sur trois ans montre un changement de structure des indicateurs présentant une chute remarquable pour les mois de juin, juillet, août, septembre en 2019 au niveau national comparativement à la même période de 2017 et 2018. Cela s'explique par la non notification des données pendant la grève des agents de santé. Pour corriger le creux laissé en 2019, nous avons utilisé la méthode d'imputation multiple : MICE (Multivariate Imputation by Chained Equations) et la méthode de prévision afin d'avoir des données plausibles avec une tendance normale. Ces résultats montrent que le ministère de la santé doit investir dans la formation des acteurs sur le Système National d'Information Sanitaire (SNIS) pour éviter les erreurs de remplissage tout en leur montrant l'importance des données de qualité dans la santé communautaire et dans la prise de décision.
Mots clés : Grève, MICE, Prévision, Qualité

ABSTRACT

Having quality health information is a priority for the General Directorate of Sectoral Statistics of the Ministry of Health. The quality level of routine data from the Burina Faso national health information system remains a challenge. Indeed, the low quality of the data is due to the low completeness of the data. Monthly activity reports are not either completed or sent for routine data entry. The completeness analysis for the year 2019 shows that more than 70% of the monthly reports were not submitted to the intermediate level by the health districts in June, July and August. Only twenty (20) districts achieved a reporting rate greater than 75% for the reporting rate at the level of Medical Centers with Surgical Antenna. This low completeness negatively impacted the quality of HIV / AIDS data. The analysis of the trend of the indicators over three years shows a change in the structure of the indicators showing a remarkable drop for the months of June, July, August, September in 2019 at the national level compared to the same period of 2017 and 2018. This is explained by the fact that the data was no longer entered during the strike by health workers. To correct the dip left in 2019, we used the multiple imputation method : MICE (Multivariate Imputation by Chained Equations) and the forecast method in order to have plausible data with a normal trend. These results show that the Ministry of Health must invest in the training of actors on the National Health Information System (SNIS) to avoid filling errors while showing them the importance of quality data in community health and in the taking of information decision.

Keywords : forecast, MICE, Quality, strike

LISTE DES SIGLES ET DES ABRÉVIATIONS

CHR	:	Centre Hospitalier Régional
CHU	:	Centre Hospitalier Universitaire
CISSE	:	Centre d'Information Sanitaire et de Surveillance Epidémiologique
CM	:	Centre Médical
CMA	:	Centre Médical avec Antenne Chirurgicale
CSPS	:	Centre de Santé et de Promotion Sociale
DGESS	:	Direction Générale des Etudes et des Statistiques Sectorielles
DHIS2	:	District Health Information Software – version 2
ENDOS	:	Entrepôt National de Données Sanitaires
HD	:	Hôpital de District
ICIS	:	Institut Canadien d'Indicateur de Santé
MAR	:	Missing At Random
MCAR	:	Missing Completely At Random
MCO	:	Moindres Carrés Ordinaire
MICE	:	Multiple Imputation by Chained Equations
MNAR	:	Missing Not At Random
OMS	:	Organisation mondiale de la santé
PTME	:	Prévention de la Transmission Mère Enfant
RMA	:	Rapport Mensuel d'Activités
SAIB	:	Syndicat Autonome des Infirmiers et Infirmières du Burkina
SIM	:	Services d'Information Médicale
SNIS	:	Système National d'Information Sanitaire
SPIH	:	Services de Planification et d'Information Hospitalière
SYNTAHSS	:	Syndicat des Travailleurs de l'Administration Hospitalière et des Services de Santé
SYNTSHA	:	Syndicat des Travailleurs de la Santé Humaine et Animale
SYSFMAB	:	Syndicat des Sages-Femmes et Maïeuticiens et Accoucheuses du Burkina
SYMEB	:	Syndicat national des Médecins du Burkina
TLOH	:	Télégramme lettre officielle hebdomadaire
VIH/SIDA	:	Virus de l'Immuno Déficience Humaine/ Syndrome de l'Immuno Déficience Acquise

LISTE DES TABLEAUX

LISTE DES FIGURES

PRÉAMBULE

I. Présentation de la filière

L'Université Nazi Boni (ex Université Polytechnique de Bobo-Dioulasso) est une université publique du Burkina Faso, située dans la ville de Bobo-Dioulasso. Depuis 2011, elle forme des étudiants dans les sciences des données à travers la filière Licence Statistiques-Informatique (LSI) afin de répondre au besoin de personnel qualifié aussi bien en statistique qu'en informatique muni de connaissance de base en économie. Il s'agit d'une formation résolument tournée vers les métiers de l'ingénierie des données. Elle aborde donc tous les aspects de ces métiers : collecte, administration, exploitation et valorisation des données.
L'étudiant en LSI à la fin de sa formation sera capable :

- d'organiser la collecte de l'information (enquête) ;
- de concevoir et de gérer un système d'information (base de données) ;
- de concevoir et de gérer un site web ;
- de participer à un projet de développement d'application ;
- d'analyser, résumer, et segmenter les vastes ensembles de données ;
- de décrire, traiter, synthétiser des données d'enquête ;
- d'analyser, décomposer, désaisonnaliser et modéliser des séries chronologiques ;
- d'estimer et de tester les effets d'un ensemble de facteurs.

Afin de mettre en application toutes les connaissances acquises au cours de sa formation et de s'imprégner de la vie professionnelle, l'étudiant en fin de cycle doit effectuer un stage en entreprise. Pour satisfaire cette exigence, nous avons effectué un stage de trois (03) mois allant du 02 juin au 30 août 2020 au Centre MURAZ dans le département du centre de calcul situé dans la ville de Bobo-Dioulasso. Ce stage nous a permis de produire ce présent document qui s'intitule : **Approche statistique de correction des données manquantes du système national d'information sanitaire du Burkina Faso après la grève (juin à septembre 2019) des agents de santé : cas des données du VIH/SIDA**.

II. Présentation de la structure d'accueil

II.1 Présentation de l'INSP (Institut National de Santé Publique)

L'institut National de Santé Publique du Burkina Faso est un établissement public de santé né par décret $N-2018-0618/PRES/PM/MINEFID/MS/MESRI$ du 18/06/2018. Il est doté d'une personnalité morale et juridique avec une autonomie de gestion administrative et financière. L'INSP-BF joue un rôle majeur dans la réalisation des objectifs de santé. Cet institut en collaboration avec les six (06) directions consolide les fonctions de santé publique existantes au sein d'une seule entité. Il assure également la disponibilité de données de haute qualité issues de la surveillance épidémiologique. Par ailleurs, il fournit une réponse opportune aux problèmes de santé publique et sert de centre de liaison au pays pour la coordination et la communication avec les entités régionales et continentales de gestion de la santé publique. Enfin, il constitue un centre d'innovation où les nouvelles pratiques et méthodes seront testées et incubées avant de les appliquer au sein du ministère de la santé.

✓ **Les missions de l'Institut National de Santé Publique**

L'Institut National de Santé Publique a pour mission de :

- assurer la veille sanitaire pour détecter à temps les risques sanitaires et alerter en retour les autorités de santé pour une réponse précoce idoine ;

- fournir aux autorités de santé et à Ia population, des services de laboratoire central de référence pour la protection de la santé et pour la lutte contre les maladies transmissibles et non-transmissibles ;

- assurer au sein du Ministère chargé de la santé, la promotion et la valorisation des résultats de la recherche entreprise a tous les niveaux du système de santé pour une meilleure efficacité et une assurance qualité de la recherche menée ;

- promouvoir la diffusion et l'utilisation des résultats de la recherche en santé par des moyens appropriés ;

- développer une expertise thématique, analytique et méthodologique en appui à la réalisation des fonctions essentielles de santé publique par les autorités de santé ;

- utiliser le mécanisme de l'expertise scientifique pour l'amélioration continue du système national de santé ;

- évaluer les programmes et les projets de santé ainsi que la performance globale du système

national de santé ;

- promouvoir la qualité des soins et des services de santé ;

- participer au développement, en collaboration avec les institutions nationales et internationales d'enseignement et de recherche, à la formation continue non diplômante mais certifiante en santé publique, a l'intention des professionnels de la santé ;

- développer des partenariats avec d'autres personnes morales publiques ou privées dans le cadre de la mise en œuvre des fonctions essentielles de santé.

L'INSP-BF est un institut Multi-organismes qui comprend deux types de structures :
les structures « métiers » qui sont constituées d'une part des centres dont la fusion a donné lieu à I'INSP et d'autre part par des entités scientifiques nouvelles ;
les structures « supports » qui sont faites d'organes consultatifs et de managements ainsi que de secrétariats et de directions qui assurent la coordination technique, la gestion administrative et financière ainsi que l'animation scientifique.
L'organigramme actuel de l'Institut National de Santé Publique se présente comme suit :

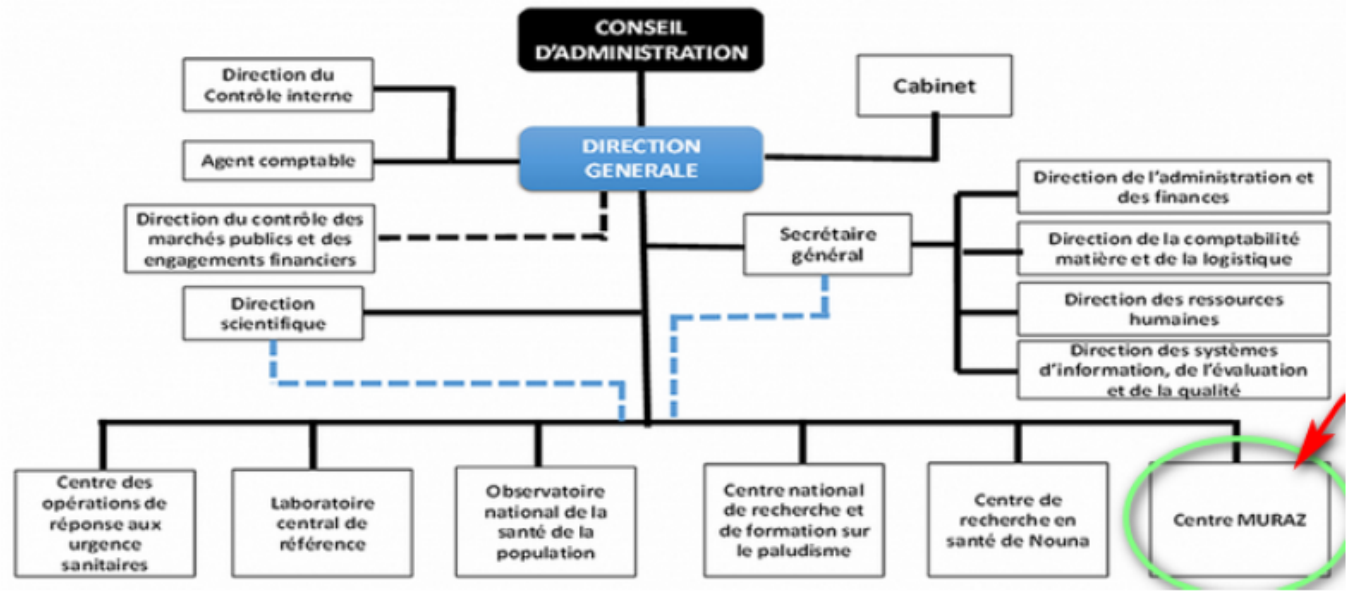

FIGURE 1 – **Institut National de Santé Publique**

II.2 Présentation du Centre MURAZ

Le Centre MURAZ est l'un des plus anciens centres de recherche en santé du Burkina Faso. Jadis connu sous le nom de Service général Autonome de la Maladie du Sommeil (SGAMS), l'actuel centre

MURAZ (depuis 1956) a été fondé en 1939 par le colonel Gaston MURAZ à Bobo-Dioulasso. Ses missions principales étaient de contrôler les maladies récurrentes y compris le paludisme, l'onchocercose, la maladie du sommeil anciennement appelée trypanosomiase humaine et les maladies à potentiel épidémique. En 2011, ce centre devient un institut public de la recherche dans le domaine de la santé avec pour nouvelles tâches de contribuer à la prévention, au diagnostic et au contrôle des maladies transmissibles et non transmissibles à travers la provision de résultats de qualité en recherche biomédicale, la formation des chercheurs et des agents de santé et l'expertise technique en biologie clinique, en science humaine et en santé publique. Depuis 2012, le Centre MURAZ ambitionne de devenir un pôle régional d'excellence et d'innovation en recherche essentielle pour la santé au Burkina Faso et dans la région africaine.

L'organigramme scientifique se compose de trois départements, à savoir :

- le département des Sciences Biomédicales (DSB) ;
- le département de Recherche Clinique (DRC) ;
- le département de Santé Public (DSP).

Chaque département est constitué d'unités de recherche. Ces trois grands départements sont chargés de la coordination de la recherche, de la prospective, de l'animation et de l'évaluation au niveau des unités de recherche et seront de ce fait, l'interface entre les unités de recherche et la Direction Scientifique.

La figure ci-dessous est l'organigramme scientifique du Centre Muraz.

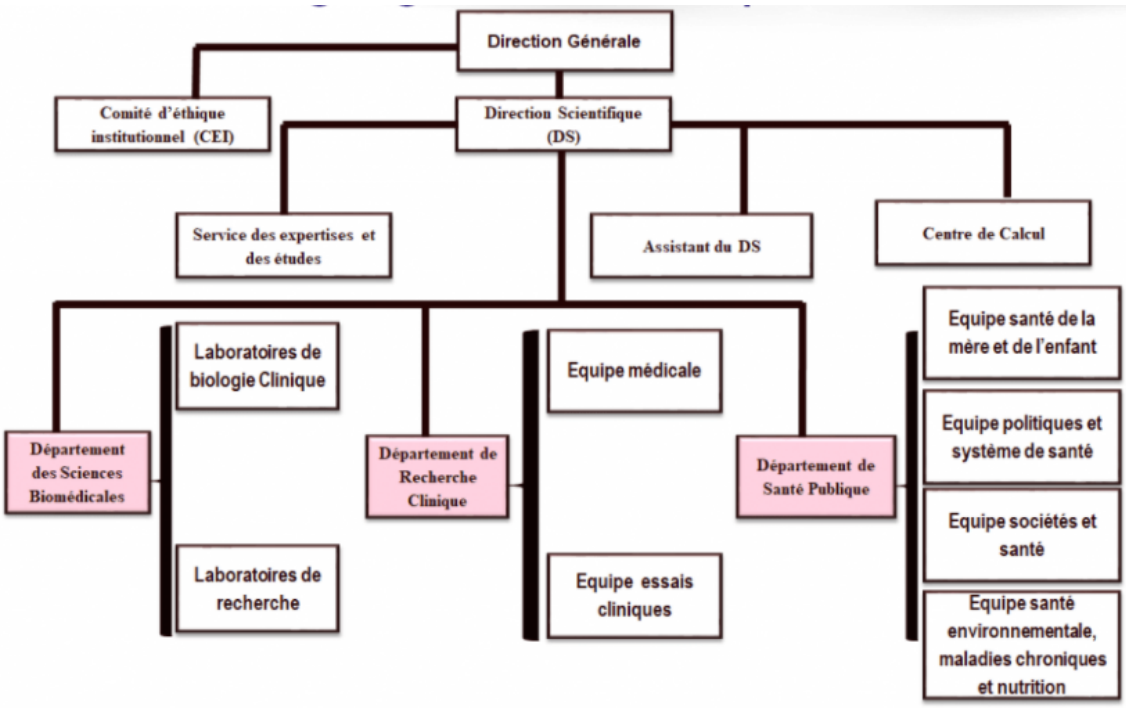

FIGURE 2 – **Organigramme Scientifique du Centre Muraz**

II.2.1 Présentation du Centre de Calcul

Logé dans le département de recherche clinique, le centre de calcul ex EAMF (Equipe d'Appui Méthodologique et Formation) est une unité entièrement consacrée à l'amélioration de la qualité de la recherche scientifique. Elle assure un grand nombre d'expertises méthodologiques hautement spécialisées et multidisciplinaires aux chercheurs du centre MURAZ et de ses institutions partenaires.
Elle offre ainsi les services suivants :

✓ appui méthodologique ;

✓ expertise scientifique et technique à travers la gestion et le traitement des données « data management », l'analyse statistique et l'évaluation Assurance Qualité (AQ) et Contrôle Qualité (CD) des données ;

✓ la recherche en méthodologie statistique et en informatique médicale.

Introduction générale

À l'échelle nationale et internationale, la collecte d'information sanitaire fiable, en temps convenable, est un pilier crucial de l'intervention en santé publique et du renforcement des systèmes de santé [**?**]. En effet, disposer d'une information de qualité est nécessaire dans la surveillance des maladies émergentes et d'autres menaces graves pour la santé. Elle est également importante pour l'organisation des programmes de sensibilisations et l'intervention rapide afin de sauver des vies et prévenir des épidémies d'ampleur nationale et aussi des pandémies mondiales. Les décisions politiques basées sur la planification et la gestion en matière de santé de la population s'inspirent le plus souvent des rapports issus du Système National d'Information Sanitaire, il demeure alors indispensable pour la planification, la gestion des services de santé et des ressources sanitaires du pays. Les systèmes d'informations sanitaires des pays sous-développés ont une performance en deçà des exigences malgré les besoins d'informations sanitaires de qualité. En effet, peu de pays disposent de systèmes d'informations sanitaires robustes pour permettre le suivi et l'évolution des programmes de santé. Malgré la disponibilité des données elles sont souvent obsolètes et le système est confronté à l'inexactitude répétitive des données collectées. Cela conduit à des erreurs dans la prise de décision [**?**].

Dans le domaine spécifique de la lutte contre le VIH/Sida, la nécessité d'un système d'information pertinent a été identifiée comme une des composantes indispensables pour la réussite des programmes. Cependant, il est très important de connaître avec exactitude le nombre de personnes vivant avec le VIH et recevant un traitement d'où l'importance de disposer de systèmes de suivi et d'évaluation solides, capables de produire des données de haute qualité [**?**]. En outre, il convient de garantir que l'ensemble des personnes vivants avec le VIH ont un accès équitable au traitement et parviennent à une suppression de leur charge virale, et que les ressources sont allouées de manière appropriée aux zones où les besoins sont les plus importants. La riposte au VIH se trouve donc à un moment crucial, où l'exactitude des données est essentielle pour garantir que les décisions adéquates soient prises de la manière la plus efficace [**?**]. Il est donc important de proposer une approche statistique de correction des données du VIH/SIDA après la grèvve de juin à septembre 2019 des agents de santé au Burkina Faso. Notre travail sera structuré en quatre grands chapitres, le premier chapitre consiste à la présentation du système national d'information sanitaire du Burkina Faso, le deuxième est une présentation du contexte et de la problématique de l'étude, par ailleurs, le troisième chapitre décrit la méthodologie de l'étude et le plan d'analyse enfin, le dernier chapitre présente les résultats obtenus. Notre travail se terminera par une conclusion générale qui rappelle les principaux résultats.

Chapitre I : Présentation du Système National d'Information Sanitaire du Burkina Faso

I.1 Introduction

Le Système National d'Information Sanitaire est un dispositif constitué d'acteurs, d'outils et de méthodes qui interagissent à différentes étapes du processus de production de l'information sanitaire que sont la collecte des données individuelles ou primaires, l'agrégation, le stockage, le partage et l'analyse des données. Ce présent chapitre est une description du Système National d'Information Sanitaire (SNIS) du BURKINA FASO.

I.2 Système National d'Information Sanitaire (SNIS)

Le Système National d'Information Sanitaire du Burkina Faso créé en 1960, est un ensemble de structures, d'institutions, de procédures, de méthodes, de matériels et de personnes. Il est organisé dans le but de fournir l'information en temps voulu et sous la forme appropriée. Sa coordination est assurée depuis 2013 par la Direction Générale des Études et des Statistiques Sectorielles (DGESS). Les objectifs du SNIS sont de :

- fournir à l'État un outil d'aide à la prise de décision ;
- fournir à tous les acteurs et utilisateurs du système de santé ainsi qu'aux autres secteurs connexes de la santé, l'information utile ;
- soutenir le processus de planification, de gestion et d'évaluation des programmes et des services de santé ;
- soutenir la recherche ;
- soutenir l'échange international d'information sanitaire ;
- produire, analyser et diffuser à temps des données fiables devant servir à la prise de décision en matière de santé.

Le Système National d'Information Sanitaire comprend six (06) composantes fonctionnelles à savoir :

- le sous-système d'information pour la surveillance épidémiologique (système d'alerte précoce) : il s'occupe des données et des informations sur les maladies épidémiologiques dans le but de contrôler leur évolution ;
- le sous-système d'information pour la gestion des programmes : il s'agit des informations concernant les contraintes et les apports financiers de l'autorité de tutelle. Il permet de faire des

investissements, le renouvellement du personnel et de la logistique ;

- le sous-système d'information pour l'administration et la gestion de ressources : il fournit les informations permettant de faire la gestion administrative de l'hôpital et concerne notamment l'admission des patients, la facturation des prestations, la gestion du personnel, la gestion budgétaire et comptable ;
- le sous-système des enquêtes et études périodiques. Ce système regroupe les sources de données réparties en deux (02) grandes catégories à savoir les données en population (recensements, enregistrements des faits d'état civil et enquêtes en population) et les données institutionnelles (dossiers individuels, dossiers de services et dossiers de ressources) ;
- le sous-système d'information à assise communautaire : il s'agit des actions et des stratégies qui visent à améliorer la santé et les droits fondamentaux des populations.

Il faut noter donc que l'objectif primordial du SNIS est de produire, d'analyser et de diffuser à temps des données fiables devant servir à la prise de décision en matière de santé. Les performances d'un tel système doivent donc être mesurées non seulement sur la base de la qualité des informations produites, mais aussi sur la preuve d'un usage continu de ces informations pour l'amélioration des activités et de la situation sanitaire.

I.3 Organisation et fonctionnement du SNIS (Système National d'Information Sanitaire)

Le Système National d'Information Sanitaire est organisé à l'image de la pyramide sanitaire à trois (03) niveaux : un niveau central, un niveau intermédiaire et un niveau périphérique.

✓ **Niveau central**

Il comprend les directions et structures centrales organisées autour du cabinet du Ministre et du Secrétariat général. A ce niveau, la gestion de l'information sanitaire est sous la responsabilité de la DGESS (Direction Générale des Études et des Statistiques Sectorielles) à travers la Direction des Statistiques Sectorielles (DSS). Il est représenté par le Centre Hospitalier Universitaire (CHU) qui est le niveau de référence le plus élevé pour les soins spécialisés. Le niveau central est chargé de produire les indicateurs pour le suivi des politiques, des programmes stratégiques en collaboration avec d'autres structures, d'assurer la production et la diffusion de l'information sanitaire (annuaire statistique, comptes de la santé, tableau de bord, bulletin d'épidémiologie et d'information sanitaire, méta-données, projections des populations cibles) et enfin coordonner le Système National d'Information Sanitaire.

✓ **Niveau intermédiaire**

Ce niveau est composé des directions régionales de la santé qui disposent d'un Centre d'Information Sanitaire et de Surveillance Épidémiologique (CISSE). Il est représenté par le Centre Hospitalier Régional (CHR) qui sert de référence et de recours aux CMA (Centre Médical avec Antenne chirurgicale). Le

niveau intermédiaire est chargé de veiller à la collecte des données et à leur validation, à l'élaboration des annuaires régionaux, des bulletins d'information et de retro information. Il est également chargé de superviser le niveau périphérique. Par ailleurs, les centres hospitaliers sont chargés plus spécifiquement de veiller à la complétude et à la promptitude des rapports des services et unités de l'hôpital et d'élaborer les bulletins périodiques et l'annuaire statistique de l'hôpital.

✓ **Niveau périphérique**

Ce niveau est représenté par le district sanitaire qui comprend deux (02) échelons : le premier échelon de soins est le Centre de Santé et de Promotion Sociale (CSPS) qui est la structure sanitaire de base du système de santé et le deuxième échelon de soins est le Centre Médical avec Antenne chirurgicale (CMA) qui sert de référence pour les formations sanitaire du district. Le niveau périphérique assure la collecte des données de base, l'agrégation, le traitement, l'analyse et la retro information. Il est dirigé par le responsable du Centre d'Information Sanitaire et de Surveillance Epidémiologique (CISSE) du district.

I.4 Collecte des données et Périodicité de transmission des rapports

Les données du SNIS (Système National d'Information Sanitaire) proviennent des rapports mensuels des formations sanitaires (publiques et privées) et des unités de soins techniques des hôpitaux. Ces données sont saisies dans l'Entrepôt de Données Sanitaires (ENDOS) à partir des Centres d'Information Sanitaires et de Surveillance Épidémiologique (CISSE) au niveau district et des Services de Planification et d'Information Hospitalière (SPIH), ou des Services d'Information Médicale (SIM) au niveau des hôpitaux.

Les rapports du mois des formations sanitaires du premier niveau (CSPS, CMA et CM) sont transmis aux districts sanitaires au plus tard le 5 du mois. L'entrepôt de données (Endos-BF) est en ligne et les districts et les hôpitaux ont jusqu'au 20 du mois pour saisir et contrôler la qualité des données. La Direction Régionale de la Santé (DRS) a jusqu'au 25 du mois pour valider les données des différentes structures de la région après avoir effectué un contrôle de qualité. A partir de ce moment la Direction des Statistiques Sectorielles a quinze (15) jours pour valider les données avant toute utilisation.

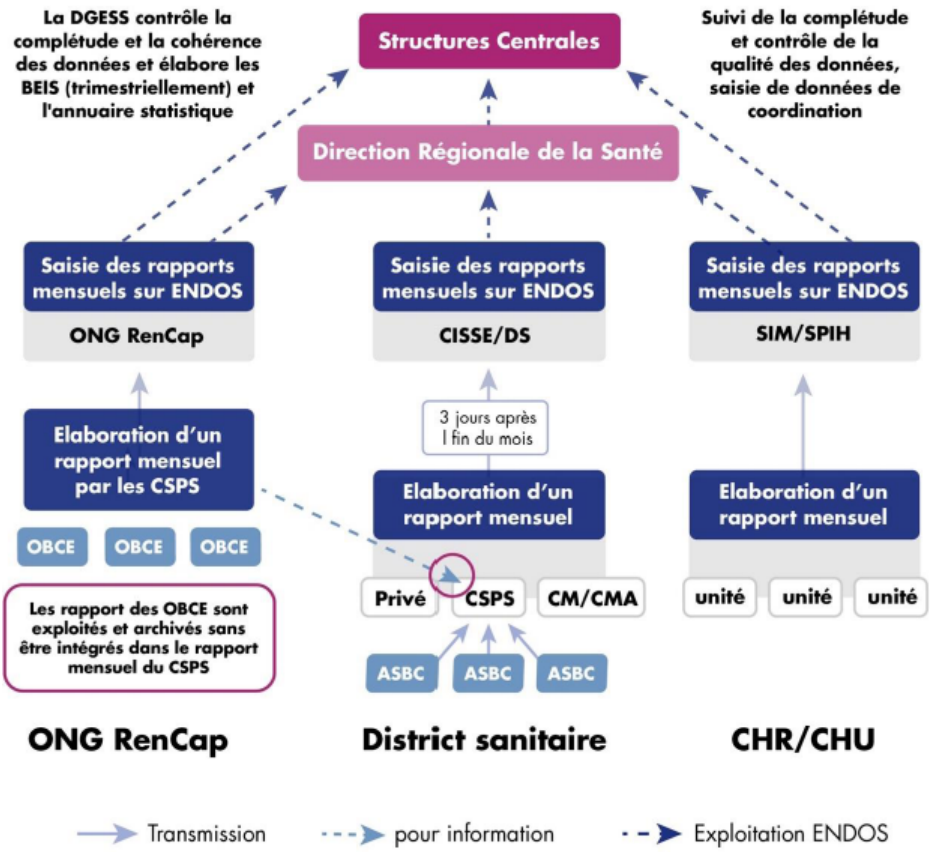

FIGURE 3 – **Circuit de l'Information**

I.5 Conclusion

Avoir une information de qualité est particulièrement importante pour le suivi de l'état de santé de la population. Avec la mise en place de l'Entrepôt de Données Sanitaire, le niveau de qualité des données de routine du système national d'information sanitaire bien qu'en amélioration ces dernières années reste une priorité du Ministère de la santé.

Chapitre II : Problématique et objectifs de l'étude

II.1 Introduction

La revue de littérature est un texte qui rassemble, analyse et organise plusieurs articles ou contenus scientifiques, afin de proposer une vue globale des avancées scientifiques d'un domaine. Dans la première partie de ce chapitre, nous présenterons des études menées dans le domaine de la qualité des données et de l'imputation multiple et enfin faire une présentation du problème principal de l'étude.

II.2 Revue de la littérature

Dans cette partie nous présenterons les études menées dans le domaine de la qualité des données et de l'imputation des données.

II.2.1 Historique et Qualité des données

La notion de qualité des données est une branche de recherche qui a intéressé de nombreux chercheurs. Cette notion a d'abord été étudiée par les statisticiens vers la fin des années 1960 [**?**]. Ainsi, au début des années 1990, les sciences de l'information ont montré un vif intérêt à ce domaine d'étude c'est ainsi que plusieurs méthodes ont été proposées pour la modélisation de la qualité des données. Dans le domaine de l'informatique, la qualité des données est examinée selon les critères de performance d'accès qui se décompose en temps, coût, volume et sécurité. Ensuite, en accessibilité qui se décompose en assistance et manipulation, de plus en fraîcheur du contenu qui se décompose en actualité et âge, enfin en fiabilité du contenu qui se décompose en complétude et en exactitude [**?**].
En santé publique, les mesures de la qualité se focalisent sur les indicateurs de performance tels que l'exhaustivité, la complétude, la cohérence et la promptitude. En effet, l'OMS (Organisation Mondiale de la Santé) aborde quatre dimensions de qualité : l'exhaustivité, la cohérence interne des données notifiées, la cohérence dans le temps et la comparaison avec des sources externes. Selon l'OMS une promptitude est jugée bonne si le nombre de rapports transmis dans les délais sur le nombre de rapports attendus est supérieur à 85%, le score idéal traduisant un bon rapportage est de 1, le taux d'exhaustivité de la notification doit être supérieur ou égale à 75% pour une bonne exhaustivité, avec un objectif global de complétude fixé à 90% [**?**].
Au Madagascar, une étude menée sur la performance du système d'information sanitaire utilise deux axes d'analyse qui sont les ratios de l'exactitude et de la complétude pour mesurer l'exactitude et la

complétude des données rapportées [?]. Il ressort donc de cette étude que le niveau moyen global de l'exactitude des données fait état de 68,1% de données exactes entre les rapports et les sources de données, 58,8% de rapports reçus parmi ceux qui étaient attendus et 77% de rapports reçus dans les délais standards.

Au Niger, une étude menée démontre que la complétude des rapports des établissements de santé transmis au niveau des districts sanitaires est de 100%. Au niveau des établissements de santé, on enregistre un taux de promptitude de 71,7% des rapports trimestriels, le taux d'exhaustivité évalué à travers le nombre de valeurs manquantes ou aberrantes pour chaque indicateur est de 100% hors mis un établissement de santé.

En ce qui concerne la cohérence de l'exhaustivité des rapports au fil du temps, aucun district sanitaire n'a une différence entre l'exhaustivité des rapports transmis à la direction des statistiques pour 2014 s'écartant de + ou - 33% de la moyenne des 3 années précédentes sauf deux districts sanitaires. Dans le domaine de cohérence interne des données rapportées, par rapport à la valeur extrêmement aberrante inférieure ou égale 3 écarts-types de la moyenne pour les quatre indicateurs, aucun district sanitaire ne présente une valeur aberrante. Aucun district sanitaire ne présente une valeur aberrante modérée (entre 2-3 écarts-types de la moyenne) par rapport à la moyenne pour l'ensemble des quatre indicateurs [?].

l'étude de l'évaluation du système d'information sanitaire de routine au Burundi révèle que les promptitudes étaient bonnes à tous les niveaux ainsi que les complétudes du rapportage au niveau supérieur. Les niveaux d'exactitudes des données variaient entre 72% à 100% entre le niveau intermédiaire et le niveau supérieur [?].

II.2.2 Traitement des données manquantes

La littérature statistique évoque plusieurs méthodes de traitement de données manquantes parmi lesquelles on peut citer les méthodes à imputations simples qui utilisent les méthodes telles que la moyenne, le cold deck, la régression [?]. Elles visent à imputer une donnée manquante une seule fois, une seule valeur lui est donc associée et les données imputées sont considérées comme étant les données qui auraient été observées si la base de données avait été complète, ce qui n'est jamais certain. Ces méthodes ne prennent pas en compte l'incertitude des données imputées. Les méthodes d'estimations simples se révèlent peu efficaces, et peuvent produire des estimations biaisées.

Par exemple, les procédures d'imputation unique comme l'imputation par la moyenne, ne tiennent pas compte de l'incertitude des imputations. Une fois l'imputation terminée, les analyses se déroulent comme si les valeurs imputées étaient les valeurs connues et vraies plutôt que les valeurs imputées. Cela conduira à des résultats trop précis et au potentiel de conclusions erronées.

Par ailleurs, nous avons les méthodes par imputation multiple qui utilisent les méthodes telles que missForest, KNN (K-Nearest Neighbors), MICE (Multiple Imputation by Chained Equations). Origi-

nellement proposée en 1978 par Rubin dans le domaine des sciences sociales, elle consiste à remplacer chaque valeur manquante par plusieurs valeurs estimées [**?**]. Ces estimations sont basées sur un modèle qui permet d'utiliser toute l'information disponible dans la base de données et de préserver ainsi les relations entre les variables. De plus, le fait d'estimer plusieurs valeurs pour chaque donnée manquante permet de prendre en compte la variabilité autour de chaque donnée imputée, et d'obtenir une variance correcte pour les estimations [**?**].

L'imputation multivariée par équations chaînées (MICE), parfois appelée « spécification entièrement conditionnelle » ou « imputation multiple par régression séquentielle », est apparue dans la littérature statistique comme une méthode de principe pour traiter les données manquantes. La création d'imputations multiples par opposition à des imputations uniques, rend compte de l'incertitude statistique dans les imputations. En outre, l'approche des équations chaînées est très flexible et peut gérer des variables de types variés (continues ou binaires) ainsi que des complexités telles que des limites ou des modèles de sauts d'enquête [**?**].

Une étude menée en Côte d'Ivoire en 2013 intitulé "Méthodologie d'obtention d'une base de données imputée » utilise l'imputation multiple plus précisément MICE (Multivariate Imputation by Chained Equations) pour l'obtention d'une base de données complètes et fiables avec des données d'enquêtes. Dans cette étude, la recherche de liens entre les variables de la base de données a été effectuée par une régression logistique binaire en fonction de la nature des variables qu'ils disposent. Cette régression leur a permis de retenir quatre variables pour l'imputation. Cette étude démontre l'efficacité de MICE (Multivariate Imputation by Chained Equations) [**?**].

Par ailleurs, une étude ménée sur la performance de l'imputation multiple sur les données environnementales, une étude comparative a été effectuée entre MissForest et deux autres méthodes d'imputations, Multivariate Imputation by Chained Equations (MICE) et K-Nearest Neighbors (KNN) il ressort que MICE figure parmi les méthodes les plus performantes pour imputer des données manquantes [**?**].

II.3 Problématique

Les données sanitaires du Burkina Faso, malgré la mise en place de ENDOS (Entrepôt de Données Sanitaires), font face à plusieurs problèmes de qualité. Ces problèmes sont, soit des erreurs humaines, des problèmes de suivi et de contrôle, soit des problèmes d'ordre politique. Le processus de contrôle de la qualité des données sanitaires du Burkina Faso n'est exécutable qu'au plan régional. Lorsque les données ont déjà été transmises à des niveaux supérieurs, le processus de détection et de correction des incohérences devient difficile. Cela est due évidement à l'absence d'outils de contrôle de la qualité des données aux niveaux inférieurs, à l'insuffisance de la formation et aux limites du système. En effet, selon le rapport d'audit du fonds mondial, plus de la moitié des 70 districts ne disposent pas de directives régissant le contrôle de la qualité des données car le contrôle de la qualité des données sanitaires est

autorisé au niveau régional et central, à la Direction des Statistiques Sectorielles, et chez les personnes chargées des données sanitaires et de la surveillance épidémiologique [**?**]. L'audit de la qualité des données de la Direction des Statistiques Sectorielles du Burkina Faso indique qu'au niveau national, 63,8% des données transmises présentaient un taux d'erreurs supérieur à 10 % [**?**]. Par ailleurs, en 2019 en raison de la lenteur du gouvernement de doter les services de santé humaine et animale en ressources humaines, équipements, consommables et autres matériels de travail, les syndicats du secteur de la santé : le SYMEB (Syndicat national des Médecins du Burkina), le SAIB (Syndicat Autonome des Infirmiers et Infirmières du Burkina), le SYSFMAB (Syndicat des Sages-Femmes et Maïeuticiens et Accoucheuses du Burkina), le SYNTAHSS (Syndicat des Travailleurs de l'Administration Hospitalière et des Services de Santé) et le SYNTSHA (Syndicat des Travailleurs de la Santé Humaine et Animale) ont appelé leurs militants à observer un mouvement d'humeur sur toute l'étendue du territoire national du 07 juin 2019 à 00 heure au 01 septembre 2019. Cette manifestation devient problématique pour les décideurs du secteur de la santé et les statisticiens car au cours de cette période, les travailleurs de la santé humaine et animale étaient tenus de ne pas fournir les rapports statistiques, les rapports mensuels d'activités et d'effectuer les tournées et missions sur toute l'étendue du territoire national [**?**]. Pour ces raisons, la base de données du VIH/SIDA figurant dans ENDOS (Entrepôt de Données Sanitaires) présente des valeurs manquantes dans la période de la grève. Or, une base de données incomplète complique l'analyse et peut donner lieu à des conclusions erronées. Elles nécessitent donc d'être pré-traitées avant d'être analysées pour une prise de décision adéquate.

II.4 Objectifs et hypothèses

L'objectif général de ce travail est de mesurer l'impact de la grève des agents de santé sur la qualité des données sanitaires du VIH/SIDA et proposer une méthode de correction des données manquantes.

II.4.1 Objectifs spécifiques

De façon spécifique, il s'agira de :

- mesurer l'exhaustivité du taux de rapportage du VIH/SIDA au niveau district ;
- mesurer l'exhaustivité des deux indicateurs d'intérêt du VIH/SIDA au niveau district sanitaire et au niveau régional ;
- mesurer la cohérence dans le temps des deux indicateurs d'intérêt et du taux de rapportage au niveau national ;
- corriger les données manquantes de chaque indicateur d'intérêt de la période de la grève au niveau national ;
- faire une prévision de chaque indicateur d'intérêt pour la période de la grève.

II.4.2 Hypothèses d'étude

A partir des objectifs spécifiques et de la revue de la littérature nous émettons les hypothèses de recherche suivantes :

H1 : nous avons une mauvaise qualité des données relatives au VIH/SIDA pendant la grève ;

H2 : la grève a entrainer un changement brusque de la série des données relative au VIH/SIDA ;

H3 : les valeurs observées de chaque indicateur peuvent dépendre d'autre valeurs ;

H4 : les valeurs observées de chaque indicateur peuvent dépendre des valeurs du passées.

II.5 Conclusion

A travers ces études décrites, nous démontrons que la qualité des données demeure un aspect très important dans la statistique. Pour éviter des conclusions erronées sur la base d'une analyse avec des données de qualité peu fiable, il serait judicieux d'entamer un processus de correction de ces données avant toute analyse d'où l'importance de l'application d'une méthode statistique pour la correction des données manquantes.

Chapitre III : Méthodologie et plan d'analyse

III.1 Introduction

La principale question dans ce chapitre est la méthode et le plan d'analyse de l'étude. Nous débuterons par une évaluation de la qualité des données, ensuite nous présenterons la méthode d'imputation multiple choisie pour corriger les données. Enfin, nous terminerons par la méthode de prévision choisie pour corriger les données manquantes.

III.2 Définition des concepts

Dans cette section, il s'agit de définir les termes essentiels pour la compréhension du thème de l'étude.

III.2.1 Qualité des données

La qualité des données (data quality) est une mesure de l'état des données fondé sur diverses méthodes : précision, exhaustivité, homogénéité, fiabilité et actualité. Mesurer le niveau de qualité de données peut aider les organisations à repérer d'éventuelles erreurs qui doivent être corrigées.

III.2.2 Taux de rapportage

Le taux de rapportage est le nombre de rapports mensuels reçu sur le nombre total de rapports attendus au niveau district.

III.2.3 Promptitude

C'est la période entre la collecte des données et la mise à disposition des données au niveau plus élevé ou leur publication.

III.2.4 Indicateur de santé

Selon l'Institut Canadien d'Indicateur de Santé (ICIS), un indicateur de santé est une mesure permettant de diffuser des renseignements sommaires sur un aspect prioritaire donné de la santé de la population ou de la performance des systèmes de santé. Par ailleurs, un indicateur de santé est "un produit de la surveillance en santé publique qui définit une mesure de la santé (c'est-à-dire, la présence d'une maladie ou d'un autre événement concernant la santé), ou bien un facteur associé à la santé (c'est-à-dire, l'état de santé ou d'autres facteurs de risque) dans une population choisie.

III.2.5 Système d'Information Sanitaire

Le Système d'Information Sanitaire est un ensemble de dispositifs et procédures de recueil et de traitement des données sanitaires que celles-ci soient relatives aux individus ou aux organisations de santé. Sa raison d'être est la génération d'informations sur la base desquelles les acteurs en santé décident et entreprennent les actions qu'ils jugent appropriées.

III.3 Méthodologie et Matériels

Dans cette section, il s'agit de montrer d'une part le matériel qui regroupe les données utilisées ainsi que les logiciels pour le traitement et l'analyse de ces données, d'autre part d'expliquer les différentes méthodes convenables pour l'atteinte de nos différents objectifs.

III.3.1 Matériels

III.3.1.1 Données utilisées

L'Entrepôt de Données Sanitaires du BURKINA FASO, construit sur la plateforme du progiciel DHIS2 (District Health Information Software) et développé par HISP (Health Information System Programme) est une technologie mise en place par le Système d'Information Sanitaire depuis 2013. Cette action a pour but d'améliorer la prise de décision sur des bases factuelles à tous les niveaux du système de santé, de renforcer les capacités d'intervention du ministère de la santé et des autres acteurs du système de santé, mais surtout de faciliter le traitement et la gestion de l'information sanitaire à tous les niveaux de la pyramide sanitaire. Donc, toutes les données des formations sanitaires publiques, privées et à base communautaire sont saisies dans ENDOS (Entrepôt de Données Sanitaires).
Les données du VIH/SIDA (Virus d'Immuno- Déficience Humaine/Syndrome d'Immuno- Déficience Acquise) sont collectées sur support papier avec le RMA (Rapport Mensuel d'Activités) communautaire qui est ensuite intégré au RMA (Rapport Mensuel d'Activités) au niveau du CSPS. Ce rapport complété est transmis au district sanitaire qui à son tour le saisit dans le DHIS2/ENDOS-BF via une interface web. Ces données saisies sont ensuite validées au niveau régional et mises à disposition du niveau central. Les données de notre étude sont des indicateurs du VIH/SIDA (Virus d'Immuno- Déficience Humaine/Syndrome d'Immuno- Déficience Acquise) issues de l'entrepôt de données sanitaire du Burkina Faso (ENDOS-BF) des années 2017, 2018, 2019 et 2020. Elles sont collectées mensuellement au niveau des formations sanitaires.

III.3.1.2 Logiciels utilisés

Pour mener à bien notre étude nous avons utilisé :

- **le logiciel Excel dans sa version 16 pour l'exportation des données sur ENDOS-BF ;**
- **le logiciel R (version 4.0.2) et RMarkdown pour le traitement, l'analyse des données et la cartographie ;**
- **le logiciel TexStudio version 2.12.16 pour la rédaction du document.**

III.3.2 Méthode

III.3.2.1 Type d'étude

Il s'agit d'une étude d'évaluation de la qualité des données, et l'application d'une méthode statistique pour la correction des données du VIH de la période de juin 2019 à septembre 2019 dans le domaine de la santé. Cette étude sera appliquée en utilisant deux indicateurs principaux :

- **le nombre de femmes enceintes ayant bénéficié d'un test de dépistage du VIH dans le cadre de la PTME (Prévention de la Transmission Mère-Enfant) lors des CPN (Consultation Prénatal) ;**
- **le nombre de personnes dépistées positives au VIH/SIDA .**

III.4 Plan d'analyse

Le plan d'analyse est une explication logique des différentes méthodes statistiques qui seront appliquées pour l'atteinte de nos objectifs.

III.4.1 Évaluation de la qualité des données

III.4.1.1 L'exhaustivité

✓ **Exhaustivité des données des indicateurs**

L'exhaustivité des données examine la proportion de valeurs non manquantes pour chaque indicateur spécifique. En d'autres termes, elle examine le pourcentage moyen de valeurs non manquantes parmi les valeurs mensuelles pour l'ensemble des indicateurs sélectionnés pendant la période définie.

✓ **Interprétation**

Si les données présentent une valeur manquante ou un certain nombre de valeurs manquantes cela signifie que les agents censés notifier les données ne le font pas exactement. D'après l'Organisation Mondiale de la Santé (OMS), le seuil d'exhaustivité d'un indicateur est de 90%.
Si le taux d'exhaustivité d'un indicateur est inférieur à 90% cela signifie que les données de cet indicateur sont sous notifiées.

✓ **Exhaustivité de la notification par les formations sanitaires**

L'exhaustivité des données sera appréciée en prenant en compte la qualité de la complétude du taux de rapportage.

$$TR = \frac{RR}{RT} * 100 \tag{1}$$

Où RR le nombre de rapport reçu. et RT le nombre de rapport total attendu.

✓ **Interprétation**

D'après l'Organisation Mondiale de la Santé, lorsque le taux de rapportage d'un mois est inférieur 75% les données en général sont sous rapportées.
Si le taux de rapportage d'un mois est de 100% les données sont exactement rapportées en fonction du nombre de rapports attendus.

III.4.1.2 Cohérence interne des données notifiées : cohérence dans le temps des données notifiées

Dans l'outil DQR (Data Quality Review), l'OMS (Organisation Mondiale de la Santé) propose d'évaluer la cohérence dans le temps par comparaison entre la valeur de l'année actuelle et celle prévue d'après la tendance des 3 années précédentes (pour les indicateurs ou programmes pour lesquels une progression est attendue), ou comparaison entre l'année actuelle et la moyenne des 3 années précédentes (pour les indicateurs ou programmes pour lesquels on s'attend à des données constantes) [**?**]. Dans notre cas nous utiliserons le test statistique de Chow pour évaluer la tendance de nos différents indicateurs dans le temps.

III.4.2 Test de changement structurel : le test de Chow

Le test de Chow ou test de stabilité de la série chronologique vérifie la stabilité d'un modèle sur une période donnée. Il permet de déterminer si deux coefficients de séries linéaires sont égaux. Les coefficients sont établis par régression linéaire. Il appelle point de rupture (t^*) un point avant lequel les coefficients des MCO (Moindres Carrés Ordinaire) prennent une valeur inconnue mais fixe et à partir duquel les coefficients sont à nouveau fixes mais avec une autre valeur. Chaque point de rupture représente un changement de l'allure de la courbe, cela veut dire un changement de la tendance de la série dans le temps. Le test de changement structurel se base sur la confrontation d'une régression contrainte (a) avec une régression non-contrainte (b). Le but principal est de déterminer si, sur les deux sous-ensembles étudiés, certains coefficients sont les mêmes [**?**].

Il s'agira dans notre cas d'effectuer ce test sur le taux de rapportage et sur chaque indicateur d'intérêt afin de connaître la situation du problème. On procède comme suit :

- on effectue la régression sur l'échantillon complet. C'est la régression contrainte l'on suppose que les coefficients sont les mêmes quelle que soit la sous période étudiée $\forall t$.

$$Y_t = \alpha_1 x_{1t} + \alpha_2 x_{2t} + \alpha_3 x_{3t} + \cdots + \alpha_n x_{kt} + \varepsilon_t \tag{2}$$

- on effectue deux régressions indépendantes sur les deux sous population. Ce sont des *régressions non contraintes* dans le sens que l'on n'impose pas que les coefficients soient les mêmes dans les deux sous-populations ou périodes.

$\forall t < t^*$

$$y_t = \alpha'_1 x_{1t} + \alpha'_2 x_{2t} + \alpha'_3 x_{3t} + \cdots + \alpha'_n x_{kt} + \varepsilon_t \tag{3}$$

$\forall t > t^*$

$$y_t = \alpha''_1 x_{1t} + \alpha''_2 x_{2t} + \alpha''_3 x_{3t} + \cdots + \alpha''_n x_{kt} + \varepsilon_t \tag{4}$$

Avec

Y_t= La variable à expliquer à la date t dans la régression contrainte ;
y_t= La variable à expliquer à la date t dans les régressions non contrainte ;

$x_{1t,\cdots,kt}$ = Les variables explicatives dans la régression contrainte ;

$x'_{1t,\cdots,kt}$ = Les variables explicatives dans la régression non contrainte ;

$x''_{1t,\cdots,kt}$ = Les variables explicatives dans la régression non contrainte ;

$\alpha_{1,\cdots,n}$, $\alpha'_{1,\cdots,n}$ et $\alpha''_{1,\cdots,n}$ = Les paramètres des différents modèle ;

ε = erreur de spécification (différence entre le modèle vrai et le modèle spécifié) ;
cette erreur est inconnue et restera inconnue ;

n = nombre d'observations.

- La statistique du test suit une loi de FISHER à K et $(N1 + N2 - 2K)$ degrés de liberté.

  Les hypothèses du test sont les suivantes pour le cas ci-dessus :

$$\begin{cases} H_0 : \alpha_1 = \alpha'_1 = \alpha''_1 \\ \qquad \alpha_2 = \alpha'_2 = \alpha''_2 \rightarrow \quad \text{le modèle est stable} \\ \qquad \alpha_n = \alpha'_n = \alpha''_n \\ H_1 : \alpha_1 \neq \alpha'_1 \neq \alpha''_1 \\ \qquad \alpha_2 \neq \alpha'_2 \neq \alpha''_2 \rightarrow \quad \text{le modèle est instable} \\ \qquad \alpha_n \neq \alpha'_n \neq \alpha''_n \end{cases}$$

III.4.3 Méthodes de correction des données manquantes

Il est assez commun en statistiques d'avoir des données avec des informations manquantes. Pour prendre en compte ces types de données dans les analyses, l'analyste emploie des méthodes d'imputations.
Il existe plusieurs méthodes de correction des données manquantes. La méthode de correction des données de routine habituellement utilisée en santé publique est l'ajustement en utilisant le taux de rapportage. Cependant, elle est une méthode empirique car elle utilise un facteur k difficile à déterminer car k indique la performance d'un district à notifier les données par rapport à un autre. Les districts n'ayant pas les mêmes comportements, la méthode est donc inappropriée.

L'ajustement peut être exprimé comme suit :

$$n_{ajust} = n + n\left(\frac{1}{c} - 1\right) * k \tag{5}$$

Où n est le nombre de sorties de service, c est l'exhaustivité du rapport et k est le facteur d'ajustement.
Nous utiliserons la méthode de prévision de Holth-winters et l'imputation multiple MICE (Multivariate Imputation by Chained Equations) pour corriger les données manquantes.

III.4.3.1 Gestion statistiques des données manquantes

✓ **Typologie des données manquantes**

Une donnée manquante peut être définie comme une donnée qui était visée par le processus de collecte, mais qui n'a pu être obtenue [**?**].
La littérature statistique distingue trois types de données manquantes selon leur processus d'existence. Cette distinction est de première importance puisque la validité des méthodes de gestion des données manquantes en dépend.

- **Manquante complètement aléatoire MCAR (Missing Completely At Random)** : les données manquantes d'une variable explicative X sont M.C.A.R si la probabilité qu'une

observation de X soit manquante est indépendante de sa valeur et de celles des autres variables recueillies, en particulier des autres variables explicatives pré-sélectionnées.

- **Manquante non aléatoire MNAR (Missing Not At Random)** : le processus d'existence d'une donnée est M.N.A.R, c'est à dire sa probabilité d'être manquante, dépend (au moins) de sa vraie valeur (et éventuellement des valeurs prises par les autres variables recueillies).
- **Manquante dépendant d'une observation MAR (Missing At Random)** : dans ce cas, la probabilité qu'une observation de X soit manquante est fonction des valeurs prises par certaines invariables de X, c'est à dire par certaines autres variables recueillies. Mais elle ne doit pas être fonction de la vraie valeur de X. Ainsi, M.A.R équivaut à M.C.A.R conditionnellement aux autres variables de la base de données.

✓ **L'Imputation Multiple**

Soit $X = (X_1, X_2, \ldots, X_k)$ un vecteur de k variables dans lequel chaque variable aléatoire est partiellement observée. Ainsi chaque variable $X_j = (X_j^{obs}, X_j^{mis})$ peut être scindée en une composante observée(X_j^{obs}) et en une composante manquante (X_j^{mis}). Le but de l'imputation multiple est d'obtenir à partir de la probabilité jointe $P(X_1, X_2, \ldots, X_k)$, la distribution non conditionnelle de X . Désignons par t le rang des itérations ($t = 1, 2, \ldots, m$). Nos données manquantes étant MAR (Missing At Random) la méthode MICE (Multivariate Imputation by Chained Equations) sera utilisée pour l'imputation.

III.4.3.2 MICE : Multivariate Imputation by Chained Equations

✓ **Description de MICE (Multivariate Imputation by Chained Equations)**

MICE (Multiple Imputation by Chained Equations) est une méthode paramétrique qui attribue un modèle d'imputation différent pour chaque variable dont les prédicteurs sont les autres variables du système. C'est une méthode itérative, c'est-à-dire que MICE impute les données manquantes une nouvelle fois à chaque itération en se basant sur les résultats obtenus à l'itération précédente jusqu'à ce que le critère d'arrêt soit atteint. L'approche de MICE consiste à imputer des données manquantes multivariées variable par variable en spécifiant un modèle d'imputation par variable contenant les données manquantes.

MICE spécifie la distribution multivariée défini P(Y, X, R| θ) en spécifiant une densité conditionnelle P(Y_j|X,Y_{-j}, R,θ) pour chaque Y_j. Cette densité est utilisée pour imputer Y_j sachant X, Y_{-J} et R. A partir de simples tirages de la distribution marginale, l'imputation sous MICE se fait par itération sur tous les modèles d'imputations conditionnés spécifiés [**?**].

✓ **Les différentes étapes de MICE : (Multivariate Imputation by Chained Equations)**

- Étape 1 : une imputation simple, telle que l'imputation de la moyenne, est effectuée pour

chaque valeur manquante dans l'ensemble de données. Ces imputations moyennes peuvent être considérées comme des «espaces réservés».

- Étape 2 : les imputations moyennes «fictives» pour une variable («var») sont ramenées à valeurs manquantes.

- Étape 3 : les valeurs observées de la variable «var» à l'étape 2 sont régressées sur les autres variables du modèle d'imputation, qui peuvent ou non être constituées de toutes les variables de l'ensemble de données. En d'autres termes, «var» est la variable dépendante dans un modèle de régression et toutes les autres variables sont des variables indépendantes dans le modèle de régression. Ces modèles de régression fonctionnent selon les mêmes hypothèses que l'on ferait lors de l'exécution de modèles de régression linéaire, logistique ou Poisson en dehors du contexte de l'imputation de données manquantes.

- Étape 4 : les valeurs manquantes pour «var» sont ensuite remplacées par des prédictions (imputations) du modèle de régression. Lorsque «var» est par la suite utilisée comme variable indépendante dans les modèles de régression pour d'autres variables, les valeurs observées et imputées seront utilisées.

- Étape 5 : les étapes 2 à 4 sont ensuite répétées pour chaque variable dont les données sont manquantes. Le cycle à travers chacune des variables constitue une itération ou «cycle». À la fin d'un cycle, toutes les valeurs manquantes ont été remplacées par des prédictions issues de régressions qui reflètent les relations observées dans les données.

- Étape 6 : les étapes 2 à 4 sont répétées pour un certain nombre de cycles, les imputations étant mises à jour à chaque cycle [**?**].

L'algorithme de l'imputation MICE est décrite à la page **??**.

Pour la spécification des modèles d'imputation pour chaque indicateur, nous allons utiliser la régression linéaire multiple.

✓ **La régression linéaire multiple**

Les modèles de régressions linéaires multiples sont plus flexibles car ils incluent plusieurs variables explicatives. Cela permet alors de contrôler à la fois plusieurs facteurs qui affecteraient la variable dépendante. Ce qui est souvent observé dans le cas réel.

$$y_t = a_0 + a_1 x_{1t} + a_2 x_{2t} + \cdots + a_k x_{kt} + \varepsilon_t \tag{6}$$

pour $t = 1, \cdots, n$

avec

y_t= variable à expliquer à la date t ;

x_{1t} = variable explicative 1 à la date t ;

x_{2t} = variable explicative 2 à la date t ;

x_{kt} = variable explicative k à la date t ;

a_0, a_1,..., a_k = paramètres du modèle ;

ε =erreur de spécification (différence entre le modèle vrai et le modèle spécifié) ;
cette erreur est inconnue ;

n = nombre d'observations.

III.4.3.3 Méthode de prévision : La méthode non saisonnière

Les méthodes de lissage exponentiel sont des méthodes de prévision à court terme, elles supposent que le phénomène étudié ne dépend que de ses valeurs passées. Ce sont des méthodes d'extrapolation qui donnent un poids prépondérant aux valeurs récentes. Les coefficients de pondération décroissent exponentiellement en remontant dans le temps, chacune des méthodes dépend d'un ou plusieurs paramètres (paramètres de lissage) compris entre 0 et 1, et le poids de chacune des valeurs passées se calcule à partir de ces paramètres.
La méthode non saisonnière de Holt-Winters traite des séries présentant une tendance linéaire mais sans saisonnalité [**?**].
Modèle considéré :

$$X_t = a(t - T) + b + \varepsilon_t \tag{7}$$

Les mises à jour pour le lissage exponentiel s'écrivent aussi

$$\hat{a}_T = \frac{1-\beta}{2}(\hat{X}_T(1) - \hat{X}_{T-1}(1)) + \frac{1+\beta}{2}\hat{a}_{T-1} \tag{8}$$

et

$$\hat{b}_T = (1-\beta^2)X_T + \beta^2(\hat{X}_{T-1}(1) + \hat{X}_{T-1}(2)) \tag{9}$$

Ainsi écrit, $\hat{a}_T$ et $\hat{b}_T$ apparaissent comme des barycentres. Holt-Winters ont alors proposé les mises à jours suivantes :

$$\hat{a}_T = (1-\gamma)(\hat{X}_T(1) - \hat{X}_{T-1}(1)) + \gamma \hat{a}_{T-1} \tag{10}$$

et

$$\hat{b}_T = (1-\alpha)X_T + \alpha(\hat{X}_{T-1}(1) + \hat{X}_{T-1}(2)) \tag{11}$$

où $|\alpha| < 1$ et $|\beta| < 1$.

L'avantage de cette approche est d'avoir une plus grande flexibilité mais la contrepartie est de devoir régler deux paramètres. Si α et β sont proches de 1 tous les deux, la prévision est lisse (fort poids du passé) et au cas contraire elle est rigide (dépend des observations précédentes).

III.5 Conclusion

Dans notre étude, nous utiliserons la méthode MICE et de prévision pour la correction des données de la période de la grève. En ce qui concerne l'analyse de la qualité des données nous utiliserons l'exhaustivité et la cohérence dans le temps des indicateurs ainsi que du taux de rapportage des données.

Chapitre IV : Résultats et discussion

IV.1 Introduction

Dans ce chapitre, il s'agit de la présentation des résultats obtenus à partir des données du VIH/SIDA dans ENDOS-BF. Premièrement, nous ferons une analyse sur la qualité des données pour l'année 2019, il s'agira dans cette section de mesurer l'exhaustivité de la notification du rapportage des rapports mensuels et des indicateurs d'intérêt par district et par région. Deuxièmement, viendra la section sur le test de changement structurel pour etudier la cohérence dans le temps de nos indicateurs d'intérêt et le taux de rapportage. Enfin, nous proposerons une méthode d'imputation et de lissage exponentiel pour corriger les données manquantes dues à la grève des agents de santé au Burkina Faso.

IV.2 Résultat de l'évaluation de la qualité des données

Dans cette section, il s'agit de montrer les résultats sur l'analyse de la qualité des données de chaque indicateur d'intérêt.

IV.2.1 Résultats de L'exhaustivité

✓ **Exhaustivité de la notification par les formations sanitaires**

L'analyse du taux de rapportage sur l'année 2019 montre que plus de 70% des rapports mensuels n'ont pas été soumis au niveau intermédiaire par les districts sanitaires au mois de juin, juillet et août. Les districts ayant atteint un taux de rapportage supérieur à 75% pour le rapportage CMA sont entre autres : le district de Barsalogho dans le centre Nord, le district de Gayeri à l'Est, le district de Gorom-Gorom au Sahel et le district de Batié dans le Sud-Ouest pour les mois de juin et de septembre ; au mois de juillet et août il s'agissait du district de Gayeri à l'Est et du district de Batié dans le Sud-Ouest ; et enfin dans le mois d'octobre il s'agissait du district de Réo dans le Centre Ouest, du district de Gayeri à l'Est, du district de Gorom-Gorom au Sahel et du district de Batié dans le Sud-Ouest. En somme, de juin à novembre seulement 20 districts ont un taux de rapportage supérieur à 75%. En ce qui concerne le programme de protection mère-enfant, le rapportage demeure très faible au niveau district sanitaire aucun district n'a soumis de rapport pendant les périodes de juin, juillet, août et septembre. Au niveau régional durant ses périodes, le taux de rapportage est de 31% ce qui est inférieur au seuil de 75%.

✓ **Exhaustivité des données des indicateurs**

L'exhaustivité des indicateurs est le pourcentage des valeurs manquantes par mois sur l'année 2019. Les pourcentages des valeurs manquantes de l'indicateur "nombre de personnes dépistées positives au VIH/SIDA" au niveau district sanitaire pour les mois de juin, juillet, août, septembre et octobre sont respectivement 81,4%, 90%, 88,5%, 82,9% et 84,3%. Soit un taux d'exhaustivité global de 8,57% sur l'année 2019 au niveau district et 30,76% au niveau régional. Cela est relativement faible et en dessous du seuil de 90% (recommandé par l'OMS).

Pour l'indicateur "nombre de femmes enceintes ayant bénéficié d'un test de dépistage pendant les CPN", les pourcentages des valeurs manquantes dans les mois de juin, juillet, août, septembre et octobre sont respectivement 54,3%, 57,1%, 57,1%, 55,7% et 57,1%. Soit un taux global de 38,57% au niveau district sanitaire et 76,92% au niveau régional.

Les cartes ci-dessous sont une représentation de l'exhaustivité de chaque indicateur en 2019 selon les districts sanitaires et les régions. Selon la légende, les zones dont les fonds sont clairs sont les zones où les données sont bien notifiées.

FIGURE 4 – **Exhaustivité de la notification des femmes enceintes ayant fait un test de VIH au niveau district sanitaire**

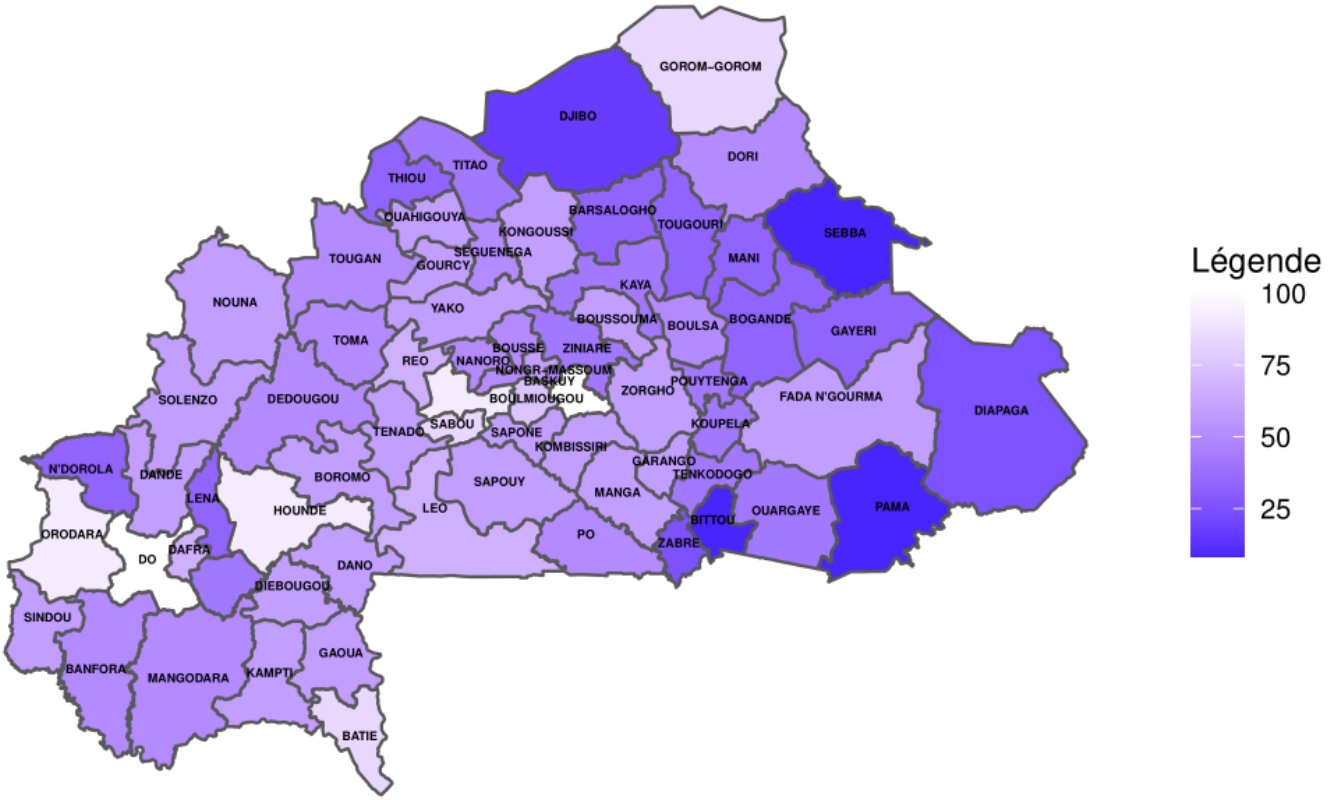

FIGURE 5 – **Exhaustivité de la notification du nombre de personnes dépistées positives au VIH au district sanitaire**

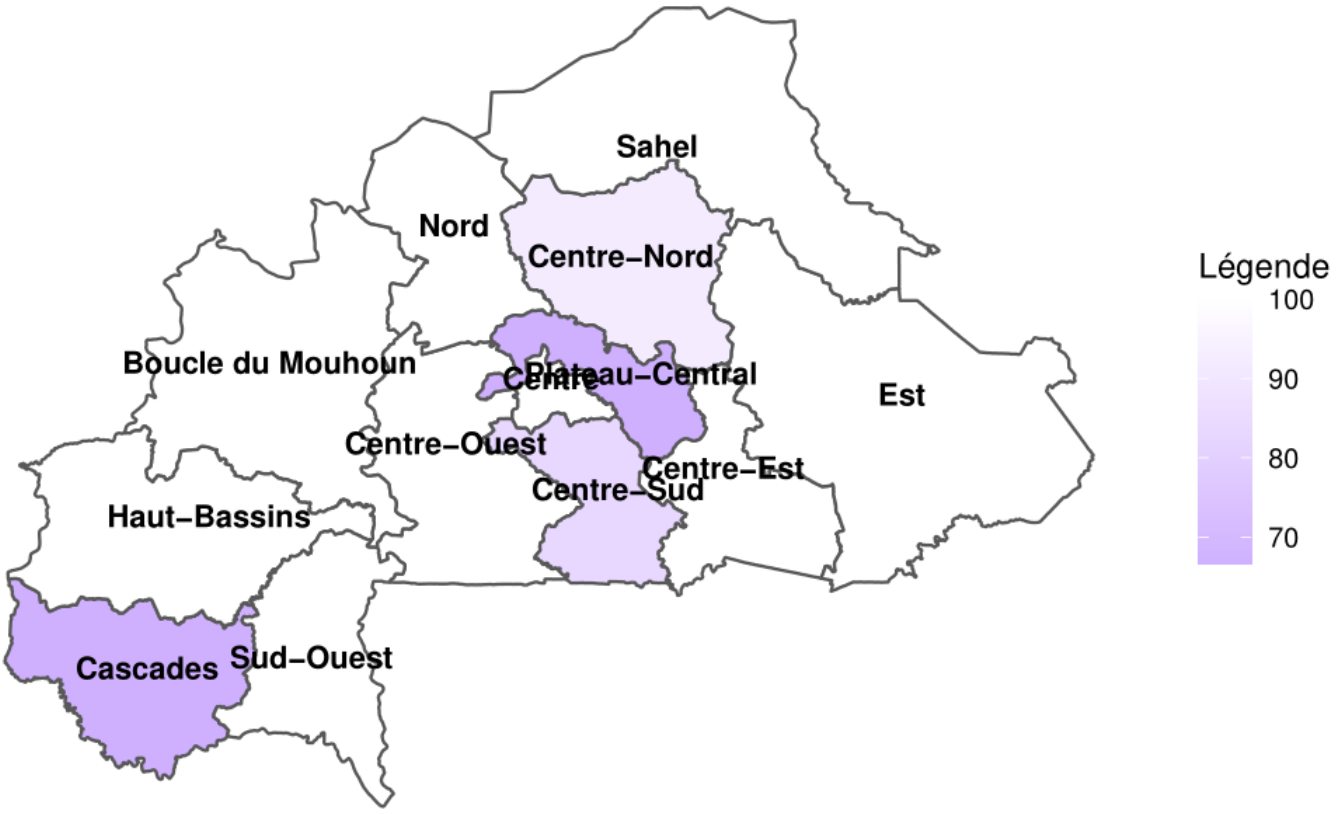

FIGURE 6 – **Exhaustivité de la notification des femmes enceintes ayant fait un test de VIH au niveau régional**

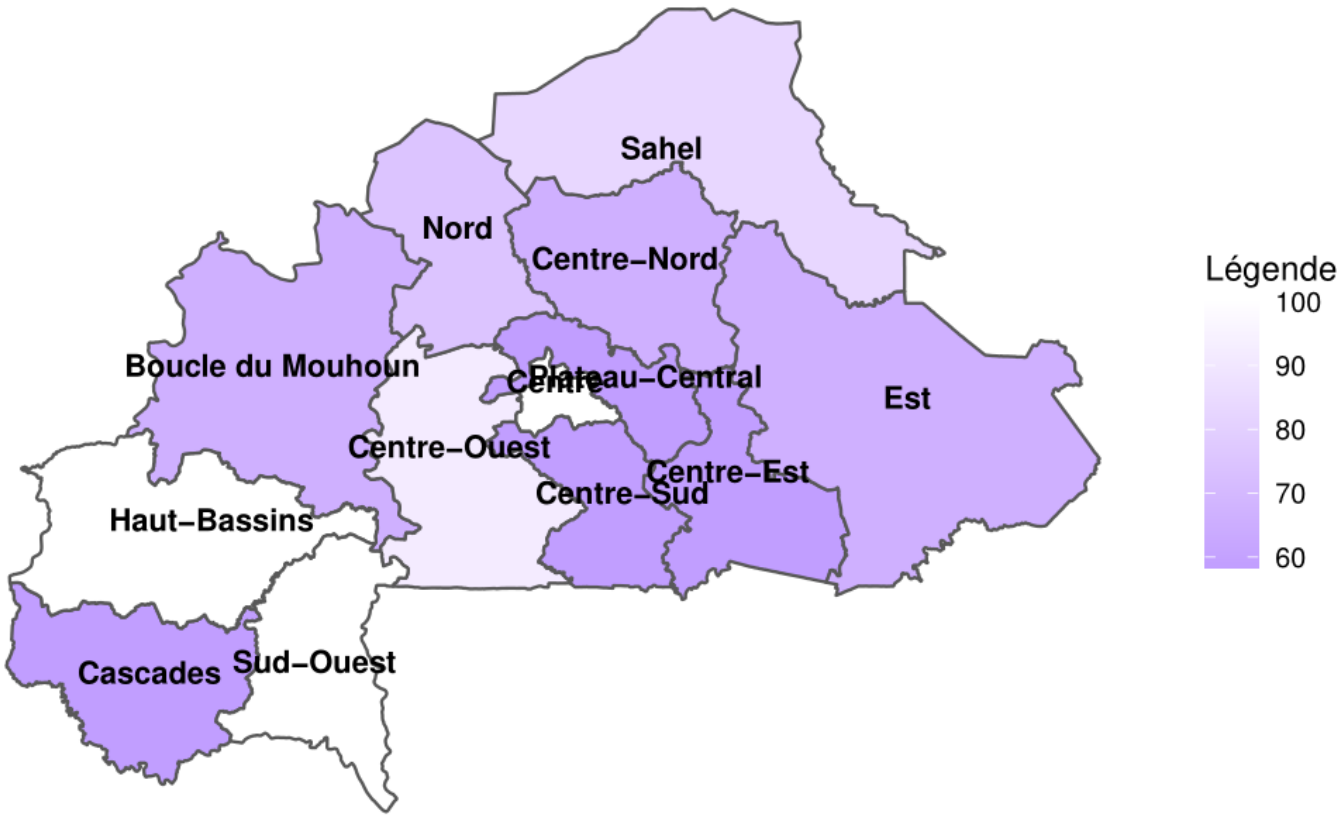

FIGURE 7 – **Exhaustivité de la notification du nombre de personnes dépistées positives au VIH au niveau régional**

IV.2.2 Résultat de la Cohérence interne des données notifiées

IV.2.2.1 Test de changement structurel sur les indicateurs d'intérêt

✓ **Résultat de la Cohérence dans le temps des indicateurs d'intérêt**

Le test de changement structurel sur le nombre de personnes dépistées positives au VIH donne une p-value = 4.595e-08 significatif au seuil de 5%, cela prouve que la série des données présente des points de ruptures en mai et en septembre. L'indicateur n'est pas cohérent dans le temps car elle ne présente pas les mêmes allures au fil du temps.

Le test de changement structurel sur le nombre de femmes enceintes ayant bénéficié d'un test de dépistage du VIH lors des CPN donne une p-value = 0.002978 significatif au seuil de 5%. Le test révèle également les point de ruptures respectifs 29 (mois de Juin) et 35 (mois d'Octobre), donc l'indicateur n'est pas cohérent dans le temps car elle ne présente pas les mêmes allures au fil du temps.

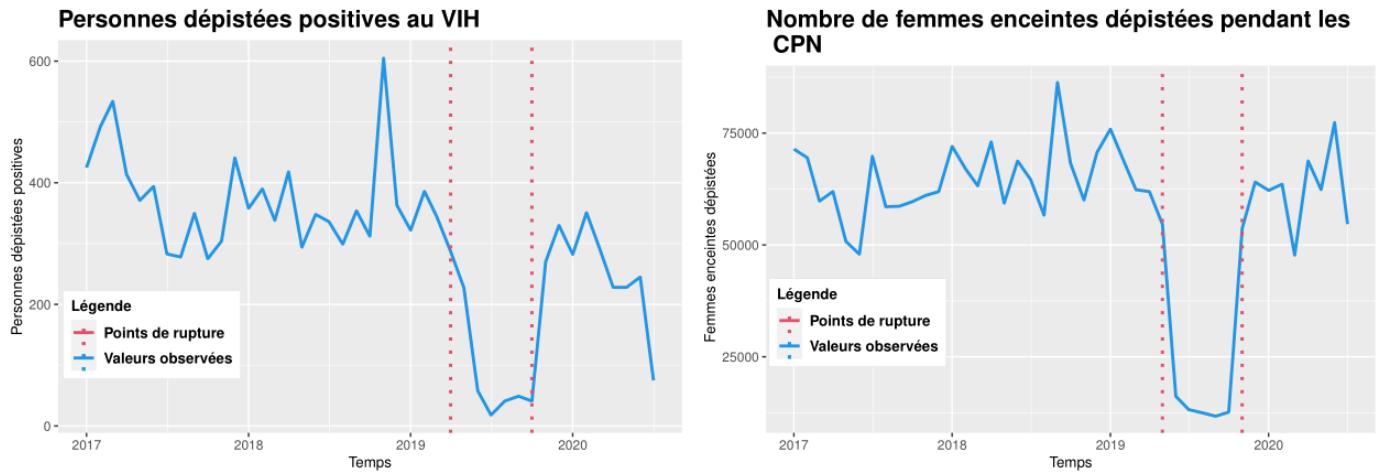

FIGURE 8 – **Cohérence dans le temps des indicateurs : représentation des points de ruptures**

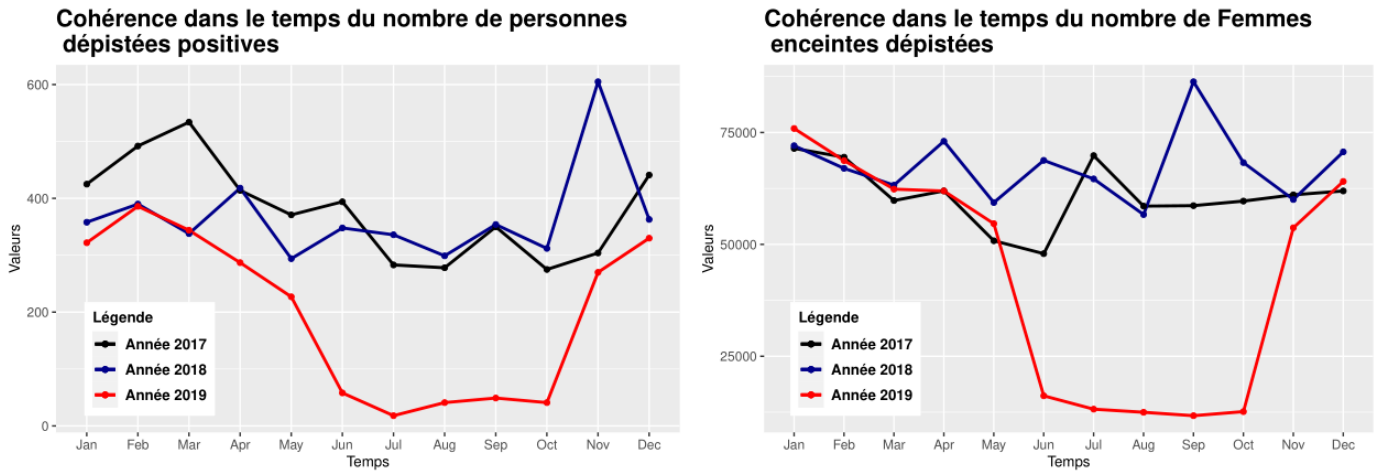

FIGURE 9 – **Cohérence de la notification dans temps : allure des courbes au fil du temps**

IV.2.2.2 Test de changement structurel sur les taux de rapportage

Les résultats du test sur le taux de rapportage dans le cadre de la protection mère-enfant donne une p.value= 2.977e-07 et une p-value = 1.146e-06 dans le cadre du rapportage CMA tous deux significatifs au seuil de 5%, cela signifie alors que l'hypothèse d'égalité des coefficients est rejetée, la série des données des taux de rapportages présente des points de ruptures. Les différents points de ruptures sont le mois juin et le mois d'octobre 2019. Le mois de juin correspond au début de la grève, la courbe prend donc une allure décroissante car les données n'étaient plus notifiées. Au mois d'octobre les courbes prennent une allure croissante car avec la fin de grève, les agents de santé ont commencé à notifier les données.

IV.3 L'imputation multiple par équations chainées

✓ **Résultat de la régression linéaire**

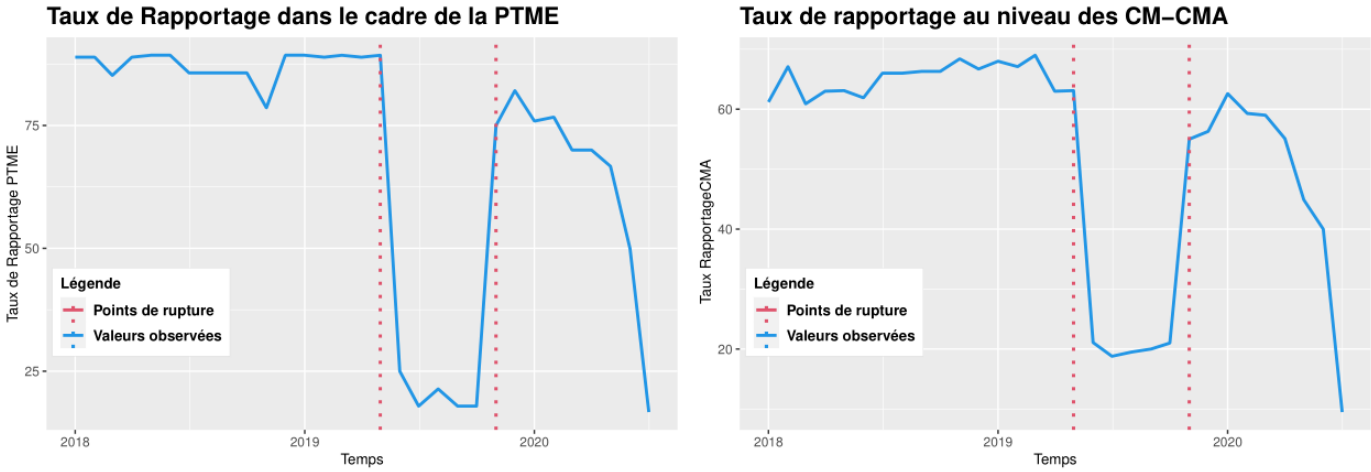

FIGURE 10 – **Cohérence du taux de Rapportage : représentation des points de ruptures**

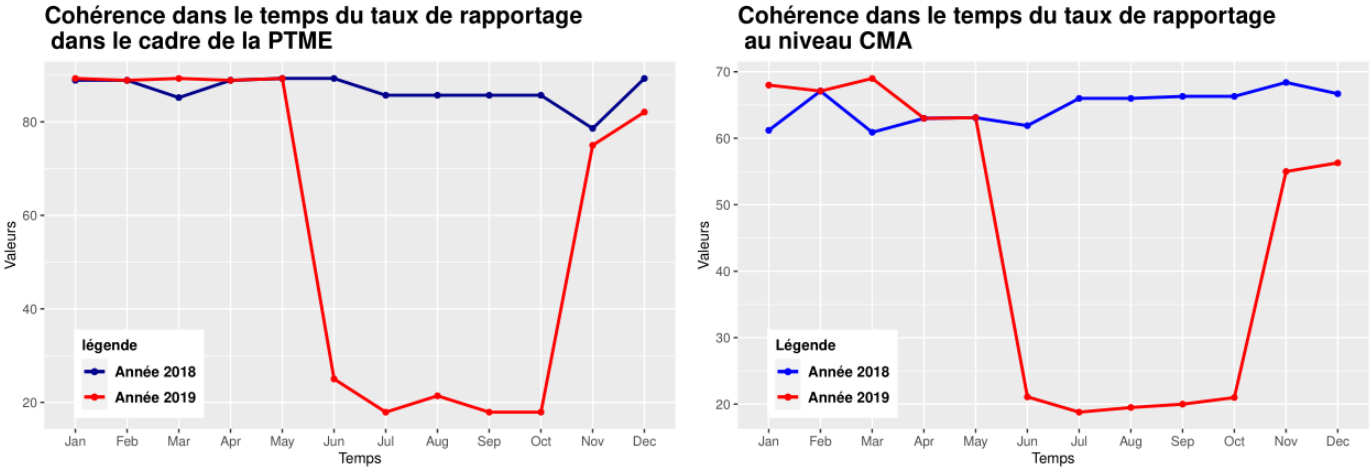

FIGURE 11 – **Cohérence du taux de Rapportage : allure des courbes au fil du temps**

- Pour les femmes enceintes dépistées :

$$log(\widehat{FEdepiste}) = 4.2177 + 1.1670 \log(tauxDepistag) + 0.8543 \ log(Taux_CouvertureCPN1) \tag{12}$$

Une augmentation de 1% du taux de dépistage dans le cadre de la PTME (Prévention de la Transmission Mère Enfant) entraine une augmentation du nombre de femmes qui ont bénéficié d'un test de dépistage lors de la CPN (Consultation Prénatal) de 11.6%, plus les femmes partent en CPN1 plus elles bénéficient du test de dépistage. Une augmentation de 1% de la couverture en CPN entraine une augmentation du nombre de femmes qui ont bénéficié d'un test de dépistage lors de la CPN (Consultation Prénatal) de 85.43%.

La p-value= 7.85e-16 significatif au seuil de 5% et le $r^2 = 0.9258$ cela signifie que 92.58% de la variation du nombre de femmes qui ont bénéficié d'un test de dépistage lors de la CPN est expliquée par la couverture en CPN1 (première Consultation Prénatal) ainsi que le taux de dépistage. Ainsi, la

matrice de prédiction de ces deux indicateurs sera utilisée pour prédire notre indicateur d'intérêt dans de cadre de l'imputation.

- Pour les personnes dépistées positives au VIH :

$$\widehat{log(VIH+)} = -0.7975 + 0.6770log(Test_ffectue) \quad (13)$$

Une augmentation de 1% du nombre de test réalisé entraine une augmentation du nombre de personnes dépistées positives VIH (test positif)de 67.70%.
La p-value : 0.0002846 significatif au seuil de 5% et le $r^2 = 0.3688$ les tests effectués expliquent le nombre de personnes positives au VIH à 36.68%.

✓ **Résultat de l'imputation MICE**

L'imputation au niveau national consiste à considérer les données de la période de grève comme manquante avant d'appliquer la méthode MICE. Ce qui nous a permis d'obtenir des valeurs plausibles car les données imputées et celles observées sont les mêmes densités. Voir annexe page**??**.

TABLE 1 – ***Tableau comparatif des valeurs observées et des valeurs imputées***

Indicateurs	Dépistées VIH+		Femmes enceintes dépistées	
mois	**Observées**	**Imputation**	**Observées**	**Imputation**
Juin	58	534	16164	68728
Juillet	18	390	13175	58555
Aout	41	322	12480	47929
Septembre	49	358	11720	56664
Octobre	41	293	12631	7305

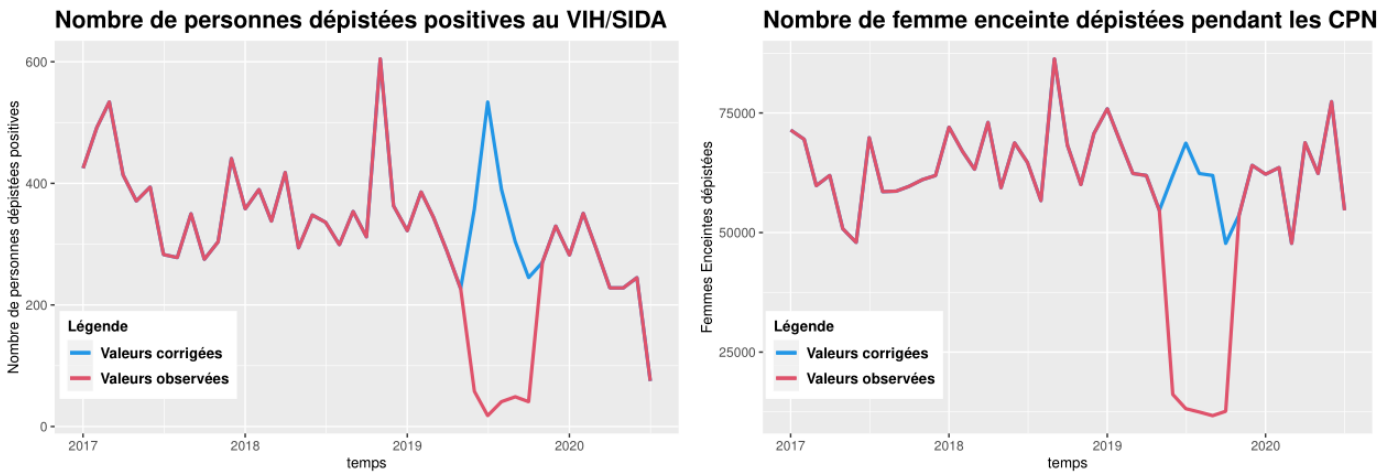

FIGURE 12 – **Résultats de l'imputation MICE**

IV.4 Prévision par lissage exponentiel

TABLE 2 – ***Les paramètres de lissage***

Paramètres / Indicateurs	α	β
Nombre de femmes enceintes testées	0.9	0.1
Nombre de personnes VIH+	0.9	0.05

Les constantes de lissage des deux indicateurs montrent un poids modéré au passé et aux valeurs récentes.

TABLE 3 – ***Tableau comparatif de la prévision et des valeurs observées***

Indicateurs	Dépistées VIH+		Femmes enceintes dépistées	
mois	**Observées**	**Prévision**	**Observées**	**Prévision**
Juin	58	243.6792	16164	56171.95
Juillet	18	252.3465	13175	56171.95
Aout	41	261.013	12480	56171.95
Septembre	49	269.6813	11720	56171.95
Octobre	41	278.3487	12631	56171.95

Les prévisions à l'horizon h sont

$$\widehat{VIH+}_{(h)} = 235.011763 + 8.667388h \tag{14}$$

$$\widehat{FE}_{(h)} = 55308.386 - 1225.365h \tag{15}$$

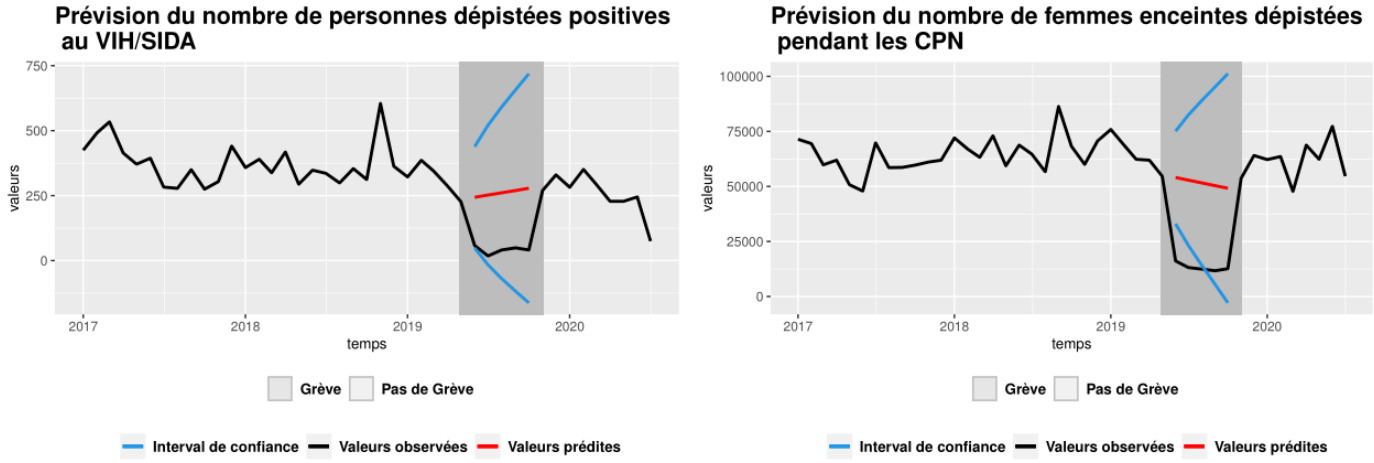

FIGURE 13 – **Lissage exponentiel des indicateurs d'intérêt**

IV.5 Discussion des résultats obtenus

IV.5.1 Synthèse des principaux résultats

Au terme de notre analyse, nous retenons que les données du VIH/SIDA présentent des anomalies. Ces anomalies se distinguent plus au niveau district. En effet, à ce niveau l'exhaustivité par indicateur est très faible car le taux de données manquantes est élevé, cela est dû généralement au faible rapportage des données. En ce qui concerne la cohérence du rapportage dans le temps, nous constatons qu'avec le test de chow à un seuil de 5% le test reste significatif pour les deux taux de rapportage, cela révèle un changement de structure des données dans le temps. Le test nous donne respectivement les différents points de rupture qui sont en juin 2019 marquant le début de la grève avec de faibles rapportage et octobre 2019 (un mois après la grève) avec un taux de rapportage tendant vers la normale.

Le test de chow effectué également sur chaque indicateur d'intérêt révèle un changement structurel. Le test effectué sur le nombre de personnes dépistées positives et le nombre de femmes enceintes ayant bénéficié d'un test de dépistage lors de la CPN (Consultations Prénatales) donne une p-value significatif au seuil de 5% et deux points de rupture qui est juin et octobre 2019, pendant cette période de grève, les agents de santé n'ont notifié aucune données concernant ces indicateurs.

La méthode MICE a été effectuée pour corriger les anomalies sur les données afin d'obtenir des valeurs plausibles. En effet, pour chaque variable incomplète, un modèle spécifique a été utilisé pour imputer les données manquantes de cette même variable. Ce qui signifie que chaque variable sera imputée en

utilisant sa propre distribution conditionnellement aux autres variables spécifiques du modèle. Nous constatons que les données imputées et celles observées ont les mêmes distributions **??**. Cela prouve que l'imputation MICE produit de meilleurs résultats.

Quant à la prévision faite sur la série de données de chaque indicateur d'intérêt, a pour but d'observer à l'horizon $h = 5$ correspondant à la durée de la grève les valeurs qui auraient dues être observées s'il n'y avait pas grève. Avec la méthode de lissage exponentiel, nous constatons que l'intervalle de confiance pour les valeurs prédites est large. D'après le tableau comparatif contenant les valeurs des données imputées et celles de la prévision ainsi que celles obtenues pendant la grève dans un tableau comparatif à la page**??**.

IV.5.2 Validation de l'étude

L'étude menée par l'OMS (Organisation Mondiale de la Santé) sur *l'évaluation de la qualité des données et des systèmes du niveau national et des partenaires relatifs au traitement de l'infection à VIH et au suivi des patients* [**?**] démontre que les données de routines ont un problème de qualité. Cette étude a également proposé des méthodes de correction des données qui est l'ajustement ou le recomptage . Dans notre étude nous avons démontrer que les données du VIH/SIDA présente un problème d'exhaustivité sur l'année 2019, nous avons essayé par la méthode d'imputation multiple et de prévision de corriger les données manquantes, ces résultats et ces propositions étant similaire, cela renforce la validité de nos résultats.

IV.5.3 Limites et forces de l'étude

L'étude présente quelques limites. Premièrement, dans le cadre de l'évaluation de la qualité des données notre étude n'a pas pris en compte la comparaison externe avec d'autres sources de données c'est à dire comparer la base de données en ligne avec des données d'enquêtes à la même période afin de mieux valider la non qualité des données. Deuxièmement, l'étude de la cohérence entres les indicateurs n'a pas été estimée car plusieurs indicateurs qui pourraient expliquer nos indicateurs d'intérêts existaient dans ENDOS sans données.

Malgré ces limites, l'étude présente également plusieurs avantages. Premièrement, les données utilisées sont celles de l'Entrepôt de données sanitaires du Burkina Faso notre travail prouve une utilisation des données récentes en ligne du Burkina et une valorisation de ENDOS. Deuxièmement, notre étude a appliqué de nouvelles méthodes pour mesurer la qualité des données du VIH ainsi que pour corriger les données manquantes car les données de qualité améliorée permettront aux directeurs de programme, de déterminer avec plus de précision là où il faut allouer des ressources supplémentaires pour améliorer les services de la protection mère-enfant et du traitement anti-rétro viral pour les patients dépistés positifs. Dernièrement, elle est d'une grande utilité parce qu'elle permettra de voir les performances de chaque district à notifier les données ainsi de mettre l'accent sur les districts par apports financiers et matériels pour une bonne notification.

IV.5.4 Recommandations

- **Accélérer les processus d'automatisation de la capture des données sur la fourniture des services de santé ;**
- **Renforcer les CISSE en personnels et en capacité pour un meilleur contrôle de la qualité de l'information sanitaire ;**
- **Intégrer les données de suivi de patients VIH dans la plateforme ENDOS-BF ;**
- **Sensibiliser les prestataires de santé sur l'importance de l'information sanitaire pour leurs activités ;**
- **Former les acteurs de la santé publique et les chercheurs à l'utilisation des données de prestations des services de routines.**

IV.6 Conclusion

Après l'analyse il ressort que la grève a négativement impacté la qualité des données du VIH/SIDA. En effet, les données n'ont pas été notifiées pendant la grève. Le taux d'exhaustivité des indicateurs en 2019 est inférieur à 90% et le taux de rapportage inférieur à 75% car les rapports d'activités mensuels n'étaient plus soumis pour la saisie des données dans ENDOS-BF. Les méthodes de correction par imputation multiple et de prévision ont été utilisées pour remedier au problème de données manquantes. Il est a noter que l'imputation multiple par équations chainées présente beaucoup d'avantages comparativement à la méthode de prévision.

Conclusion Générale

Le système national du Burkina Faso est victime de problème de qualité de données après la grève des agents de santé. L'objectif de l'étude est de proposer une méthode de correction des données du VIH/SIDA du Système National d'Information Sanitaire (SNIS) après une évaluation de la qualité de ces données. Pour y arriver, nous avons utilisé les indicateurs du VIH/SIDA disponibles dans l'entrepôt de données sanitaires du Burkina Faso. Les deux principaux indicateurs choisi sont : *Le nombre de personnes dépistées positives au VIH/SIDA* et *Le nombre de femmes enceintes dépistées pendant les consultations prénatales dans le cadre de la protection mère-enfant.*

Après l'analyse de la qualité des données, avec un taux d'exhaustivité faible (inférieur à 90%) pour chaque indicateur spécifique et un taux de rapportage faible (inférieur à 75%) nous avons trouvé que la grève a impacté négativement la qualité des données. Cela nous permet de confirmer notre première hypothèse qui stipule que nous avons une mauvaise qualité des données avec la grève.

Ensuite, l'application du test de chow sur chaque série d'indicateur et sur les différents taux de rapportage montre une rupture au mois de juin 2019 (début de la grève) indiquant réellement le changement de l'allure des différentes courbes. De ce test statistique nous confirmons notre deuxième hypothèse qui stipulait que la grève a entrainé un changement brusque de la série des données du VIH/SIDA.

Enfin, les régressions linéaires multiples des indicateurs d'intérêt avec d'autres indicateurs du VIH/-SIDA étaient toutes significatives au seuil de 5%. Nous avons donc conclu que les valeurs des indicateurs d'intérêt dépendaient d'autres valeurs présentent dans l'entrepôt, donc la méthode d'imputation multiple pour la correction des valeurs manquantes se fait en fonction des liens retrouvés entre indicateurs. Nous confirmons notre troisième hypothèse.

L'application de la méthode de prévision permet d'obtenir des données suivant une tendance en fonction des paramètres de lissage. Elle demeure une méthode à prendre en considération.

L'investissement sur le programme VIH/SIDA pourrait être un gaspillage de ressource si l'on ne remédie pas aux problèmes de qualité des données.

Références bibliographiques

[1] Yusentha et Hohlfeld Ameer et Odendaal Willem A et Schmidt Bey-Married et Zweigenthal Virginia et Watkins Jocelyn Anstey et Daniels Karen Leon, Natalie et Balakrishna. Améliorations du système d'information sanitaire de routine (sisr) pour une gestion renforcée du système de santé. *Base de données Cochrane des revues systématiques*, 2020.

[2] Organisation Mondiale de la Santé. Cadre et normes applicables aux systèmes nationaux d'information sanitaire. 2017.

[3] Organisation Mondiale de la Santé. Evaluation de la qualité des données et des systèmes du niveau national et des partenaires relatifs au traitement de l'infection à vih et au suivi des patients : outil de mis en oeuvre. Technical report, Organisation mondiale de la Santé, 2018.

[4] Organisation Mondiale de la Santé. Projet de stratégie oms sur le vih, 2011-2015 : rapport du secrétariat. Technical report, Organisation mondiale de la Santé, 2011.

[5] Yang W et Wang Richard Y Strong, Diane M et Lee. Qualité des données en contexte. *Communications de l'ACM*, 40 :103–110, 1997.

[6] Rami Harrathi and Sylvie Calabretto. Un modèle de qualité de l'information. In *EGC*, pages 299–304, 2006.

[7] Organisation Mondiale de la Santé. Data quality review (examen de la qualité des données) : module 2 : examen sur dossier de la qualite des donnees. 2019.

[8] Lippeveld T Ye Y (2016) Ly M, N'Gbichi JM. Rapport d'évaluation de la performance du Système d'Information Sanitaire de Routine (SISR) et de la Surveillance Intégrée de la Maladie et la Riposte (SIMR) — MEASURE Evaluation. `https://www.measureevaluation.org/resources/publications/sr-16-129-fr`. (visité le 2020-06-20).

[9] Rapport sur la qualite des donnees sanitaires dqr niger. `https://docplayer.fr/52281886-Rapport-sur-la-qualite-des-donnees-sanitaires-dqr-niger.html`. (visité le 2020-09-22).

[10] Rapport d'Evaluation du Système d'Information Sanitaire de Routine par l'Approche et les Outils PRISM — MEASURE Evaluation. `https://www.measureevaluation.org/resources/publications/sr-15-120-fr`. (visité le 2020-06-02).

[11] Laurent Donzé. L'imputation des données manquantes, la technique de l'imputation multiple, les conséquences sur l'analyse des données : l'enquête 1999 kof/ethz sur l'innovation. 2001.

[12] Stéphane Paquin. Comparaison de quatre méthodes pour le traitement des données manquantes au sein d'un modèle multiniveau paramétrique visant l'estimation de l'effet d'une intervention. 2011.

[13] Paul Dixneuf. *Analyse de la performance de la méthode d'imputation de données manquantes missForest et application à des données environnementales.* PhD thesis, École de technologie supérieure, 2019.

[14] Elizabeth A et Frangakis Constantine et Leaf Philip J Azur, Melissa J et Stuart. Imputation multiple par équations chaînées : qu'est-ce que c'est et comment ça marche ? *Revue internationale des méthodes de recherche psychiatrique*, 20 :40 à 49, 2011.

[15] Jean-Marc Kouadjo, Jean Arnaud Kouakou, and Kouamé Désiré Kanga. 3. méthodologie d'obtention d'une base de données imputées. *Journal statistique africain*, 62, 2013.

[16] Fonds Mondial Genève. Subventions du fonds mondial au burkina faso, 22 novembre 2017.

[17] BURKINA FASO. Rapport d'activite sur la riposte au sida au burkina faso (garp 2014). 2014.

[18] Burkina : Le SYNTSHA annonce un mouvement de juin à septembre - L'Actualité du Burkina Faso 24h/24. `https://www.burkina24.com/2019/06/04/burkina-le-syntsha-annonce-un-mouvement-de-juin-a-septembre/`. (visité le 2020-07-02).

[19] Ricco Rakotomalala. Pratique de la regression lineaire multiple. *Diagnostic et selection de variables*, 2011.

[20] Gilles Cottrell, Michel Cot, and J-Y Mary. L'imputation multiple des données manquantes aléatoirement : concepts généraux et présentation d'une méthode monte-carlo. *Revue d'épidémiologie et de santé publique*, 57(5) :361–372, 2009.

[21] Agnes Lagnoux. Séries chronologiques. *ISMAG, Master1-MI00141X, Université de Toulouse Le Mirail, 53p*, 2015.

[22] WHO-CDS-HIV-18.43-fre.pdf. `https://apps.who.int/iris/bitstream/handle/10665/312370/WHO-CDS-HIV-18.43-fre.pdf?ua=1`. (visité le 2020-11-27).

TABLE DES ANNEXES

Annexe I : Description de l'indicateur "Femmes enceintes ayant bénéficié d'un test de dépistage du VIH lors des CPN dans le cadre de la PTME" **IV**

Annexe II : Description de l'indicateur "VIH - Dépistés VIH positif" **V**

Annexe III : Données manquantes et visualisation **VI**

Annexe IV : Résultat de l'exhaustivité du taux de rapportage **VII**

Annexe V : Résultat de l'exhaustivité des indicateurs **VIII**

Annexe VI : Test de chow **IX**

Annexe VII : Résultats de l'estimation du test de chow sur le rapportage **X**

Annexe VII : L'algorithme de MICE **XI**

Annexe VIII : Les phases de l'imputation multiple **XII**

Annexe IX : Présentation des résultats de l'imputation et de la prévision **XIII**

Annexe I : Description de l'indicateur "Femmes enceintes ayant bénéficié d'un test de dépistage du VIH lors des CPN dans le cadre de la PTME"

TABLE 4 – ***Femmes enceintes ayant bénéficié d'un test de dépistage du VIH lors des CPN dans le cadre de la PTME***

Définition opérationnelle	Nombre de femmes enceintes vues en CPN et ayant réalisé le test VIH dans le cadre de la PTME.
Objet	Apprécier la mise en oeuvre du dépistage systématique du VIH chez les femmes enceintes lors des CPN
Mode d'expression	Nombre
Formule	Nombre de femmes enceintes vues en CPN et ayant réalisé le test VIH
Périodicité	Mensuelle, trimestrielle, semestrielle, annuelle
Source des données	Registre PTME, registre CPN, rapport mensuel d'activités
Niveau de calcul	Formation sanitaire, district, région, national
Programmes, politiques ou structure suivant l'indicateur	DGS (PSSLS), PNDS

Source : *Ministère de la Santé*

Annexe II : Description de l'indicateur "VIH - Dépistés VIH positif"

Table 5 – ***VIH - Dépistés VIH positif***

Définition opérationnelle	Nombre de personnes testées VIH+ à une période donnée
Objet	Mesurer l'acceptation du test de dépistage VIH et apprécier la séropositivité au VIH
Mode d'expression	Nombre
Formule	Nombre de personnes testées VIH + dans la population totale à une période donnée
Périodicité	Mensuelle, trimestrielle, semestrielle, annuelle
Source des données	enquêtes, rapport mensuel d'activités
Niveau de calcul	Formation sanitaire, district, région, national
Programmes, politiques ou structure suivant l'indicateur	PSSLS, PNDS, GARP

Source : *Ministère de la Santé*

Annexe III : Données manquantes et visualisation

I.1 Données manquantes et valeurs nulles par indicateur

La figure ci-dessous est une représentation graphique des données manquantes au niveau district sanitaire.

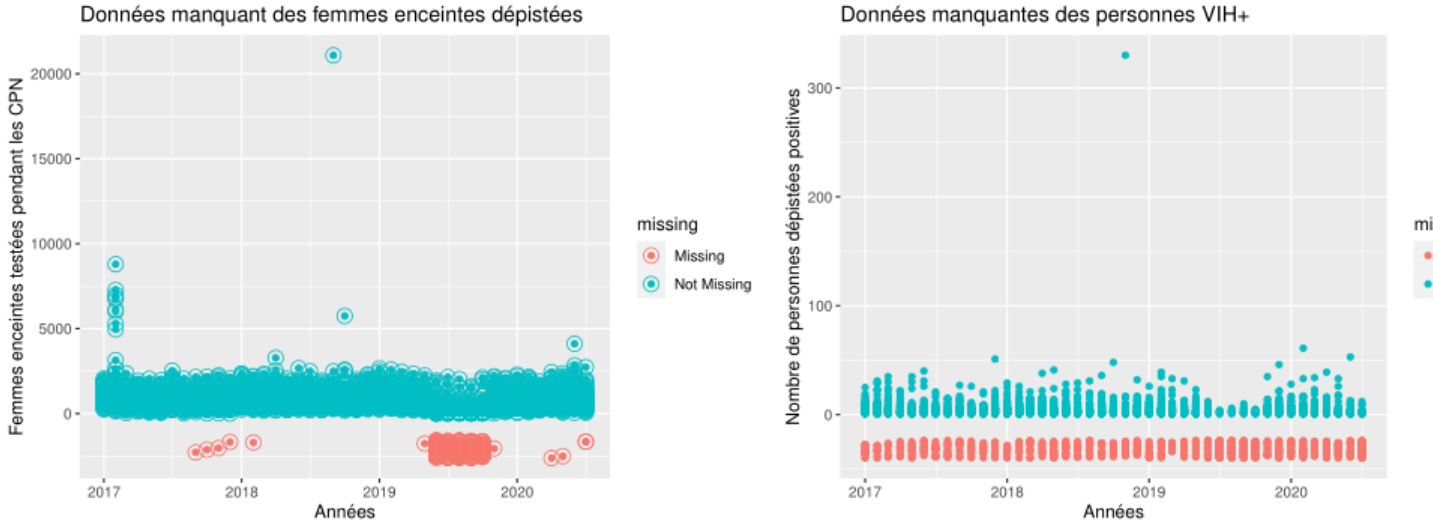

FIGURE 14 – **Visualisation au niveau district des données manquantes**

Une analyse dans la base de données nous montre le nombre de valeurs nulles et de valeurs manquantes par indicateur dans la base de donnée.

TABLE 6 – ***Données manquantes par indicateur***

Indicateurs	**Nombre de valeurs nulles**	**Nombre de valeurs manquantes**
Femmes enceintes ayant bénéficié d'un test de dépistage du VIH lors des CPN dans le cadre de la PTME	0	219
VIH - Dépistés VIH positif	0	943

Annexe IV : Résultat de l'exhaustivité du taux de rapportage

Table 7 – ***L'exhaustivité du rapportage pour l'année 2019***

Structures	Rapport CM-CMA		Rapport PTME	
mois	**District (N=70)**	**Région (N=13)**	**District (N=70)**	**Région (N=13)**
Janvier	4(5.7%)	100%	69(98.6%)	2(15.4%)
Février	3(4.3%)	100%	69(98.6%)	2(15.4%)
Mars	5(7.1%)	100%	69(98.6%)	2(15.4%)
Avril	3(4.3%)	100%	69(98.6%)	2(15.4%)
Mai	6(8.6%)	100%	69(98.6%)	2(15.4%)
Juin	51(72.9%)	5(38.5%)	100%	9(69.2%)
Juillet	54(77.1%)	7(53.8%)	100%	9(69.2%)
Aôut	54(77.1%)	6(46.2%)	100%	9(69.2%)
Septembre	52(74.3%)	6(46.2%)	100%	9(69.2%)
Octobre	51(72.9%)	6(46.2%)	100%	9(69.2%)
Novembre	5(7.1%)	100%	69(98.6%)	2(15.4%)
Decembre	3(4.3%)	100%	69(98.6%)	2(15.4%)

Annexe V : Résultat de l'exhaustivité des indicateurs

Table 8 – ***Exhaustivité des données des indicateurs***

Indicateurs	Dépistées VIH+		Femmes enceintes depistées	
mois	**District1 (N=70)**	**Région1 (N=13)**	**District2 (N=70)**	**Région2 (N=13)**
Janvier	11(15.7%)	100%	100%	100%
Février	13(18.6%)	100%	100%	100%
Mars	8(11.4%)	100%	100%	100%
Avril	11(15.7%)	100%	100%	100%
Mai	18(25.7%)	1(7.7%)	1(1.4%)	100%
Juin	57(81.4%)	7(53.8%)	38(54.3%)	1(7.7%))
Juillet	63(90.0%)	9(69.2%)	40(57.1%)	3(23.1%)
Aôut	62(88.6%)	9(69.2%)	40(57.1%)	2(15.4%
Septembre	58(82.9%)	6(46.2%)	39(55.7%)	3(23.1%)
Octobre	59(84.3%)	6(46.2%)	40(57.1%)	2(15.4%)
Novembre	16(22.9%)	100%	1(1.4%)	100%
Decembre	17(24.3%)	1(7.7%)	100%	100%

Annexe VI : Test de chow

Le test de changement structurel se base sur la confrontation d'une régression contrainte avec une régression non-contrainte. Le but principale est de déterminer si, sur les deux sous ensembles étudiées, certains coefficients sont les mêmes. $Si\ f > f*(p,q)$ On accepte H_1. La statistique du test suit une loi de FISHER Les hypothèses du test sont les suivantes pour le cas ci-dessus :

$$\begin{cases} H_0 : \alpha_1 = \alpha_2' = \alpha_3'' \\ \qquad \alpha_2 = \alpha_2' = \alpha_2'' \rightarrow & \text{le modèle est stable} \\ \qquad \alpha_3 = \alpha_3' = \alpha_3'' \\ \Rightarrow \text{modèle contraint avec } SCR_c = SCR_0 \\ H_1 : \alpha_1 \neq \alpha_2' \neq \alpha_3'' \\ \qquad \alpha_2 \neq \alpha_2' \neq \alpha_2'' \rightarrow & \text{le modèle est instable} \\ \qquad \alpha_3 \neq \alpha_3' \neq\neq \alpha_3'' \\ \Rightarrow \text{modèle non contraint avec } SCR_{nc} = SCR_1 + SCR_2 \end{cases}$$

SCRc = somme des carrés des résidus du modèle contraint et SCRnc = somme des carrés des résidus du modèle non contraint. La statistique du test lorsque H0 est vraie s'écrit :

$$f = \frac{(SCR_c - SCR_{nc})/(dl_c - dl_{nc})}{SCR_{nc}/dl_{nc}} \rightsquigarrow F(dl_c \breve{} dl_{nc}, dl_{nc}) = F(p,q)$$

$$\Leftrightarrow f = \frac{(SCR_0 - (SCR_1 + SCR_2))/(dl_c - dl_{nc})}{(SCR_1 + SCR_2)/dl_{nc}} \rightsquigarrow F(dl_c \breve{} dl_{nc}, dl_{nc}) = F(p,q).$$

Annexe VII : Résultats de l'estimation du test de chow sur le rapportage

```
##  supF test
##
## data:  modell
## sup.F = 31.092, p-value = 1.146e-06
##
##   Optimal 4-segment partition:
##
## Call:
## breakpoints.formula(formula = raportN$rapportCM_CMA ~ 1)
##
## Breakpoints at observation number:
## 17 22 27
##
## Corresponding to breakdates:
## 0.5483871 0.7096774 0.8709677
```

```
##  supF test
##
## data:  modell
## sup.F = 33.731, p-value = 2.977e-07
##
##   Optimal 4-segment partition:
##
## Call:
## breakpoints.formula(formula = raportN$rapportPTME ~ 1)
##
## Breakpoints at observation number:
## 17 22 27
##
## Corresponding to breakdates:
## 0.5483871 0.7096774 0.8709677
```

Annexe VII : L'algorithme de MICE (Multivariate Imputation by Chained Equations)

L'algorithme MICE est une méthode de Monte-Carlo par chaines de Markov (MCMC), où l'espace d'état est une collection de toutes les valeurs imputées. Plus spécifiquement, si les conditionnelles sont compatibles, l'algorithme MICE est un échantillonneur de Gibbs, une technique de simulation bayésienne qui échantillonne à partir des distributions conditionnelles afin d'obtenir des échantillons de la distribution conjointe.

1. Spécifier un modèle d'imputation $P(Y_j^{mis}|Y_j^{obs}, Y_{-j}, R)$ pour la variable Y_j avec $j = 1, \cdots, p$.
2. Pour chaque j, remplir les imputations de depart Y_j^0 par un tirage aléatoire de Y_j^{obs}.
3. Répeter pour $t = 1, \cdots, T$.
4. Répeter pour $j = 1, \cdots, p$.
5. Définir $Y_{-j}^t = (Y_1^t, \cdots, Y_{j-1}^t, Y_{j+1}^{t-1}, \cdots, Y_p^{t-1})$ comme les données actuelles complètes sans Y_j.
6. Tirer $\phi_j^t \sim P(\phi_j^t|Y_j^{obs}, Y_{-j}^t, R)$
7. Tirer les imputations $Y_j^t \sim P(Y_j^{mis}|Y_j^{obs}, Y_{-j}^t, R, \phi_j^t)$.
8. Finir de répéter j.

Annexe VIII : Les phases de l'imputation multiple

FIGURE 15 – **Étapes de l'imputation multiple**

Annexe IX : Présentation des résultats de l'imputation et de la prévision

I Régression linéaire multiple

	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	4.2177	0.3736	11.29	0.0000
log(tauxDepistag)	1.1670	0.0705	16.56	0.0000
log(Taux_CouvertureCPN1)	0.8543	0.0737	11.59	0.0000

	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	-0.7975	1.6015	-0.50	0.6225
log(Test_ffectue)	0.6770	0.1625	4.17	0.0003

II Tableau Comparatif

TABLE 9 – ***Tableau comparatif entre l'imputation et la prévision***

Indicateurs	VIH+			FE depistées		
mois	**Observées**	**Prévision**	**Imputation**	**Observées**	**Prévision**	**Imputation**
Juin	58	243.6792	534	16164	56171.95	68728
Juillet	18	252.3465	390	13175	56171.95	58555
Aout	41	261.0139	322	12480	56171.95	47929
Septembre	49	269.6813	358	11720	56171.95	56664
Octobre	41	278.3487	293	12631	56171.95	7305

Source : *ENDOS-BF 2020*

II Validation de l'imputation MICE

Les courbes en rouges sont celles de l'imputation et celles en bleu est celle des valeurs observées. Nous remarquons donc que les courbes ont presque les mêmes densités. Les points en bleu sont celles des valeurs observées et celles en rouges les points imputées, à chaque itération les valeurs observées et celles imputées sont similaires.

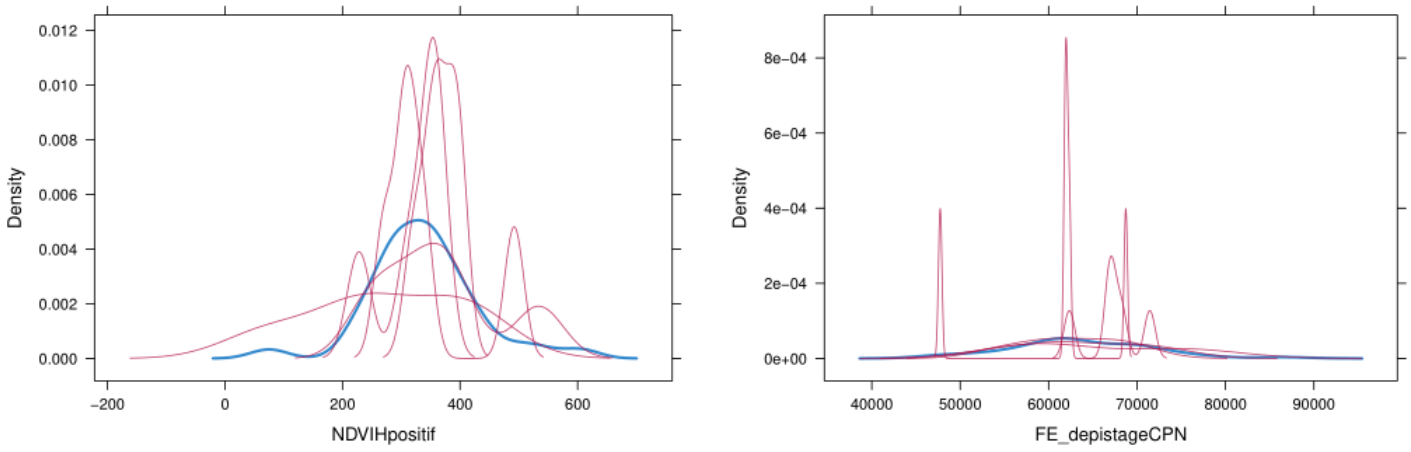

FIGURE 16 – **Courbes de densités de l'imputation**

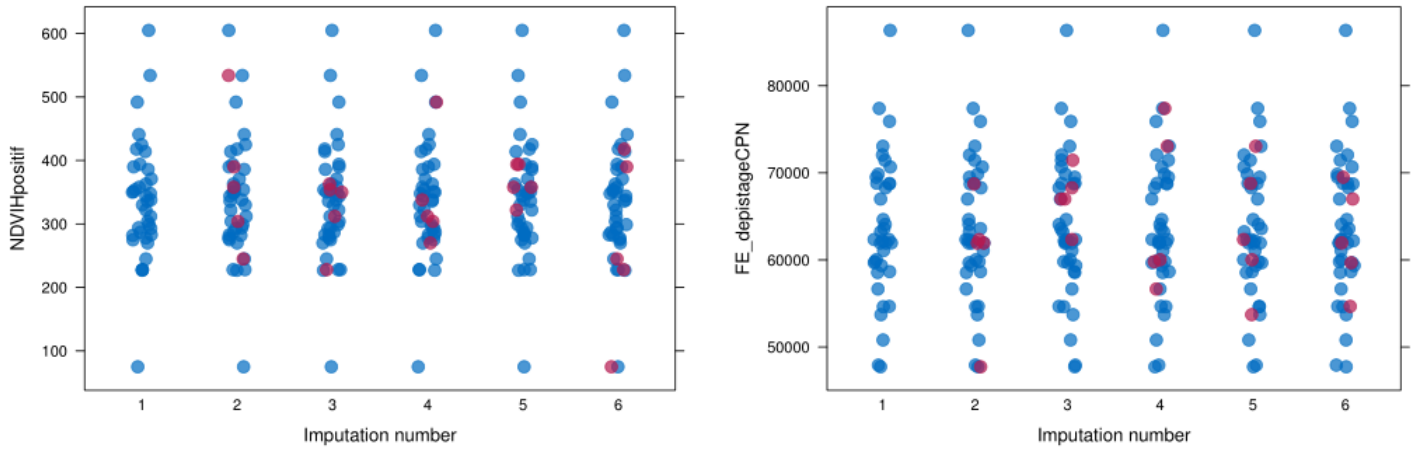

FIGURE 17 – **Comportement des données à chaque itération**

III Code source de l'imputation MICE sous R

Imputation utilisant la matrice de prédiction construit a base de l'imputation multuiple

```
library(dplyr)
library(mice)
library(lattice)
setwd("C:/Users/lenovo/Desktop/Rachida/MONRAPPORT")
imp_bf<- read.csv2("dataImpu.csv")
indic_bf<- select(imp_bf,NDVIHpositif , FE_depistageCPN,
   penfant_traitementC)
#md.pattern(indic_bf)
imp_1<- mice(imp_bf, maxit = 0)
```

```
# Les methodes
pred<- imp_1$predictorMatrix
meth<-imp_1$method
post <- imp_1$post
# La matrice de prediction
pred["NDVIHpositif",]<-c(0,      0        ,0,      0,       1,       0,
         0,       0,       0,       0,
                          0,      0,       0,       0,       0,       0,
                                    0,       0,       0,       0,
                         0,       0,       0,       0,       0,       0)
pred["FE_depistageCPN",]<-c(0,  0        ,0,      0        ,0,      0,
         ,0,      0,
                                  0,       0,       0,       0,       0,
                                           0,       0        ,0,
                                  0        ,0,      0        ,0,      1
                                             ,0,      0,       0,
                                     0,
                                          1)

#les mothodes
meth["penfant_traitementC"]<-"pmm"
meth["NDVIHpositif"]<-"pmm"
meth["FE_depistageCPN"]<-"pmm"

imp <- mice(imp_bf, meth="pmm", pred=pred, print=FALSE, m=5, seed
   =123)
```

Imputation utilisant les coefficients de l'imputation multuiple

```
library(dplyr)
setwd("C:/Users/lenovo/Desktop/Rachida")
imp_bf1<- read.csv2("dataImpu2e.csv")
indic_bf1<-select(imp_bf1,NDVIHpositif , FE_depistageCPN)
library(lattice)
library(mice)
md.pattern(indic_bf1)
```

```
imp_2<- mice(imp_bf1, maxit = 0)
# Les methodes
pred<- imp_2$predictorMatrix
meth<-imp_2$method
post <- imp_2$post
meth["NDVIHpositif"]<- "~I(-0.7975 +0.6770*Test_ffectue )"
meth["FE_depistageCPN"]<- "~I(4.21768 +1.16696*tauxDepistag +
   0.85427*Taux_CouvertureCPN1)"
pred[c("Test_ffectue"), "NDVIHpositif"] <- 0

pred[c("tauxDepistag","Taux_CouvertureCPN1"), "FE_depistageCPN"] <-
    0
pred[c("penfantPCR6s", "PFECD4", "tauxDepistag"), "
   penfant_traitementC"] <- 0

imp1 <- mice(imp_bf1, meth=meth, pred=pred, print=FALSE, m=5, seed
   =123)
```

Récapitulatif des niveaux d'élaboration et de transmission des rapports de santé

Table 10 – ***Récapitulatif des niveaux d'élaboration et de transmission des différents types de rapports***

Niveau d'élaboration	**Type de rapport**	**Période du rapport**	**Niveau de transmission**	**Delais de transmission/de saisie/de validation**
Communautaire	RMA de santé communautaire	Du 26 du mois précédent au 25 du mois en cours	CSPS/OBC	Fin du mois en cours
CSPS	Synthèse du RMA de santé communautaire	Du 26 du mois précédent au 25 du mois en cours	ECD	le 05 du mois suivant
CSPS/CM/CMA	RMA	Du 26 du mois précédent au 25 du mois en cours	ECD	le 05 du mois suivant
FS/Unités de soins	TLOHe	Lundi au Dimanche	Téléphone	Lundi avant 10h
Unités des soins et services des hôpitaux	RMA	Du 26 du mois précédent au 25du mois en cours	SIM/SPIH	5 du mois suivant

ECD	Saisie du RMA sur Endos	Du 26 du mois précédent au 25 du mois en cours	En ligne	Jusqu'au 20 du mois suivant
SIM/SPIH	Saisie du RMA sur Endos	Du 26 du mois précédent au 25 du mois en cours	En ligne	Jusqu'au 20 du mois suivant
OBC	Saisie du RMA sur Endos	Du 26 du mois précédent au 25 du mois en cours	En ligne	Jusqu'au 20 du mois suivant

Source :*Ministère de la Santé*